

Deflected Subgradient Method per ELM LASSO

Tutorial completo con dimostrazioni, comportamento atteso, risultati

Group 63 — nota di studio

Abstract

Questo documento spiega da zero il *Deflected Subgradient Method con Polyak Target Level* (SGPTL) richiesto dal progetto ML-25. È pensato per essere autosufficiente: chi legge non deve aver mai visto un metodo del subgradiente. Coprono in ordine: analisi convessa di base, subgradienti, metodo del subgradiente puro, passo di Polyak, convergenza e rate, deflessione, target level, sicurezze pratiche, applicazione a ELM LASSO. Ogni teorema usato è dimostrato per intero; ogni risultato sperimentale atteso è illustrato con il plot reale prodotto dai nostri esperimenti.

Contents

I	Background: il problema e gli strumenti matematici	4
1	Il problema: ELM LASSO	4
1.1	Decomposizione che useremo sempre	5
1.2	Dimensioni tipiche e cosa cambia	5
2	Strumenti di analisi convessa	7
2.1	Funzioni convesse	7
2.2	La f del nostro problema è convessa (e strongly convex)	7
2.3	Sublivelli, coercività e compattezza	7
2.4	Perché i sublivelli compatti ci servono per la teoria di convergenza	8
2.5	Gradiente, subgradiente, subdifferenziale	9
2.6	Regole di calcolo del subdifferenziale	9
2.7	Subdifferenziale di f in ELM LASSO	10
2.8	Condizioni di ottimalità (KKT) del LASSO	12
2.9	La disuguaglianza chiave	12
2.10	Lipschitz continuity su compatti e bound L sui subgradienti	12
II	Il metodo del subgradiente puro	12
3	L'algoritmo	13
3.1	Schema base	13
3.2	Quali stepsize si possono usare	13
4	Il passo di Polyak	13
4.1	Derivazione	13
4.2	Range ammissibile e perché è "ottimale"	14

5	Convergenza del subgradiente con passo di Polyak	14
5.1	Cosa dice il rate in pratica	16
5.2	Il lower bound di Nemirovski-Yudin	16
III	Il metodo del subgradiente deflesso	16
6	Perché il subgradiente puro non basta	16
6.1	Il problema delle oscillazioni	16
6.2	L'idea: combinare con la direzione precedente	16
7	La direzione deflessa	16
7.1	Scelta ottimale di γ_i : forma chiusa	17
7.2	Il floor $\gamma_{\min} > 0$	17
8	Passo deflesso e regola stepsize-restricted	17
9	Convergenza del subgradiente deflesso	18
9.1	La quantità chiave: ν_i	18
9.2	Dal Lemma 9.2 al rate	19
10	Errata: cosa era sbagliato nel vecchio Teorema 3.1 del report	20
10.1	L'enunciato del Teorema 3.1 — non era quello il problema	20
10.2	Dove la vecchia dim si rompeva	20
10.3	Il cuore della difficoltà: la dis. del subgradiente non si applica a $\mathbf{d}_i$	21
10.4	L'errore concreto del vecchio draft	21
10.5	Cosa fa la nuova dim per risolverli	21
10.6	Confronto vecchio vs nuovo, in tabella	22
10.7	Perché la nuova è certamente corretta — tre check	22
10.8	Riassunto onesto	23
IV	Il meccanismo del target level	23
11	Il problema: f^* è incognito	23
11.1	Definizioni	23
11.2	Regole di aggiornamento	23
11.3	Convergenza con target level: citazione + verifica delle ipotesi	24
11.4	Scelta di ρ	25
V	SGPTL: algoritmo completo e sicurezze	25
12	Sicurezze pratiche aggiuntive	25
13	Pseudocodice completo	26
14	Scelta dei parametri	26
VI	Applicazione a ELM LASSO	27
15	Calcolo del subgradiente	27

16	Verifica delle ipotesi del Teorema 9.1	27
17	Il warm-start OLS: costo, alternativa, perché conviene	27
17.1	Costo: contiamo i FLOP	27
17.2	Costo in contesto: confronto con il costo totale degli algoritmi	28
17.3	Cosa cambierebbe con il cold start $\mathbf{w}_0 = \mathbf{0}$	28
17.4	Sintesi	29
18	Esempio numerico (un'iterazione)	29
VII	Comportamento atteso e risultati	30
19	Convergenza	30
19.1	Non-monotonicità in f	30
20	Sensibilità a ρ	30
21	Warm vs cold start (con regola theory-pure)	31
22	Confronto con IRLS	32
23	Scalabilità	32
24	Validazione su dati reali	33
VIII	Lettura guidata della proof finale del Teorema 3.1	34
25	Il quadro generale: cosa stiamo provando e con quale strategia	34
26	La mappatura di notazione	35
27	Punto (a): la condizione (2.13)	37
28	Punto (b): la condizione (3.5)	38
29	Punto (c): la condizione (3.26)	38
30	Subgradienti uniformemente limitati	40
31	Lettura della conclusione	42
32	Cosa NON facciamo — e perché va bene	42
33	Sanity check: la proof è onesta?	43
34	Cosa potresti voler controllare ancora	43
IX	Conclusioni	43

Part I

Background: il problema e gli strumenti matematici

1 Il problema: ELM LASSO

L'Extreme Learning Machine (ELM) è una rete neurale a un solo strato nascosto in cui i pesi di input $\mathbf{W}_1$ sono fissati casualmente e *mai* aggiornati. Solo i pesi di output $\mathbf{w} \in \mathbb{R}^H$ vengono ottimizzati. Dopo aver applicato la non-linearità σ alla matrice di input, otteniamo

$$\mathbf{X} = \sigma(\mathbf{X}_{\text{origin}} \mathbf{W}_1^\top) \in \mathbb{R}^{M \times H},$$

matrice “fissa” dal punto di vista dell'ottimizzazione. Il problema diventa quindi regressione lineare con regolarizzazione ℓ_1 :

$$\min_{\mathbf{w} \in \mathbb{R}^H} f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1 \quad (1)$$

con $\lambda > 0$ parametro di regolarizzazione, $\|\mathbf{w}\|_1 = \sum_{i=1}^H |w_i|$, $\|\cdot\|_2$ norma euclidea. La regolarizzazione ℓ_1 spinge molte componenti di $\mathbf{w}$ a zero (*sparsità*), selezionando automaticamente i neuroni nascosti rilevanti.

Intuizione

f è la somma di due pezzi: un termine quadratico (smooth, derivabile ovunque) e un termine ℓ_1 (non differenziabile in tutti i punti in cui qualche $w_i = 0$). Il valore aggiunto del progetto è proprio gestire questa non-differenziabilità.

Perché un gradient descent classico non funziona direttamente. Tre motivi, in ordine crescente di gravità:

(1) *Il gradiente non esiste nei punti che ci interessano.* La regola di aggiornamento del gradient descent è $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha \nabla f(\mathbf{w}_i)$, ma ∇f non è definito sui punti con almeno una componente nulla. Il modulo $|w_i|$ ha una derivata che “salta” da -1 a $+1$ attraversando $w_i = 0$, e non esiste un unico vettore tangente. Su quegli iperpiani coordinati il gradient descent letteralmente non sa cosa fare.

(2) *Ed è proprio lì che vive la soluzione.* La caratteristica del LASSO è la sparsità: la soluzione ottimale $\mathbf{w}^*$ ha tipicamente *molte componenti esattamente zero*. Quindi $\mathbf{w}^*$ sta proprio negli iperpiani in cui ∇f non esiste — non è una patologia che si può evitare facendo un piccolo passo in più, è esattamente la regione che vogliamo raggiungere.

(3) *Anche barando, non si discende.* Si potrebbe pensare di prendere un qualsiasi subgradiente $\mathbf{g} \in \partial f$ al posto di ∇f (definito ovunque), e procedere come in gradient descent. Ma a differenza del caso smooth, $-\mathbf{g}$ **non è una direzione di discesa**: anche con passo arbitrariamente piccolo non è garantito $f(\mathbf{w}_{i+1}) < f(\mathbf{w}_i)$. Tutto l'apparato del gradient descent (line search di Armijo, controllo per direzione di discesa) si appoggia su quella proprietà; nel caso non-smooth crolla. Per questo serve una teoria diversa: il *metodo del subgradiente*, che non garantisce discesa monotona ma piuttosto convergenza del *record value* $\bar{f}^i = \min_{h \leq i} f(\mathbf{w}_h)$.

1.1 Decomposizione che useremo sempre

Scriviamo $f = g + h$ con

$$g(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2, \quad h(\mathbf{w}) = \lambda \|\mathbf{w}\|_1.$$

g è quadratica e C^∞ ; h è convessa ma con spigoli sui piani coordinati.

1.2 Dimensioni tipiche e cosa cambia

Cosa è M (= “campioni”). La regressione che stiamo facendo ha questa struttura: abbiamo M esempi (coppie input-output)

$$(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(M)}, y^{(M)}),$$

con ogni $\mathbf{x}^{(j)} \in \mathbb{R}^N$ un vettore di feature di input e $y^{(j)} \in \mathbb{R}$ il valore numerico che vogliamo predire. Ogni esempio è una *riga* della matrice $\mathbf{X}_{\text{origin}} \in \mathbb{R}^{M \times N}$ e una entry del vettore $\mathbf{y} \in \mathbb{R}^M$. Quindi M = numero di righe = numero di esempi disponibili per addestrare.

Cosa fa la trasformazione ELM, esempio per esempio. Prendiamo un singolo esempio $\mathbf{x}^{(j)} \in \mathbb{R}^N$ (un vettore di N feature originarie, una riga di $\mathbf{X}_{\text{origin}}$). L’ELM fa due cose:

- (1) Lo proietta su H “direzioni casuali”: calcola $\mathbf{W}_1 \mathbf{x}^{(j)} \in \mathbb{R}^H$, dove $\mathbf{W}_1 \in \mathbb{R}^{H \times N}$ è la matrice dei pesi nascosti (sorteggiata una volta sola, all’inizio, e poi mai più toccata). Il risultato è un vettore di H numeri reali ciascuno della forma $\sum_{n=1}^N (\mathbf{W}_1)_{hn} x_n^{(j)}$.
- (2) Applica una nonlinearietà σ *elemento per elemento*: il vettore $\sigma(\mathbf{W}_1 \mathbf{x}^{(j)}) \in \mathbb{R}^H$ ha come h -esima componente $\sigma((\mathbf{W}_1 \mathbf{x}^{(j)})_h)$. Esempi tipici di σ : sigmoide $\sigma(t) = 1/(1 + e^{-t})$, oppure tanh, oppure ReLU. Nel nostro codice usiamo la sigmoide.

Il risultato $\sigma(\mathbf{W}_1 \mathbf{x}^{(j)}) \in \mathbb{R}^H$ è la *nuova rappresentazione* di $\mathbf{x}^{(j)}$: le sue H componenti vengono chiamate *attivazioni dei neuroni nascosti* (con $\mathbf{W}_1$ vista come la matrice “input-to-hidden” di una rete neurale a uno strato).

Da esempio singolo a matrice $\mathbf{X}$. Mettiamo affiancate le rappresentazioni di tutti gli M esempi, uno per riga:

$$\mathbf{X} = \begin{pmatrix} \sigma(\mathbf{W}_1 \mathbf{x}^{(1)})^\top \\ \sigma(\mathbf{W}_1 \mathbf{x}^{(2)})^\top \\ \vdots \\ \sigma(\mathbf{W}_1 \mathbf{x}^{(M)})^\top \end{pmatrix} \in \mathbb{R}^{M \times H}.$$

Equivalentemente, in forma compatta: $\mathbf{X} = \sigma(\mathbf{X}_{\text{origin}} \mathbf{W}_1^\top)$, dove σ è applicata elemento per elemento alla matrice $\mathbf{X}_{\text{origin}} \mathbf{W}_1^\top \in \mathbb{R}^{M \times H}$.

Cosa è cambiato e cosa è rimasto. Confrontiamo le dimensioni:

	Prima dell’ELM	Dopo l’ELM
matrice esempi	$\mathbf{X}_{\text{origin}} \in \mathbb{R}^{M \times N}$	$\mathbf{X} \in \mathbb{R}^{M \times H}$
numero esempi (righe)	M	M (<i>invariato</i>)
feature per esempio (colonne)	N (originarie)	H (attivazioni nascoste)

Il numero di righe non cambia: continuiamo ad avere M esempi, gli stessi di prima, solo che ogni esempio è ora descritto da H “feature derivate” anziché dalle N feature originarie. È come passare da un dataset descritto in termini di età/altezza/reddito (le feature originali) a un dataset descritto in termini di H feature artificiali ottenute mescolando le feature originali con la nonlinearietà σ . Per il problema di ottimizzazione che ci interessa (trovare $\mathbf{w} \in \mathbb{R}^H$ che fa fittare bene $\mathbf{X}\mathbf{w} \approx \mathbf{y}$) la matrice di lavoro è $\mathbf{X}$, non più $\mathbf{X}_{\text{origin}}$.

La funzione di costo f . Una volta fissata $\mathbf{X}$, ogni candidato $\mathbf{w} \in \mathbb{R}^H$ produce un vettore di predizioni $\mathbf{X}\mathbf{w} \in \mathbb{R}^M$, cioè $(\mathbf{X}\mathbf{w})_j = \sum_{h=1}^H X_{jh} w_h$ è la predizione per l'esempio j . Il residuo dell'esempio j è $(\mathbf{X}\mathbf{w} - \mathbf{y})_j = \hat{y}_j - y^{(j)}$, e

$$\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 = \sum_{j=1}^M (\hat{y}_j - y^{(j)})^2$$

è la somma dei quadrati degli errori sui M esempi. Lo standard nel least-squares è il fattore $\frac{1}{2}$ davanti (semplifica la derivata: $\nabla_{\mathbf{w}} \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$, senza il 2 che verrebbe fuori derivando il quadrato). La penalità $\lambda \|\mathbf{w}\|_1$ aggiunge un termine che premia $\mathbf{w}$ con molte componenti nulle (sparsità), come discusso più sopra.

Cosa è H . Numero di neuroni nascosti, parametro architetturale che fissiamo prima di addestrare. Determina la dimensione del problema di ottimizzazione: $\mathbf{w} \in \mathbb{R}^H$, quindi H parametri da ottimizzare.

Cosa cambia nel regime $M > H$. Pensiamoci dimensionalmente: $\mathbf{X} \in \mathbb{R}^{M \times H}$ ha più righe che colonne (è “alta e magra”). Allora:

(a) $\mathbf{X}^\top \mathbf{X}$ è quasi sempre invertibile. $\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{H \times H}$ è simmetrica e $\succeq 0$ per costruzione. Diventa definita positiva (quindi invertibile) se e solo se $\mathbf{X}$ ha rango colonna pieno, cioè le colonne di $\mathbf{X}$ sono linearmente indipendenti. Con $M \geq H$ e $\mathbf{X}$ generata da una nonlinearietà su input casuali, questo accade “con probabilità 1” (in pratica sempre). Quando $M < H$ invece $\mathbf{X}$ può avere al massimo rango $M < H$, quindi $\mathbf{X}^\top \mathbf{X}$ è singolare per forza.

(b) f è strongly convex. Per la Proposizione 2.2: se $\mathbf{X}^\top \mathbf{X} \succ 0$ con autovalore minimo $\mu = \lambda_{\min}(\mathbf{X}^\top \mathbf{X}) > 0$, allora $\nabla^2 g = \mathbf{X}^\top \mathbf{X} \succeq \mu I$, cioè

$$g(\mathbf{w}) - g(\mathbf{w}') - \langle \nabla g(\mathbf{w}'), \mathbf{w} - \mathbf{w}' \rangle \geq \frac{\mu}{2} \|\mathbf{w} - \mathbf{w}'\|^2,$$

la disuguaglianza di strong convexity per g . Sommando h convessa (la ℓ_1), si conserva. Nel caso $M < H$ invece $\mu = 0$ e f è solo convex (non strongly).

(c) L 'OLS warm-start è ben definito.

Cos'è l'OLS warm-start. OLS = *Ordinary Least Squares* (minimi quadrati ordinari), il problema $\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$ senza regolarizzazione ℓ_1 . Se $\mathbf{X}^\top \mathbf{X}$ è invertibile, la soluzione esiste, è unica, ed è data dalla classica equazione normale

$$\mathbf{X}^\top \mathbf{X} \mathbf{w}_{\text{OLS}} = \mathbf{X}^\top \mathbf{y} \implies \mathbf{w}_0 := \mathbf{w}_{\text{OLS}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Si chiama *warm start* perché lo usiamo come punto iniziale $\mathbf{w}_0$ degli algoritmi IRLS e SGPTL: invece di partire da $\mathbf{w} = \mathbf{0}$ (*cold start*), partiamo da $\mathbf{w}_0$ che è già una buona soluzione del problema senza penalità ℓ_1 . Poi gli algoritmi iterativi “raffinano” $\mathbf{w}_0$ sciogliendo l'effetto della regolarizzazione ℓ_1 (cioè spingono a zero le componenti che il LASSO vuole eliminare).

Perché è ben definito? “Ben definito” nel senso matematico = esiste ed è unico. L'esistenza è garantita dalla coercività di $\frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$ (a cui non aggiungiamo ℓ_1 , quindi non cambia la coercività di g). L'unicità è garantita dalla strict convexity di g quando $\mathbf{X}^\top \mathbf{X} \succ 0$: una funzione strettamente convessa ha al più un minimizzatore. Quindi nel regime $M \geq H$ con rango pieno, $\mathbf{w}_{\text{OLS}}$ è univocamente determinata. Nella pratica si calcola con una fattorizzazione di Cholesky di $\mathbf{X}^\top \mathbf{X}$ ($O(H^3)$, una volta sola) seguita da forward/back substitution ($O(H^2)$ per RHS).

Nel progetto. H tra 50 e 2000, $M = 5H$ nella scalability, $M = 300$ sull'istanza di convergenza ($H = 100$), $M = 400$ sulla sweep dei parametri ($H = 100$), e su dati reali $M = 354$ con $H = 200$ (diabetes, dove $M < H$ ma poi standardizziamo) e $M = 16512$ con $H = 200$ (California housing). Aggiungiamo un piccolo Tikhonov $+10^{-12}I$ nel codice quando calcoliamo $\mathbf{w}_{\text{OLS}}$ per stabilità numerica: se $\mathbf{X}^\top \mathbf{X}$ è “quasi singolare” (autovalore minimo molto piccolo), il termine garantisce che il Cholesky non si rompa. In pratica $10^{-12} \mathbf{v}^\top \mathbf{v}$ è trascurabile rispetto alla scala di $\mathbf{X}^\top \mathbf{X}$ nei nostri esperimenti.

2 Strumenti di analisi convessa

2.1 Funzioni convesse

Definizione 2.1 (Convessità). Una funzione $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è *convessa* se per ogni $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ e $t \in [0, 1]$:

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y}).$$

Geometricamente: il segmento di estremi $(\mathbf{x}, f(\mathbf{x}))$ e $(\mathbf{y}, f(\mathbf{y}))$ giace *sopra* il grafico di f .

Definizione 2.2 (Strong convexity). f è μ -fortemente convessa con $\mu > 0$ se $f - \frac{\mu}{2} \|\cdot\|^2$ è convessa, equivalentemente:

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y}) - \frac{\mu}{2}t(1-t)\|\mathbf{x} - \mathbf{y}\|^2.$$

Per f due volte differenziabile, equivale a $\nabla^2 f \succeq \mu I$ ovunque.

2.2 La f del nostro problema è convessa (e strongly convex)

Proposizione 2.3. $f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$ è convessa. Se $\mathbf{X}$ ha rango colonna pieno, f è μ -strongly convex con $\mu = \lambda_{\min}(\mathbf{X}^\top \mathbf{X}) > 0$.

Dimostrazione

Convessità. $g(\mathbf{w})$ è quadratica con Hessiano $\mathbf{X}^\top \mathbf{X}$, che è simmetrico semidefinito positivo (per ogni $\mathbf{v}$: $\mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} = \|\mathbf{X}\mathbf{v}\|_2^2 \geq 0$). Funzioni quadratiche con Hessiano $\succeq 0$ sono convesse. $h(\mathbf{w}) = \lambda \sum_i |w_i|$ è somma di moduli (ciascun $|\cdot|$ è convesso) moltiplicati per scalare positivo, quindi convesso. La somma di convesse è convessa.

Strong convexity. Se $\mathbf{X}$ ha rango pieno colonna, $\mathbf{X}^\top \mathbf{X} \succ 0$ (definito positivo) con autovalore minimo $\mu = \lambda_{\min}(\mathbf{X}^\top \mathbf{X}) > 0$. Quindi $\nabla^2 g = \mathbf{X}^\top \mathbf{X} \succeq \mu I$, cioè g è μ -strongly convex. Aggiungendo h convessa preserva la proprietà: $f = g + h$ è μ -strongly convex.

Attenzione

Perché ci importa la strong convexity? In linea di principio, problemi μ -strongly convex ammettono algoritmi con rate migliorato: invece di $O(L^2/\varepsilon^2)$ per il caso convex puro, $O(L^2/(\mu\varepsilon))$ per il caso strongly convex (un fattore $1/\varepsilon$ in meno). *Ma:* SGPTL non sfrutta questa struttura. È un algoritmo per il caso convex puro; il rate che otterremo è $O(1/\varepsilon^2)$ anche se f è strongly convex. Per sfruttare μ servirebbero metodi specializzati (prossimali, accelerati). Lo notiamo per onestà ma non ne facciamo uso.

2.3 Sublivelli, coercività e compattezza

Cos'è un sublivello. Fissiamo un livello $c \in \mathbb{R}$. Il *sublivello* di f al livello c è l'insieme dei punti $\mathbf{w}$ in cui f vale $\leq c$:

$$S_c := \{\mathbf{w} \in \mathbb{R}^H : f(\mathbf{w}) \leq c\}.$$

Geometricamente è la regione “sotto” la quota c del grafico di f . Se c è grande, S_c contiene molti punti (perché tante $\mathbf{w}$ soddisfano $f(\mathbf{w}) \leq c$); se c è piccolo (vicino a $f^* = \min f$), S_c si stringe attorno al minimizzatore $\mathbf{w}^*$. Se $c < f^*$, $S_c = \emptyset$.

Esempio

In 1D, immagina $f(w) = w^2$. Allora $S_c = \{w : w^2 \leq c\} = [-\sqrt{c}, \sqrt{c}]$ (un intervallo simmetrico attorno a 0). $S_0 = \{0\}$ (solo il minimo). $S_4 = [-2, 2]$ (regione più ampia). $S_{-1} = \emptyset$ (nessun w ha quadrato negativo).

In 2D, se $f(w_1, w_2) = w_1^2 + w_2^2$, $S_c = \{(w_1, w_2) : w_1^2 + w_2^2 \leq c\}$ è un disco di raggio $\sqrt{c}$ centrato nell'origine.

A cosa servono i sublivelli. A garantire *contenimento*: se sappiamo che un punto $\mathbf{w}$ soddisfa $f(\mathbf{w}) \leq c$, sappiamo automaticamente che $\mathbf{w} \in S_c$. Se S_c è “piccolo” (limitato, anzi compatto), sappiamo allora che $\mathbf{w}$ vive in un insieme controllato.

Proposizione 2.4 (Coercività di f e compattezza dei sublivelli). *La f in (1) è coerciva: $f(\mathbf{w}) \rightarrow +\infty$ quando $\|\mathbf{w}\| \rightarrow \infty$. Di conseguenza, ogni sublivello S_c è chiuso e limitato, cioè compatto.*

Dimostrazione

Coercività. $f(\mathbf{w}) \geq \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$ (lasciando cadere il termine ℓ_1 , che è ≥ 0). Se $\mathbf{X}$ ha rango pieno colonna, sia $\mu = \lambda_{\min}(\mathbf{X}^\top \mathbf{X}) > 0$ il minimo autovalore di $\mathbf{X}^\top \mathbf{X}$; allora $\|\mathbf{X}\mathbf{v}\|^2 = \mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} \geq \mu \|\mathbf{v}\|^2$ per ogni $\mathbf{v}$. Quindi

$$\|\mathbf{X}\mathbf{w} - \mathbf{y}\| \geq \|\mathbf{X}\mathbf{w}\| - \|\mathbf{y}\| \geq \sqrt{\mu} \|\mathbf{w}\| - \|\mathbf{y}\| \xrightarrow{\|\mathbf{w}\| \rightarrow \infty} +\infty,$$

e $f(\mathbf{w}) \geq \frac{1}{2}(\sqrt{\mu} \|\mathbf{w}\| - \|\mathbf{y}\|)^2 \rightarrow +\infty$.

Compattezza dei sublivelli. (a) *Chiusura*: f è continua, quindi la preimmagine dell'intervallo chiuso $(-\infty, c]$ è chiusa. Cioè S_c è chiuso. (b) *Limitatezza*: se S_c fosse illimitato, esisterebbe una successione $\mathbf{w}^{(k)} \in S_c$ con $\|\mathbf{w}^{(k)}\| \rightarrow \infty$; ma allora $f(\mathbf{w}^{(k)}) \rightarrow \infty$ per coercività, contraddicendo $f(\mathbf{w}^{(k)}) \leq c$. Chiuso+limitato in $\mathbb{R}^H =$ compatto (Heine-Borel).

2.4 Perché i sublivelli compatti ci servono per la teoria di convergenza

Cos'è un iterato. Quando esegui un algoritmo iterativo come SGPTL, parti da $\mathbf{w}_0$ e generi una sequenza $\mathbf{w}_0, \mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_i, \dots$: ogni $\mathbf{w}_i$ è il valore corrente del parametro alla i -esima iterazione del ciclo. La parola “iterato” è il termine tecnico per “il punto $\mathbf{w}_i$ all'iterazione i ”. Tutti i discorsi di convergenza riguardano questa sequenza di iterati.

Perché ci serve $\|\mathbf{g}_i\| \leq L$. I teoremi che dimostreremo (Teorema 5.1 e Teorema 9.1) hanno l'ipotesi “ $\|\mathbf{g}_i\| \leq L$ per ogni iterazione i ”, cioè “tutti i subgradienti che l'algoritmo incontra hanno norma uniformemente limitata da una costante L ”. Senza questa ipotesi, la dimostrazione non funziona: il rate $O(L/\sqrt{k})$ degenera se $L = \infty$.

Il problema. Sul nostro problema f , il subgradiente $\mathbf{g}(\mathbf{w}) = \mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{s}$ non è limitato globalmente su $\mathbb{R}^H$: la parte $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$ cresce linearmente con $\|\mathbf{w}\|$. Quindi se $\mathbf{w}_i$ vagasse molto lontano dall'origine, $\|\mathbf{g}_i\|$ esploderebbe. Non possiamo trovare un L valido su tutto $\mathbb{R}^H$.

La soluzione: restringerci a un compatto.

- (1) *Su un compatto $S \subset \mathbb{R}^H$, i subgradienti sono limitati.* Su S compatto, la funzione continua $\mathbf{w} \mapsto \|\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})\|$ ha massimo finito (Weierstrass: continua su compatto $\Rightarrow$ raggiunge max). Sul termine ℓ_1 : $\|\lambda \mathbf{s}\| \leq \lambda \sqrt{H}$ uniformemente (perché ogni $|s_i| \leq 1$). Sommando, $\|\mathbf{g}\| \leq L_S < \infty$ per ogni $\mathbf{g} \in \partial f(\mathbf{w})$, $\mathbf{w} \in S$.
- (2) *Mostriamo che gli iterati restano in qualche compatto.* Se troviamo un c_0 tale che $\mathbf{w}_i \in S_{c_0}$ per ogni i , allora il punto (1) dà $\|\mathbf{g}_i\| \leq L_{S_{c_0}} =: L$ per ogni i . Questo è il famoso L del teorema.

Perché gli iterati di SGPTL restano in un compatto. Tre meccanismi che cooperano:

- Il record $\bar{f}^i = \min_{h \leq i} f(\mathbf{w}_h)$ è monotono non-crescente per costruzione, quindi $\mathbf{w}_{\text{best}} \in S_{f(\mathbf{w}_0)}$ *sempre*.
- Il singolo iterato $\mathbf{w}_i$ può temporaneamente uscire dal sublivello $S_{f(\mathbf{w}_0)}$ (SGPTL è non-monotono, $f(\mathbf{w}_{i+1})$ può salire), ma il *safeguard di overshoot* (§12) lo riporta indietro a $\mathbf{w}_{\text{best}}$ se va troppo in alto.
- Il meccanismo del target level tiene α_i proporzionale al gap $f(\mathbf{w}_i) - (f_{\text{ref}} - \delta)$ che si mantiene su scala ragionevole.

Quindi esiste $c_0 \geq f(\mathbf{w}_0)$ tale che $\mathbf{w}_i \in S_{c_0}$ per *tutte* le iterazioni. Su questo compatto S_{c_0} , $\|\mathbf{g}_i\| \leq L$ uniformemente. L'ipotesi del teorema è verificata.

Attenzione

L dipende dal problema (da $\mathbf{X}, \mathbf{y}, \lambda$) e dalla scala iniziale (c_0). Non è una costante universale. Però è *finito*, ed è tutto ciò che il teorema richiede.

2.5 Gradiente, subgradiente, subdifferenziale

Quando f è differenziabile, il gradiente $\nabla f(\mathbf{w})$ è l'unico vettore tale che

$$f(\mathbf{w}') \geq f(\mathbf{w}) + \langle \nabla f(\mathbf{w}), \mathbf{w}' - \mathbf{w} \rangle \quad \forall \mathbf{w}'.$$

Questa è la proprietà “*la tangente giace sotto il grafico*”, conseguenza della convessità. Quando f non è differenziabile, di tangenti del genere possono essercene molte. Si chiamano *subgradienti*.

Definizione 2.5 (Subgradiente, subdifferenziale). Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convessa. Un vettore $\mathbf{g} \in \mathbb{R}^n$ è *subgradiente* di f in $\mathbf{w}$ se

$$f(\mathbf{w}') \geq f(\mathbf{w}) + \langle \mathbf{g}, \mathbf{w}' - \mathbf{w} \rangle \quad \forall \mathbf{w}' \in \mathbb{R}^n. \quad (2)$$

L'insieme dei subgradienti in $\mathbf{w}$ si chiama *subdifferenziale*, scritto $\partial f(\mathbf{w})$.

Intuizione

Nei punti dove f è differenziabile, $\partial f(\mathbf{w}) = \{\nabla f(\mathbf{w})\}$: c'è un solo subgradiente, ed è il gradiente. Nei punti dove f ha uno spigolo (es. $|w_i|$ in $w_i = 0$), il subdifferenziale è un insieme con più elementi: ogni elemento rappresenta una possibile “tangente sotto il grafico”. La condizione di ottimalità si generalizza naturalmente: $\mathbf{w}^*$ minimizza f se e solo se $\mathbf{0} \in \partial f(\mathbf{w}^*)$.

2.6 Regole di calcolo del subdifferenziale

(R1) **Differenziabile:** $\partial g(\mathbf{w}) = \{\nabla g(\mathbf{w})\}$.

(R2) **Modulo:** $\partial |\cdot|$ in w_i è $\{\text{sign}(w_i)\}$ se $w_i \neq 0$, $[-1, +1]$ se $w_i = 0$.

(R3) **Norma ℓ_1 :** $\partial \|\mathbf{w}\|_1 = \{\mathbf{s} : s_i \in \partial |w_i| \forall i\}$ (per separabilità componente-per-componente).

(R4) **Somma:** $\partial(g + h)(\mathbf{w}) = \partial g(\mathbf{w}) + \partial h(\mathbf{w})$ (somma di Minkowski). Vale sotto un'ipotesi di compatibilità tra i domini, che per noi è banalmente soddisfatta (g e h sono entrambe finite su tutto $\mathbb{R}^H$).

2.7 Subdifferenziale di f in ELM LASSO

Applicando le regole:

$$\partial f(\mathbf{w}) = \underbrace{\mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})}_{=: \mathbf{q}(\mathbf{w})} + \lambda \{ \mathbf{s} : s_i \in \partial |w_i| \forall i \}.$$

Chiamiamo $\mathbf{q}(\mathbf{w}) := \nabla g(\mathbf{w}) = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$ il *gradiente smooth* (è il gradiente di g , definito ovunque). Un generico subgradiente di f è quindi:

$$\mathbf{g} = \mathbf{q}(\mathbf{w}) + \lambda \mathbf{s}, \quad s_i = \begin{cases} \text{sign}(w_i) & w_i \neq 0 \\ \in [-1, +1] & w_i = 0 \end{cases} \quad (3)$$

Attenzione

Punto delicato: la scelta di s_i a $w_i = 0$. Tutti i valori in $[-1, +1]$ producono un subgradiente valido nel senso di (2), e tutti garantiscono il funzionamento della teoria di convergenza. Però scelte diverse producono $\mathbf{g}$ di norma diversa, e $\|\mathbf{g}\|$ entra al denominatore del passo di Polyak: la scelta ha effetto su *quanto in fretta* l'algoritmo converge, non sul fatto che converga.

Derivazione della scelta di norma minima. Sui componenti j con $w_j \neq 0$, s_j è già forzato a $\text{sign}(w_j)$ e non c'è scelta. Sui componenti i con $w_i = 0$, s_i è libero in $[-1, +1]$. Vogliamo minimizzare $\|\mathbf{g}\|^2 = \sum_j (q_j + \lambda s_j)^2$ rispetto a queste s_i libere; il problema è separabile (ogni s_i minimizza il suo termine indipendentemente), quindi basta studiare il problema univariato:

$$\min_{s_i \in [-1, +1]} \varphi(s_i), \quad \varphi(s_i) := (q_i + \lambda s_i)^2.$$

Passo 1: minimo non vincolato. Per vedere chiaramente cos'è φ come funzione di s_i , sviluppiamo il quadrato del binomio:

$$\varphi(s_i) = (q_i + \lambda s_i)^2 = q_i^2 + 2q_i\lambda s_i + \lambda^2 s_i^2.$$

È un polinomio di grado 2 in s_i della forma standard $a s_i^2 + b s_i + c$ con $a = \lambda^2$, $b = 2q_i\lambda$, $c = q_i^2$, cioè una **parabola** (curva quadratica). Il coefficiente del termine s_i^2 è $\lambda^2 > 0$ (perché $\lambda > 0$ per ipotesi), quindi la parabola è “rivolta verso l'alto” (concava in giù è quando $a < 0$, concava in su è $a > 0$): ha un *unico* minimo, e nessun massimo. Possiamo trovare quel minimo derivando.

Calcolo della derivata, in due modi che danno lo stesso risultato:

- **Metodo 1 — regola della catena.** Pongo $u := q_i + \lambda s_i$ (funzione interna), allora $\varphi = u^2$. La derivata di u^2 rispetto a u è $2u$, e la derivata di u rispetto a s_i è λ (perché q_i è costante e $\frac{d}{ds_i}(\lambda s_i) = \lambda$). Per la regola della catena:

$$\varphi'(s_i) = \frac{d\varphi}{du} \cdot \frac{du}{ds_i} = 2u \cdot \lambda = 2\lambda(q_i + \lambda s_i).$$

- **Metodo 2 — derivare termine per termine.** Sulla forma sviluppata sopra:

$$\varphi'(s_i) = \frac{d}{ds_i}(q_i^2) + \frac{d}{ds_i}(2q_i\lambda s_i) + \frac{d}{ds_i}(\lambda^2 s_i^2) = 0 + 2q_i\lambda + 2\lambda^2 s_i.$$

Raccogliendo 2λ : $\varphi'(s_i) = 2\lambda(q_i + \lambda s_i)$. Stessa cosa.

Ponendo $\varphi'(s_i) = 0$: $2\lambda(q_i + \lambda s_i) = 0$. Divido per 2λ ($\neq 0$) e risolvo: $s_i^{\text{nv}} = -q_i/\lambda$. In quel punto $\varphi(s_i^{\text{nv}}) = (q_i + \lambda(-q_i/\lambda))^2 = 0^2 = 0$, cioè il subgradiente in quella componente vale esattamente zero — la perdita $\|\mathbf{g}\|^2$ contribuisce zero da quella componente.

Passo 2: rispettare il vincolo $s_i \in [-1, +1]$.

- Se $|s_i^{\text{nv}}| = |q_i/\lambda| \leq 1$, cioè $|q_i| \leq \lambda$: il minimo non vincolato è ammissibile, quindi $\boxed{s_i^* = -q_i/\lambda, \quad g_i^* = 0}$. *Sotto-caso* $q_i = 0$: $|q_i| = 0 \leq \lambda$, quindi cade qui dentro; $s_i^* = -0/\lambda = 0$, $g_i^* = q_i + \lambda \cdot 0 = 0$. Notare che è l'unico caso in cui la scelta del codice ($s_i = 0$) coincide *anche* con la scelta di norma minima.
- Se $|q_i| > \lambda$: il minimo non vincolato cade fuori da $[-1, +1]$, e la parabola convessa ha minimo vincolato sull'estremo più vicino. Per $q_i > 0$: $s_i^{\text{nv}} < -1$, estremo più vicino -1 , da cui $s_i^* = -1$. Per $q_i < 0$: $s_i^{\text{nv}} > +1$, estremo $+1$, $s_i^* = +1$. (Il caso $q_i = 0$ non compare qui perché $|q_i| = 0$ non soddisfa la condizione $|q_i| > \lambda$ con $\lambda > 0$; va automaticamente nel ramo precedente.) In entrambi i sotto-casi $\boxed{s_i^* = -\text{sign}(q_i), \quad g_i^* = q_i - \lambda \text{sign}(q_i)}$, di modulo $|q_i| - \lambda > 0$.

I due rami coprono tutto $\mathbb{R}$. Il valore $|q_i|$ è un numero reale non negativo; o soddisfa $\leq \lambda$ (primo ramo, $q_i = 0$ incluso) o soddisfa $> \lambda$ (secondo ramo). Non c'è spazio per casi non considerati.

Cosa fa il codice (e perché non è il min-norma). Il codice prende $s_i = \text{sign}(w_i)$ con `numpy.sign(0)=0`, in una riga vettorizzata: `return grad_smooth + lam * np.sign(w)`. Senza alcun `if-branch` per $w_i = 0$, è semplice e veloce. Quando $w_i \neq 0$, $s_i = \text{sign}(w_i)$ è l'unica scelta possibile. Quando $w_i = 0$, $s_i = 0$ è una scelta *ammissibile* (sta in $[-1, +1]$, quindi $\mathbf{g}$ è un subgradiente valido), **ma non coincide con il min-norma**:

- Se $|q_i| \leq \lambda$, min-norma sarebbe $s_i^* = -q_i/\lambda$ con $g_i^* = 0$; il codice mette $s_i = 0$ con $g_i = q_i$. Differenza in $|g_i|$: $|q_i|$, fino a λ .
- Se $|q_i| > \lambda$, min-norma sarebbe $s_i^* = -\text{sign}(q_i)$ con $|g_i^*| = |q_i| - \lambda$; il codice mette $s_i = 0$ con $|g_i| = |q_i|$. Differenza: λ .

In sintesi: il codice perde fino a λ in $|g_i|$ per ogni componente con $w_i = 0$ rispetto alla scelta ottima. Questo gonfia $\|\mathbf{g}\|$ e quindi la costante L del rate, ma *non* cambia l'ordine $O(1/\sqrt{k})$.

Perché va bene comunque: la misura nulla. Sembrerebbe una scelta inefficiente. In pratica è quasi sempre irrilevante per un motivo geometrico: **l'evento “ $w_i = 0$ esatto” durante l'iterazione ha probabilità zero.** Più formalmente:

- L'insieme $\{\mathbf{w} \in \mathbb{R}^H : w_i = 0\}$ è un iperpiano coordinato, cioè un sottospazio di dimensione $H - 1$ in uno spazio di dimensione H . La sua misura di Lebesgue (“volume”) è 0, esattamente come una retta in un piano ha area zero.
- Lo step di Polyak $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i$ con α_i derivata da floating-point e $\mathbf{d}_i$ generato da prodotti matrice-vettore non ti porta “per caso” su un iperpiano: la probabilità che il nuovo iterato cada esattamente lì è zero.
- Quindi, partendo da $\mathbf{w}_0$ non patologico, durante l'iterazione $\mathbf{w}_i$ ha quasi sicuramente *tutte* le componenti non nulle. La branch “ $w_i = 0$ ” del subdifferenziale non si attiva mai per davvero — w_i può essere arbitrariamente piccolo (10^{-10} , 10^{-15}) ma non esattamente zero.

L'unica eccezione: *cold start* con $\mathbf{w}_0 = \mathbf{0}$. In quel caso il primo subgradiente $\mathbf{g}_0 = \mathbf{X}^\top(\mathbf{X}\mathbf{0} - \mathbf{y}) + \lambda \mathbf{s}_0$ con $\mathbf{s}_0 = \mathbf{0}$ è $-\mathbf{X}^\top \mathbf{y}$ (non in min-norma se qualche $|q_i| \leq \lambda$, ma siamo solo all'iterazione zero, il danno è limitato). Dopo il primo step $\mathbf{w}_1 \approx \alpha_0 \mathbf{X}^\top \mathbf{y}$, che ha quasi sicuramente tutte le componenti diverse da zero.

Conclusione onesta. La nostra scelta $s_i = 0$ a $w_i = 0$ è ammissibile ma non min-norma. Sceglierla min-norma migliorerebbe la costante del rate ma non l'ordine, e in pratica la differenza si manifesta solo in un evento di misura nulla, quindi il guadagno reale sarebbe trascurabile. Il codice resta deliberatamente semplice.

2.8 Condizioni di ottimalità (KKT) del LASSO

Proposizione 2.6 (KKT per LASSO). $\mathbf{w}^*$ è ottimale per (1) se e solo se esiste $\mathbf{s}^* \in \partial \|\mathbf{w}^*\|_1$ tale che

$$\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y}) + \lambda \mathbf{s}^* = \mathbf{0},$$

ossia componente per componente:

$$\begin{cases} [\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y})]_i = -\lambda \text{sign}(w_i^*) & \text{se } w_i^* \neq 0, \\ |[\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y})]_i| \leq \lambda & \text{se } w_i^* = 0. \end{cases}$$

Dimostrazione

Per ottimalità di una funzione convessa: $\mathbf{w}^*$ minimizza f se e solo se $\mathbf{0} \in \partial f(\mathbf{w}^*)$. Da (3), $\mathbf{0} \in \partial f(\mathbf{w}^*)$ equivale a $-\mathbf{q}(\mathbf{w}^*)/\lambda \in \partial \|\mathbf{w}^*\|_1$, cioè $[-\mathbf{q}(\mathbf{w}^*)/\lambda]_i \in \partial |w_i^*|$ per ogni i . Espandendo le due alternative di $\partial |w_i^*|$ si ottengono le condizioni dell'enunciato.

2.9 La disuguaglianza chiave

Useremo costantemente la seguente conseguenza di (2). Sia $\mathbf{w}^*$ un minimizzatore, $f^* := f(\mathbf{w}^*)$. Ponendo $\mathbf{w}' = \mathbf{w}^*$ in (2):

$$f^* \geq f(\mathbf{w}) + \langle \mathbf{g}, \mathbf{w}^* - \mathbf{w} \rangle,$$

ovvero (riarrangiando):

$$\langle \mathbf{g}, \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}) - f^* \quad (4)$$

Interpretazione. Il prodotto scalare tra il subgradiente $\mathbf{g}$ e la direzione $\mathbf{w} - \mathbf{w}^*$ ("da $\mathbf{w}^*$ verso $\mathbf{w}$ ") è almeno pari al divario di valore $f(\mathbf{w}) - f^*$. Equivalentemente: $-\mathbf{g}$ è una direzione che decresce la distanza da $\mathbf{w}^*$ in modo proporzionale al gap di valore.

2.10 Lipschitz continuity su compatti e bound L sui subgradienti

Per la teoria di convergenza ci serve $\|\mathbf{g}_i\| \leq L$ per qualche $L < \infty$ lungo tutta l'iterazione. Sul nostro problema questo non vale globalmente su $\mathbb{R}^H$ (perché $\mathbf{q}(\mathbf{w}) = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$ cresce come $\|\mathbf{w}\|$), ma vale su *compatti*.

Proposizione 2.7. Sia $S \subset \mathbb{R}^H$ compatto. Esiste $L_S < \infty$ tale che $\|\mathbf{g}\| \leq L_S$ per ogni $\mathbf{g} \in \partial f(\mathbf{w})$, $\mathbf{w} \in S$.

Dimostrazione

Su S compatto, $\mathbf{w} \mapsto \|\mathbf{q}(\mathbf{w})\| = \|\mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})\|$ è continua, quindi limitata da una costante C_S . Sul termine ℓ_1 : $\|\lambda \mathbf{s}\| \leq \lambda \sqrt{H}$ uniformemente, poiché ogni $|s_i| \leq 1$. Quindi $\|\mathbf{g}\| \leq C_S + \lambda \sqrt{H} =: L_S$.

Nel nostro caso, gli iterati di SGPTL non escono troppo dal sublivello S_{c_0} per qualche $c_0 \geq f(\mathbf{w}_0)$ (perché il meccanismo del target level tiene i passi limitati). Su questo compatto, L è ben definita.

Part II

Il metodo del subgradiente puro

3 L'algoritmo

3.1 Schema base

A ogni iterazione, scegli un subgradiente $\mathbf{g}_i \in \partial f(\mathbf{w}_i)$, fai un passo nella sua direzione opposta:

$$\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{g}_i, \quad \alpha_i > 0.$$

Sembra il gradient descent, ma con $\mathbf{g}_i$ al posto di ∇f . Tre conseguenze importanti, distinte da quelle del gradient descent classico:

1. **$-\mathbf{g}_i$ non è necessariamente una direzione di discesa.** Cioè non è garantito $f(\mathbf{w}_{i+1}) < f(\mathbf{w}_i)$, neanche con α_i piccolo. È una specificità del caso non differenziabile: il subgradiente “vede sotto il grafico”, non punta direzione di pendenza locale come fa ∇f nel caso smooth.
2. **Si tiene il record value** $\bar{f}_i := \min_{h \leq i} f(\mathbf{w}_h)$, il valore migliore visto finora. La convergenza si dimostra su $\bar{f}_i$, non su $f(\mathbf{w}_i)$.
3. **Si restituisce $\mathbf{w}_{\text{best}}$** , l'iterato che ha realizzato $\bar{f}_i$, non l'ultimo $\mathbf{w}_i$.

3.2 Quali stepsize si possono usare

Tre famiglie classiche:

- **Costante:** $\alpha_i = \alpha$. Converge solo a un *intorno* di $\mathbf{w}^*$, di dimensione $O(\alpha L)$. Per ottenere ε accuratezza serve $\alpha \sim \varepsilon$, e quindi rate $O(L^2/\varepsilon^2)$ iterazioni.
- **Diminishing:** $\alpha_i = c/\sqrt{i+1}$ o simile. Converge a $\mathbf{w}^*$ con rate $O(1/\sqrt{i})$, ma richiede di scegliere bene c .
- **Polyak:** $\alpha_i = (f(\mathbf{w}_i) - f^*) / \|\mathbf{g}_i\|^2$. Rate ottimale (matching dei lower bound), ma richiede f^* noto.

Noi useremo il Polyak step. Vediamo come si deriva e perché è “ottimale”.

4 Il passo di Polyak

4.1 Derivazione

L'idea base: scegliere α_i in modo da minimizzare la distanza al quadrato da $\mathbf{w}^*$ *dopo* il passo. Espandendo:

$$\begin{aligned} \|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 &= \|\mathbf{w}_i - \alpha_i \mathbf{g}_i - \mathbf{w}^*\|_2^2 \\ &= \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - 2\alpha_i \langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + \alpha_i^2 \|\mathbf{g}_i\|_2^2. \end{aligned}$$

Questa è una parabola in α_i con coefficiente $\|\mathbf{g}_i\|^2 > 0$. Il minimo (in α_i) si trova derivando e ponendo = 0:

$$\alpha_i^{\text{ideale}} = \frac{\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle}{\|\mathbf{g}_i\|_2^2}.$$

Sostituendo questo valore in $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2$:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 = \|\mathbf{w}_i - \mathbf{w}^*\|^2 - \frac{\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle^2}{\|\mathbf{g}_i\|^2}.$$

Il problema è che non conosciamo $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$ (servirebbe $\mathbf{w}^*$). Per (4) però sappiamo che $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$. Sostituiamo la minorante:

$$\alpha_i^{\text{Polyak}} = \frac{f(\mathbf{w}_i) - f^*}{\|\mathbf{g}_i\|_2^2} \quad (5)$$

Attenzione

α_i^{Polyak} dipende da f^* , che non conosciamo. È il prezzo da pagare per usare la regola di Polyak. Il *meccanismo del target level* (§11) sostituirà f^* con una stima adattiva.

4.2 Range ammissibile e perché è “ottimale”

Proposizione 4.1 (Polyak step range). *Con $\alpha_i \in (0, 2\alpha_i^{\text{Polyak}})$ vale $\|\mathbf{w}_{i+1} - \mathbf{w}^*\| < \|\mathbf{w}_i - \mathbf{w}^*\|$.*

Dimostrazione

Dall’espansione: $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 - \|\mathbf{w}_i - \mathbf{w}^*\|^2 = \alpha_i^2 \|\mathbf{g}_i\|^2 - 2\alpha_i \langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$. Usando $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$, basta che $\alpha_i^2 \|\mathbf{g}_i\|^2 < 2\alpha_i (f(\mathbf{w}_i) - f^*)$, cioè $\alpha_i < 2(f(\mathbf{w}_i) - f^*) / \|\mathbf{g}_i\|^2 = 2\alpha_i^{\text{Polyak}}$.

In altre parole: α_i^{Polyak} è il *punto medio* dell’intervallo dei passi che producono contrazione monotona della distanza da $\mathbf{w}^*$. Il termine “ottimale” va inteso in questo senso preciso: massimizza la contrazione attesa di $\|\mathbf{w}_i - \mathbf{w}^*\|^2$ usando le sole informazioni disponibili.

5 Convergenza del subgradiente con passo di Polyak

Teorema 5.1 (Convergenza, subgradiente puro con Polyak). *Sia f convessa, $\mathbf{w}^*$ minimizzatore, $f^* = f(\mathbf{w}^*)$. Supponiamo $\|\mathbf{g}_i\|_2 \leq L$ per ogni i . Allora il record value $\bar{f}_k = \min_{i \leq k} f(\mathbf{w}_i)$ del subgradiente con Polyak step soddisfa*

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\sqrt{k}}. \quad (6)$$

In particolare $\bar{f}_k \rightarrow f^*$, e per gap $\leq \varepsilon$ servono $O(L^2/\varepsilon^2)$ iterazioni.

Dimostrazione

Passo 1 — Disuguaglianza per-step. Dall’espansione di $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2$ e usando (4):

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - 2\alpha_i (f(\mathbf{w}_i) - f^*) + \alpha_i^2 \|\mathbf{g}_i\|_2^2. \quad (7)$$

Passo 2 — Sostituiamo il passo di Polyak. Vogliamo sostituire $\alpha_i = (f(\mathbf{w}_i) - f^*) / \|\mathbf{g}_i\|^2$ nei due termini in α_i che compaiono in (7). Lo facciamo *uno alla volta*, mostrando ogni passaggio, perché qui c’è un punto che spesso confonde: **il quadrato $(f(\mathbf{w}_i) - f^*)^2$ che apparirà alla fine non viene da un quadrato di α_i nell’espansione originale, ma dal fatto che α_i contiene già un fattore $(f(\mathbf{w}_i) - f^*)$, e moltiplicandolo per il $(f(\mathbf{w}_i) - f^*)$ che è già presente fuori, otteniamo $(f(\mathbf{w}_i) - f^*)^2$.**

Termine 1: il pezzo $-2\alpha_i(f(\mathbf{w}_i) - f^)$.*

$$-2\alpha_i(f(\mathbf{w}_i) - f^*) = -2 \cdot \underbrace{\frac{f(\mathbf{w}_i) - f^*}{\|\mathbf{g}_i\|^2}}_{=\alpha_i} \cdot (f(\mathbf{w}_i) - f^*) = -\frac{2(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}.$$

Il quadrato a numeratore nasce dal prodotto $\alpha_i \cdot (f(\mathbf{w}_i) - f^*)$: il primo fattore contribuisce un $(f(\mathbf{w}_i) - f^*)$ (nascosto dentro α_i), il secondo fattore ne contribuisce un altro (esplicito), e $(f - f^*) \cdot (f - f^*) = (f - f^*)^2$.

Termine 2: il pezzo $+\alpha_i^2 \|\mathbf{g}_i\|^2$.

$$\alpha_i^2 \|\mathbf{g}_i\|^2 = \left(\frac{f(\mathbf{w}_i) - f^*}{\|\mathbf{g}_i\|^2} \right)^2 \cdot \|\mathbf{g}_i\|^2 = \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^4} \cdot \|\mathbf{g}_i\|^2 = \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}.$$

Qui invece il quadrato nasce dall'elevare α_i a sua volta al quadrato: $(\alpha_i)^2 = (f - f^*)^2 / \|\mathbf{g}_i\|^4$, e il $\|\mathbf{g}_i\|^2$ esterno semplifica con due dei quattro $\|\mathbf{g}_i\|$ a denominatore, lasciandone due.

Somma dei due termini.

$$\underbrace{-\frac{2(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}}_{\text{Termine 1}} + \underbrace{\frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}}_{\text{Termine 2}} = -\frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}.$$

Cioè: il coefficiente combinato è $-2 + 1 = -1$ davanti a $(f - f^*)^2 / \|\mathbf{g}_i\|^2$. Il termine “Polyak” (Termine 1, negativo) prevale sul termine “quadratico” del passo (Termine 2, positivo), ed esattamente di metà. Questa esatta cancellazione $-2 + 1 = -1$ è il motivo per cui il passo di Polyak è “ottimale”: è il valore di α_i che massimizza il pezzo negativo che resta in $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2$.

Mettendo tutto insieme:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{g}_i\|^2}.$$

Per finire il passo, usiamo $\|\mathbf{g}_i\| \leq L$ (ipotesi del teorema), che dà $1/\|\mathbf{g}_i\|^2 \geq 1/L^2$, quindi $-(f - f^*)^2 / \|\mathbf{g}_i\|^2 \leq -(f - f^*)^2 / L^2$ (il segno si conserva perché il numeratore $(f - f^*)^2 \geq 0$):

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - \frac{(f(\mathbf{w}_i) - f^*)^2}{L^2}. \quad (8)$$

Passo 3 — Telescoping. Sommando per $i = 0, \dots, k-1$ (i termini di distanza si elidono a cascata):

$$\sum_{i=0}^{k-1} \frac{(f(\mathbf{w}_i) - f^*)^2}{L^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2.$$

Per ogni $i \leq k$, $f(\mathbf{w}_i) \geq \bar{f}_k$, da cui $(f(\mathbf{w}_i) - f^*)^2 \geq (\bar{f}_k - f^*)^2$:

$$\frac{k(\bar{f}_k - f^*)^2}{L^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2,$$

e estraendo la radice si ottiene (6).

5.1 Cosa dice il rate in pratica

$O(1/\sqrt{k})$ è *sublineare*. Cosa significa numericamente:

- Dimezzare l'errore: $4 \times$ iterazioni.
- Ridurre di un fattore 10: $100 \times$ iterazioni.
- Ridurre di un fattore 100: $10\,000 \times$ iterazioni.
- Ridurre di un fattore 10^6 : 10^{12} iterazioni $\rightarrow$ impraticabile.

Per gap $\leq 10^{-6}$ servono già $\sim 10^{12} \|\mathbf{w}_0 - \mathbf{w}^*\|^2 L^2$ iterazioni: spesso fuori budget. È intrinsecamente difficile.

5.2 Il lower bound di Nemirovski-Yudin

Teorema 5.2 (Lower bound, qui senza dim.). *Per qualunque metodo del primo ordine (cioè che usa solo valori di f e subgradienti) applicato a una funzione convessa generica con $\|\mathbf{g}\| \leq L$, esiste un'istanza per cui dopo k iterazioni $f(\mathbf{w}_k) - f^* \geq c L \|\mathbf{w}_0 - \mathbf{w}^*\| / \sqrt{k}$ per qualche costante $c > 0$.*

Significa: *nessun algoritmo* può fare asintoticamente meglio di $O(L^2/\varepsilon^2)$ sul caso convex non-smooth generico. Il subgradiente con Polyak step *raggiunge* questo lower bound, ed è in questo senso “ottimale”. Non c'è speranza di un metodo “smart” che migliori il rate senza ipotesi aggiuntive sulla struttura del problema (es. smoothness, strong convexity sfruttata).

Part III

Il metodo del subgradiente deflesso

6 Perché il subgradiente puro non basta

6.1 Il problema delle oscillazioni

In pratica il subgradiente puro *oscilla* molto. Su problemi LASSO, quando l'iterato è vicino al minimo, $\mathbf{g}_i$ continua ad avere norma significativa: in $\mathbf{w}^*$ il subdifferenziale $\partial f(\mathbf{w}^*)$ contiene $\mathbf{0}$, ma anche altri vettori non nulli. Quando $\mathbf{w}_i$ è in un piccolo intorno di $\mathbf{w}^*$, $\mathbf{g}_i$ può non essere piccolo, e il passo $\alpha_i \mathbf{g}_i$ rimane “lungo”. Risultato: l'iterato salta avanti-indietro attorno a $\mathbf{w}^*$.

6.2 L'idea: combinare con la direzione precedente

Una cura, ispirata al *conjugate gradient method* (per problemi smooth quadratici): invece di usare $\mathbf{g}_i$ come direzione, usare una combinazione di $\mathbf{g}_i$ e della direzione precedente $\mathbf{d}_{i-1}$. Se le due sono allineate (consecutive iterations going the same way), la combinazione le rinforza; se sono opposte (oscillazione), la combinazione le smorza.

7 La direzione deflessa

Definizione 7.1 (Direzione deflessa). Data una sequenza di subgradienti $\mathbf{g}_0, \mathbf{g}_1, \dots$, la *direzione deflessa* è definita ricorsivamente:

$$\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}, \quad \gamma_i \in [0, 1],$$

con convenzione $\mathbf{d}_{-1} := \mathbf{0}$, da cui $\gamma_0 = 1$ e $\mathbf{d}_0 = \mathbf{g}_0$.

- $\gamma_i = 1$: ignora il passato, usa il subgradiente puro.
- $\gamma_i = 0$: ignora il subgradiente attuale, prosegui sulla vecchia direzione.
- Valori intermedi: mediano.

Attenzione

Punto teorico fondamentale. $\mathbf{d}_i$ **non** è un subgradiente di f in $\mathbf{w}_i$. È una combinazione convessa di $\mathbf{g}_i$ (subgradiente in $\mathbf{w}_i$) e $\mathbf{d}_{i-1}$ (storia delle iterazioni precedenti). La disuguaglianza chiave (4) **non vale** direttamente per $\mathbf{d}_i$. Questa è la complicazione che richiede una dimostrazione di convergenza nuova (§9).

7.1 Scelta ottimale di γ_i : forma chiusa

Vogliamo γ_i che renda $\mathbf{d}_i$ “il più informativo possibile”. Il criterio proposto dalla slide del corso è minimizzare $\|\mathbf{d}_i\|^2$: una norma più piccola dà un passo più lungo (perché $\|\mathbf{d}_i\|$ va al denominatore di α_i).

Proposizione 7.2 (Forma chiusa di γ_i). $\gamma_i^* = \arg \min_{\gamma \in [0,1]} \|\gamma \mathbf{g}_i + (1 - \gamma) \mathbf{d}_{i-1}\|_2^2$ *vale*

$$\gamma_i^* = \text{clip}_{[0,1]} \left(\frac{\|\mathbf{d}_{i-1}\|^2 - \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle}{\|\mathbf{g}_i - \mathbf{d}_{i-1}\|^2} \right). \quad (9)$$

Dimostrazione

Sia $\varphi(\gamma) := \|\gamma \mathbf{g}_i + (1 - \gamma) \mathbf{d}_{i-1}\|^2$. Espandendo:

$$\varphi(\gamma) = \gamma^2 \|\mathbf{g}_i\|^2 + 2\gamma(1 - \gamma) \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle + (1 - \gamma)^2 \|\mathbf{d}_{i-1}\|^2.$$

Derivando rispetto a γ e ponendo $= 0$:

$$\gamma \left(\|\mathbf{g}_i\|^2 - 2 \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle + \|\mathbf{d}_{i-1}\|^2 \right) = \|\mathbf{d}_{i-1}\|^2 - \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle.$$

Il coefficiente di γ è $\|\mathbf{g}_i - \mathbf{d}_{i-1}\|^2$, da cui il quoziente nell’enunciato. Il *clip* su $[0, 1]$ segue dalla minimizzazione vincolata.

7.2 Il floor $\gamma_{\min} > 0$

Intuizione

Senza floor, γ_i^* può proiettarsi su 0 quando $\|\mathbf{d}_{i-1}\|^2 \leq \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle$ (cioè $\mathbf{g}_i$ è “più lungo nella direzione di $\mathbf{d}_{i-1}$ ”). Con $\gamma_i = 0$, $\mathbf{d}_i = \mathbf{d}_{i-1}$: la direzione si congela. Combinato con $\beta_i = \min(\beta, \gamma_i) = 0$, anche il passo si annulla. L’iterato si ferma.

Su ELM LASSO questo accade entro poche decine di iterazioni qualunque sia il warm start. La cura: clippare γ_i su $[\gamma_{\min}, 1]$ con $\gamma_{\min} > 0$. Noi usiamo $\gamma_{\min} = 0.05$.

Vedremo in §9 dove il floor entra nella teoria.

8 Passo deflesso e regola stepsize-restricted

Adesso facciamo il passo:

$$\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i.$$

La slide del corso (Set 5, p. 15) propone la regola *stepsize-restricted*:

$$\alpha_i = \beta_i \frac{f(\mathbf{w}_i) - f^*}{\|\mathbf{d}_i\|_2^2}, \quad \beta_i \leq \gamma_i. \quad (10)$$

Passo di Polyak applicato a $\mathbf{d}_i$, modulato dal coefficiente β_i . La condizione $\beta_i \leq \gamma_i$ significa: “tanto più deflessione (e quindi tanto meno il subgradiente fresco $\mathbf{g}_i$ informa $\mathbf{d}_i$), tanto più corto il passo”.

Nel nostro algoritmo: $\beta_i = \min(\beta, \gamma_i)$ con $\beta = 1$, così la condizione $\beta_i \leq \gamma_i$ è automatica.

Intuizione

Perché la regola $\beta_i \leq \gamma_i$ funziona? La capiremo formalmente in §9: è la condizione che fa chiudere un’induzione su una certa quantità ν_i . Intuitivamente: $\mathbf{d}_i$ con γ_i piccolo è “contaminato” da $\mathbf{d}_{i-1}$, una direzione che non sappiamo se punti ancora verso $\mathbf{w}^*$. Per sicurezza accorciamo il passo proporzionalmente: tanto più $\mathbf{d}_i$ è informazione fresca (γ_i alto), tanto più ci permettiamo passo lungo.

9 Convergenza del subgradiente deflesso

Attenzione

Domanda naturale di chi legge: nel Teorema 5.1 (caso plain) ho applicato la disuguaglianza del subgradiente a $\mathbf{g}_i$ direttamente. Adesso, sullo stesso algoritmo SGPTL, dici che non posso. Cos’è cambiato?

Risposta. L’algoritmo è lo stesso, ma il *regime di parametri* è diverso. Più precisamente:

- Il Teorema 5.1 dimostra la convergenza nel *caso speciale* $\gamma_i \equiv 1$ per ogni i . In quel caso, sostituendo $\gamma_i = 1$ nella formula $\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$ si ottiene $\mathbf{d}_i = \mathbf{g}_i$ *letteralmente*: la direzione di iterazione è sempre un subgradiente. La dis. del subgradiente vale ed è applicata.
- Il Teorema 9.1 (questo, qua sotto) dimostra la convergenza nel *caso generale* $\gamma_i \in [\gamma_{\min}, 1]$, dove γ_i può essere < 1 . In questo regime $\mathbf{d}_i$ è una combinazione convessa di $\mathbf{g}_i$ (subgradiente in $\mathbf{w}_i$) e $\mathbf{d}_{i-1}$ (direzione storica, *non* un subgradiente in $\mathbf{w}_i$). La dis. del subgradiente non si applica a $\mathbf{d}_i$ direttamente.

SGPTL nel codice esegue il caso generale con default $\gamma_{\min} = 0.05$, quindi è il Teorema 9.1 che ci interessa davvero per il progetto. Il Teorema 5.1 è un *warm-up*: spiega lo scaffolding (espansione del quadrato, sostituzione Polyak, telescoping) per il sotto-caso $\gamma_i \equiv 1$ che, in più, è esattamente il subgradient method classico di Polyak. Il Teorema 9.1 riutilizza lo stesso scaffolding ma rimpiazza la dis. del subgradiente con un’induzione su ν_i .

Teorema 9.1 (Convergenza, deflesso). *Sia f convessa, $\|\mathbf{g}_i\| \leq L$. Supponiamo $\beta_i \leq \gamma_i$ e $\beta_i \geq \beta_{\min} > 0$. Allora*

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\beta_{\min} \sqrt{k}}. \quad (11)$$

Stesso rate $O(1/\sqrt{k})$ del Teorema 5.1, con costante peggiore di $1/\beta_{\min}$.

9.1 La quantità chiave: ν_i

Per il subgradiente puro la disuguaglianza che ci salva è $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$. Per il deflesso ci serve un controllo su $\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$, che chiamiamo ν_i .

Lemma 9.2 (Bound induttivo su ν_i). *Sotto le ipotesi del Teorema 9.1, $\nu_i := \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$ soddisfa*

$$\nu_i \geq \beta_i (f(\mathbf{w}_i) - f^*) \quad \forall i \geq 0. \quad (12)$$

Dimostrazione

Per induzione su i .

Base $i = 0$. Convenzione $\mathbf{d}_{-1} = \mathbf{0} \Rightarrow \gamma_0 = 1, \mathbf{d}_0 = \mathbf{g}_0$. Allora $\nu_0 = \langle \mathbf{g}_0, \mathbf{w}_0 - \mathbf{w}^* \rangle \stackrel{(4)}{\geq} f(\mathbf{w}_0) - f^*$. Poiché $\beta_0 \leq \gamma_0 = 1$: $\beta_0(f(\mathbf{w}_0) - f^*) \leq f(\mathbf{w}_0) - f^* \leq \nu_0$. OK.

Passo induttivo. Assumiamo $\nu_{i-1} \geq \beta_{i-1}(f(\mathbf{w}_{i-1}) - f^*)$. Dimostriamo $\nu_i \geq \beta_i(f(\mathbf{w}_i) - f^*)$. Spezziamo ν_i via $\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$:

$$\nu_i = \gamma_i \langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + (1 - \gamma_i) \langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle.$$

Primo pezzo: $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$ per (4).

Secondo pezzo: usiamo $\mathbf{w}_i = \mathbf{w}_{i-1} - \alpha_{i-1} \mathbf{d}_{i-1}$:

$$\begin{aligned} \langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle &= \langle \mathbf{d}_{i-1}, \mathbf{w}_{i-1} - \mathbf{w}^* \rangle - \alpha_{i-1} \|\mathbf{d}_{i-1}\|^2 \\ &= \nu_{i-1} - \alpha_{i-1} \|\mathbf{d}_{i-1}\|^2. \end{aligned}$$

Ma per definizione di α_{i-1} (Polyak deflesso):

$$\alpha_{i-1} \|\mathbf{d}_{i-1}\|^2 = \beta_{i-1}(f(\mathbf{w}_{i-1}) - f^*).$$

Quindi:

$$\langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle = \nu_{i-1} - \beta_{i-1}(f(\mathbf{w}_{i-1}) - f^*),$$

che per *ipotesi induttiva* è ≥ 0 .

Combinando:

$$\nu_i \geq \gamma_i(f(\mathbf{w}_i) - f^*) + (1 - \gamma_i) \cdot 0 = \gamma_i(f(\mathbf{w}_i) - f^*).$$

Infine, $\beta_i \leq \gamma_i \Rightarrow \nu_i \geq \beta_i(f(\mathbf{w}_i) - f^*)$. □

Intuizione

Cosa stiamo davvero usando? Due cose, una per ogni pezzo di $\mathbf{d}_i$:

- Sul subgradiente fresco $\mathbf{g}_i$: disuguaglianza del subgradiente standard. Funziona perché $\mathbf{g}_i$ è un subgradiente di f in $\mathbf{w}_i$.
- Sulla direzione vecchia $\mathbf{d}_{i-1}$: usiamo l'aggiornamento $\mathbf{w}_i = \mathbf{w}_{i-1} - \alpha_{i-1} \mathbf{d}_{i-1}$ per “trasportare” l'informazione che avevamo al passo precedente, espressa dall'ipotesi induttiva.

La condizione $\beta_i \leq \gamma_i$ è ciò che permette di passare da $\gamma_i(f(\mathbf{w}_i) - f^*)$ a $\beta_i(f(\mathbf{w}_i) - f^*)$ alla fine, chiudendo la catena.

9.2 Dal Lemma 9.2 al rate

Passo 1 — Per-step. $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 = \|\mathbf{w}_i - \mathbf{w}^*\|^2 - 2\alpha_i \nu_i + \alpha_i^2 \|\mathbf{d}_i\|^2$.

Usando il Lemma 9.2 e sostituendo $\alpha_i = \beta_i(f(\mathbf{w}_i) - f^*) / \|\mathbf{d}_i\|^2$:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - \frac{\beta_i^2 (f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2}. \quad (13)$$

Passo 2 — Bound su $\|\mathbf{d}_i\|$. Per induzione: $\mathbf{d}_0 = \mathbf{g}_0$ con $\|\mathbf{d}_0\| \leq L$. Assumendo $\|\mathbf{d}_{i-1}\| \leq L$, per disuguaglianza triangolare e $\gamma_i \in [0, 1]$:

$$\|\mathbf{d}_i\| \leq \gamma_i \|\mathbf{g}_i\| + (1 - \gamma_i) \|\mathbf{d}_{i-1}\| \leq \gamma_i L + (1 - \gamma_i) L = L.$$

Passo 3 — Telescoping. Da (13) con $\|\mathbf{d}_i\| \leq L$ e $\beta_i \geq \beta_{\min}$:

$$\sum_{i=0}^{k-1} \frac{\beta_{\min}^2 (f(\mathbf{w}_i) - f^*)^2}{L^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2.$$

Usando $(f(\mathbf{w}_i) - f^*)^2 \geq (\bar{f}_k - f^*)^2$:

$$\frac{k \beta_{\min}^2 (\bar{f}_k - f^*)^2}{L^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2 \implies \bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\beta_{\min} \sqrt{k}}. \quad \square$$

Intuizione

Riassunto.

- **La regola** $\beta_i \leq \gamma_i$ è il prerequisito per chiudere l'induzione del Lemma 9.2: senza, l'induzione si rompe.
- **Il floor** $\gamma_{\min} > 0$ dà $\beta_i \geq \gamma_{\min} =: \beta_{\min}$. Senza, β_i può tendere a 0 e la costante $1/\beta_{\min}$ in (11) esplode, rendendo il bound inutile.
- **Il rate** è $O(1/\sqrt{k})$ identico al caso plain, ma con costante peggiorata di $1/\beta_{\min}$. Con $\beta_{\min} = 0.05$ (il nostro default), un fattore 20 in $\sqrt{k}$, 400 in k .

10 Errata: cosa era sbagliato nel vecchio Teorema 3.1 del report

Questa sezione spiega cosa il prof contestava nella vecchia versione di Theorem 3.1 del report (versione [project_review/main_CM_consegna1.pdf](#)) e perché la versione corrente (la dimostrazione del Lemma 9.2 + i tre passi di rate appena visti) risolve il problema. È un'errata-corrigere dettagliata, utile per capire perché ho riscritto la dim e cosa è cambiato.

10.1 L'enunciato del Teorema 3.1 — non era quello il problema

L'enunciato del Teorema 3.1 (sia vecchia che nuova versione) dice:

Ipotesi: f convessa, subgradienti uniformemente limitati $\|\mathbf{g}_i\| \leq L$, condizioni di convergenza soddisfatte ($\beta_i \leq \gamma_i$).

Tesi: $\bar{f}^i = \min_{h \leq i} f(\mathbf{w}_h) \rightarrow f^*$ e complessità $O(L^2/\varepsilon^2)$ per arrivare a $\bar{f}^i - f^* \leq \varepsilon$.

L'enunciato è giusto e il prof non l'ha contestato. Quello che ha contestato è la **dimostrazione**.

10.2 Dove la vecchia dim si rompeva

La dim aveva due parti:

Parte A — caso subgradiente puro ($\gamma_i = 1$, $\mathbf{d}_i = \mathbf{g}_i$): tre passi standard. Espandere $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2$, sostituire il passo di Polyak, telescopare. Questa parte **era ed è corretta**: si appoggia direttamente alla disuguaglianza del subgradiente $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$, vera per ogni subgradiente.

Parte B — estensione al caso deflesso ($\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$): qui si rompeva.

10.3 Il cuore della difficoltà: la dis. del subgradiente non si applica a $\mathbf{d}_i$

Quando il passo è $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i$, l'espansione dà

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 = \|\mathbf{w}_i - \mathbf{w}^*\|^2 - 2\alpha_i \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + \alpha_i^2 \|\mathbf{d}_i\|^2.$$

Per estrarre un bound utile dobbiamo controllare $\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$ dal basso. Nel caso plain (passo lungo $\mathbf{g}_i$) questo è immediato per la dis. del subgradiente: $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$. Nel caso deflesso, abbiamo

$$\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle = \underbrace{\gamma_i \langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle}_{\geq f(\mathbf{w}_i) - f^* \checkmark} + (1 - \gamma_i) \underbrace{\langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle}_{??}.$$

Il primo pezzo va sotto controllo per dis. del subgradiente (perché $\mathbf{g}_i$ è un subgradiente di f in $\mathbf{w}_i$). **Il secondo pezzo no**, e qui sta il problema:

Attenzione

$\mathbf{d}_{i-1}$ **non è un subgradiente di f in $\mathbf{w}_i$** . È una combinazione convessa di subgradienti passati, valutati in punti passati ($\mathbf{w}_{i-1}, \mathbf{w}_{i-2}, \dots$). La disuguaglianza del subgradiente *non si applica* a $\mathbf{d}_{i-1}$ valutata in $\mathbf{w}_i$. In più, $\langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle$ non ha segno: può essere positivo, negativo o zero.

10.4 L'errore concreto del vecchio draft

Il vecchio draft scriveva, testualmente:

“The literal stepsize-restricted condition $\beta_i \leq \gamma_i$ from [5, Theorem 3.2] is precisely what recovers the bound: under this constraint the deflected step is shown to satisfy (3.14) for every iteration.”

dove (3.14) era il bound iterate-distance scritto nella forma plain:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|^2 - \frac{(f_i - f^*)^2}{\|\mathbf{d}_i\|^2}. \quad (\text{vecchio, sbagliato}) \quad (14)$$

Tre errori concreti in due frasi:

Errore A — fattore mancante. “(3.14) is shown to satisfy for every iteration” è falso così com'è scritto. Il bound corretto per il caso deflesso ha un fattore β_i^2 al numeratore di $(f_i - f^*)^2 / \|\mathbf{d}_i\|^2$, non 1. Quindi (14) non vale iter-by-iter nel caso deflesso. È strutturalmente diversa.

Errore B — citazione non verificata. “[Theorem 3.2] is precisely what recovers the bound”. La citazione [Thm 3.2] di d'Antonio-Frangioni 2009 era un placeholder mai verificato (il paper è dietro paywall, nessuno l'aveva aperto e cercato il Thm 3.2 reale). Il numero del teorema poteva essere sbagliato, e l'affermazione corrispondente è troppo specifica per non essere verificata. Il prof l'ha annusato subito: “mi pare allucinazione da LLM”.

Errore C — saltato il passaggio difficile. Tra “vale (14) iter-by-iter” e “telescopiamo, ottenuto il rate” non c'era niente. Era saltata la parte difficile, cioè proprio la dimostrazione del bound iter-by-iter. La frase “[...] is precisely what recovers the bound” suggeriva che la cosa fosse ovvia, e non lo è.

10.5 Cosa fa la nuova dim per risolverli

La nuova dim introduce *esplicitamente* una quantità ausiliaria $\nu_i := \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$ e dimostra per induzione un bound su ν_i . Poi la dim del rate viene di conseguenza. È esattamente quel che abbiamo visto in dettaglio in §9, ma ricapitolato qui per chiarezza:

- **Step A.** Per induzione, $\nu_i \geq \beta_i(f(\mathbf{w}_i) - f^*)$ (Lemma 9.2). Il passo induttivo usa due strumenti: dis. del subgradiente per il pezzo $\mathbf{g}_i$, e la sostituzione $\mathbf{w}_i = \mathbf{w}_{i-1} - \alpha_{i-1}\mathbf{d}_{i-1}$ per controllare il pezzo $\mathbf{d}_{i-1}$.
- **Step B.** Sostituendo nel quadrato della distanza:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|^2 - \frac{\beta_i^2(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|^2}. \quad (\text{nuovo, corretto}) \quad (15)$$

Confronto con (14): c'è il fattore β_i^2 in più al numeratore. Era proprio quello l'errore del vecchio: lo aveva scritto come 1.

- **Step C.** Telescopiamo con $\|\mathbf{d}_i\| \leq L$ (per induzione su combinazione convessa) e $\beta_i \geq \beta_{\min} = \gamma_{\min} > 0$ (per il floor). Risultato:

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\beta_{\min} \sqrt{k}}.$$

10.6 Confronto vecchio vs nuovo, in tabella

Aspetto	Vecchio draft	Nuovo
Bound per-step deflesso	$\ \Delta\ ^2 \leq \dots - \frac{(f_i - f^*)^2}{\ \mathbf{d}_i\ ^2}$	$\ \Delta\ ^2 \leq \dots - \frac{\beta_i^2(f_i - f^*)^2}{\ \mathbf{d}_i\ ^2}$
Costante del rate	1 (uguale al plain)	$1/\beta_{\min}$ (peggio di $20\times$ con $\gamma_{\min} = 0.05$)
Citazione di supporto	“[Thm 3.2] d’Antonio-Frangioni 2009 verbatim” (mai verificato)	Slide del corso (verificata) + [d’Antonio-Frangioni] come fonte originale
Trattamento del passo deflesso	dichiarato che (3.14) “vale iter-by-iter”, senza dimostrarlo	induzione esplicita su ν_i , 3 step numerati
Onestà sui costi del deflesso	rate dichiarato uguale al plain	rate peggio di $1/\beta_{\min}$, costo del floor reso esplicito

10.7 Perché la nuova è certamente corretta — tre check

Check 1 — caso limite. Se $\gamma_i = 1$ per ogni i (no deflessione), allora $\mathbf{d}_i = \mathbf{g}_i$ e $\beta_i = \min(1, 1) = 1$. Sostituendo nella (15): $\|\Delta\|^2 \leq \dots - 1 \cdot (f_i - f^*)^2 / \|\mathbf{g}_i\|^2$. Identico al bound del caso plain. La nuova dim si *specializza correttamente* al caso plain.

Check 2 — algebra dell’induzione. Ogni passaggio dello Step A è o un’identità o una disuguaglianza esplicita, motivata in chiaro:

- $\nu_i = \gamma_i \langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + (1 - \gamma_i) \langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle$: linearità del prodotto scalare. Identità.
- $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$: dis. del subgradiente. Vera per ogni $\mathbf{g}_i \in \partial f(\mathbf{w}_i)$.
- $\langle \mathbf{d}_{i-1}, \mathbf{w}_i - \mathbf{w}^* \rangle = \nu_{i-1} - \alpha_{i-1} \|\mathbf{d}_{i-1}\|^2$: sostituzione algebrica di $\mathbf{w}_i = \mathbf{w}_{i-1} - \alpha_{i-1}\mathbf{d}_{i-1}$ e linearità. Identità.
- $\alpha_{i-1} \|\mathbf{d}_{i-1}\|^2 = \beta_{i-1}(f_{i-1} - f^*)$: definizione di α_{i-1} . Identità.
- $\nu_{i-1} - \beta_{i-1}(f_{i-1} - f^*) \geq 0$: ipotesi induttiva. Disuguaglianza esplicita.
- $\gamma_i(f_i - f^*) \geq \beta_i(f_i - f^*)$: usa $\beta_i \leq \gamma_i$ e $f_i - f^* \geq 0$ (definizione di f^*). Disuguaglianza esplicita.

Niente nascosto, niente saltato.

Check 3 — la condizione $\beta_i \leq \gamma_i$ entra solo dove serve. Test diagnostico: se la condizione fosse decorativa, dovrebbe essere possibile ignorarla nella dim. Invece, nell’ultimo passaggio dello Step A, se $\beta_i > \gamma_i$, allora $\gamma_i(f_i - f^*) < \beta_i(f_i - f^*)$ e la catena di disuguaglianze si rompe. Quindi la condizione è strutturale, esattamente come ci si aspetta da una “regola di convergenza” come la chiama la slide del corso.

10.8 Riassunto onesto

Intuizione

Tre cose:

- Il **problema** del vecchio draft non era l'enunciato (giusto) né l'idea (citare un teorema standard di letteratura va bene). Era l'*esecuzione*: una frase di passaggio che diceva “il bound vale verbatim per ogni iterazione” come se fosse ovvio, quando invece nasconde un'induzione tecnica con un fattore β_i^2 in più che il vecchio testo aveva ommesso.
- Il **fix** consiste in due cose: (a) fare l'induzione per davvero, mostrando ogni passaggio; (b) essere onesti sul fatto che il rate del deflesso è peggio di un fattore $1/\beta_{\min}$ rispetto al plain.
- L'**onestà del fix** è un valore in sé: il prof preferisce una dim corretta con un rate peggiore a una dim sbagliata che dichiara un rate ottimo. “Comando.pdf §3” del corso è esplicito su questo punto.

Part IV

Il meccanismo del target level

11 Il problema: f^* è incognito

Tutto quanto sopra usa $\alpha_i = \beta_i(f(\mathbf{w}_i) - f^*)/\|\mathbf{d}_i\|^2$, che dipende da f^* . Idea: rimpiazzare f^* con una stima adattiva.

11.1 Definizioni

Manteniamo durante l'iterazione due quantità:

- f_{ref} = “valore di riferimento” (best stima upper-bound di f^*), inizialmente $f(\mathbf{w}_0)$;
- δ = “stima del gap rimanente $f_{\text{ref}} - f^*$ ”, inizialmente $\delta_0 > 0$.

Il *target level* è $f_{\text{ref}} - \delta$, e nel passo sostituiamo f^* con esso:

$$\alpha_i = \beta_i \frac{f(\mathbf{w}_i) - (f_{\text{ref}} - \delta)}{\|\mathbf{d}_i\|_2^2}. \quad (16)$$

11.2 Regole di aggiornamento

Tre branche, dalla slide:

1. “**Good improvement**”: se $f(\mathbf{w}_{i+1}) \leq f_{\text{ref}} - \delta/2$, $f_{\text{ref}} \leftarrow \bar{f}^{i+1}$ e $r \leftarrow 0$.
2. “**Too many steps without improvement**”: se $r > R$, $\delta \leftarrow \delta\rho$ ($\rho \in (0, 1)$), $r \leftarrow 0$.
3. **Altrimenti**: $r \leftarrow r + \alpha_i \|\mathbf{d}_i\|_2$.

Intuizione

Logica. Tre stati possibili:

- *Stiamo migliorando bene* (f è scesa di almeno mezzo δ): δ era una buona stima, teniamola; aggiorniamo f_{ref} al nuovo miglior valore.

- *Non miglioriamo da troppo tempo*: δ era ottimistico (target $f_{\text{ref}} - \delta$ sotto f^* , α_i troppo grande, oscillazioni); riduciamo δ di un fattore $\rho < 1$.
- *Stato intermedio*: stiamo procedendo, accumuliamo la distanza percorsa.

Asintoticamente, $\delta \rightarrow 0$ e $f_{\text{ref}} - \delta \rightarrow f_{\text{ref}} \geq f^*$, quindi il target converge a un upper bound di f^* . La convergenza del Teorema 9.1 si estende a questa versione con target level — la dim formale di questa estensione è nel paper d’Antonio-Frangioni 2009 e la dettagliamo subito dopo, §11.3.

11.3 Convergenza con target level: citazione + verifica delle ipotesi

Il Teorema 9.1 dimostra il rate $O(L^2/\varepsilon^2)$ sotto l’ipotesi che f^* sia noto. SGPTL nel codice usa il target $f_{\text{ref}} - \delta$ adattivo. La convergenza dell’algoritmo *come effettivamente eseguito* (con target level) è coperta da un risultato del paper d’Antonio-Frangioni 2009 — il paper che il prof Frangioni stesso cita nelle sue slide come riferimento principale per il deflesso.

Teorema 11.1 (Convergenza con target level, d’Antonio-Frangioni 2009, Theorem 3.7). *Sotto le condizioni (2.13), (3.5), e (3.26) del paper, l’algoritmo con target level (3.19) e update di δ come in Lemma 3.8 soddisfa $f_k \rightarrow f^* + \sigma^*$ quando f^* è finito, dove $\sigma^* = \limsup_k \sigma_k$ è l’errore asintotico dell’oracolo.*

Per applicare questo teorema al nostro SGPTL su ELM LASSO, dobbiamo (a) mappare la notazione del paper alla nostra, (b) verificare che le tre condizioni del paper valgano nel nostro caso.

(a) Mappa di notazione paper $\leftrightarrow$ nostra.

Simbolo paper	Significato	Nostro
σ_k	errore oracolo all’iter k	0 (oracolo esatto)
$\sigma^* = \limsup \sigma_k$	errore asintotico	0
α_k in (3.1)	parametro deflessione	γ_i
β_k in (3.1)	moltiplicatore stepsize	$\beta_i = \min(1, \gamma_i)$
ν_k	lunghezza passo (Polyak)	α_i
λ_k in (3.1)	gap rispetto al target	$f(\mathbf{w}_i) - (f_{\text{ref}} - \delta)$
μ in Lemma 3.8	contrazione target	ρ
X (insieme ammissibile)	dominio del problema	$\mathbb{R}^H$ (non vincolato)

(b) Verifica delle tre condizioni. *Condizione (2.13)* del paper. Lega la direzione d_k all’eventuale proiezione v_{k+1} sull’insieme ammissibile. Per noi $X = \mathbb{R}^H$ (problema senza vincoli), quindi nessuna proiezione è necessaria e la condizione è automaticamente soddisfatta.

Condizione (3.5) del paper:

- Se $\lambda_k \geq 0$ (target $f_{\text{ref}} - \delta$ sotto $f(\mathbf{w}_i)$), allora $\beta_k \geq \beta^* > 0$ per qualche costante uniforme β^* .
Nel nostro caso: quando $\lambda_k > 0$, $\beta_i = \min(1, \gamma_i)$ e per il floor $\gamma_i \geq \gamma_{\min}$, quindi $\beta_i \geq \gamma_{\min} =: \beta^*$.
- Se $\lambda_k < 0$ (target sopra $f(\mathbf{w}_i)$ — “infeasible”), allora $\alpha_k = 0$.
Nel nostro caso: quando $\lambda_k = f(\mathbf{w}_i) - (f_{\text{ref}} - \delta) \leq 0$, il safeguard di SGPTL (§12, item (ii) “Polyak numerator non-positive”) contrae δ e *salta* il passo, cioè $\alpha_i = 0$.

Condizione (3.26) del paper: $\liminf_k \delta_k = 0$ e $\sum_k \|\mathbf{w}_{k+1} - \mathbf{w}_k\| = \infty$.

Nel nostro caso: la regola di update di δ nel nostro Algoritmo 1 (vedi pseudocodice §12) è *letteralmente identica* alla regola di Lemma 3.8 del paper:

- Se “sufficient descent” ($f_{i+1} \leq f_{\text{ref}} - \delta/2$), reset $f_{\text{ref}} \leftarrow \bar{f}$ e $r \leftarrow 0$.
- Se “target infeasibility” ($r > R$), contrai $\delta \leftarrow \delta\rho$ e $r \leftarrow 0$.
- Altrimenti, accumula $r \leftarrow r + \alpha_i \|\mathbf{d}_i\|$.

Lemma 3.8 del paper dimostra che proprio questa regola, con $\mu = \rho \in (0, 1)$ ed $R > 0$ qualsiasi, produce $\delta_k \rightarrow 0$ e $\sum \|\mathbf{w}_{k+1} - \mathbf{w}_k\| = \infty$.

Conclusione: convergenza di SGPTL su ELM LASSO. Tutte le ipotesi del Teorema 11.1 sono verificate. Quindi

$$\bar{f}_k \rightarrow f^* + \sigma^* = f^* + 0 = f^*,$$

cioè il record value dei valori della funzione lungo SGPTL su ELM LASSO converge al minimo f^* del problema. La complessità $O(L^2/\varepsilon^2)$ è una conseguenza diretta del Teorema 3.5 dello stesso paper, la cui dimostrazione generalizza la stima di Bertsekas 1999, Theorem 7.17 al caso deflesso.

Intuizione

Onestamente. La dim formale che SGPTL converge a f^* con target level adattivo non l’abbiamo fatta noi: l’ha fatta d’Antonio-Frangioni nel paper SIOPT 2009, in ~10 pagine di analisi convessa avanzata. Quel che facciamo noi è:

1. dimostrare il rate del caso f^* noto, deflesso, sul nostro problema specifico (induzione su ν_i del Teorema 9.1);
2. verificare che il nostro Algoritmo 1 e il nostro problema soddisfano le ipotesi del paper (la triade (2.13), (3.5), (3.26) appena verificata);
3. applicare il loro Theorem 3.7 per concludere la convergenza con target level.

È quel che la teoria standard si aspetta: noi non re-dimostriamo risultati di letteratura (sarebbe ridondante e a rischio errore), ma ne verifichiamo le ipotesi sul nostro caso specifico e citiamo. Per il prof Frangioni leggere è facile: vede il suo paper citato, vede mapping di notazione e verifica delle ipotesi, e capisce immediatamente che il discorso fila.

11.4 Scelta di ρ

Il valore di ρ è critico:

- ρ vicino a 0 (*aggressive*): δ contrae rapidamente. Rischio: target undershoot sotto f^* frequente, oscillazioni continue.
- ρ vicino a 1 (*slow*): δ contrae lentamente. Rischio: δ resta troppo grande, target sotto f^* per molte iterazioni, α_i esagerato.
- Middle ground: $\rho \in [0.5, 0.7]$ è il consenso della letteratura (Brännlund 1993, Goffin-Kiwiel 1999, Bertsekas 1999).

La slide del corso lascia $\rho \in (0, 1)$ aperto con annotazione “(??)”. Noi adottiamo $\rho = 0.7$ come default, validato da uno smoke test su istanze sintetiche e reali.

Part V

SGPTL: algoritmo completo e sicurezze

12 Sicurezze pratiche aggiuntive

Nello pseudocodice della slide mancano quattro sicurezze che servono a evitare patologie numeriche su ELM LASSO:

1. $\|\mathbf{d}_i\|^2 < 10^{-30}$: direzione collassata. Usciamo dal loop.
2. **Polyak numerator** ≤ 0 : target sopra $f(\mathbf{w}_i)$, passo negativo. Contraiamo δ , saltiamo.
3. **Overshoot** $f(\mathbf{w}_{i+1}) > 1.2\bar{f}$ e $\bar{f} > \bar{f} + \delta$: patologia classica del Polyak step. Snap a $\mathbf{w}_{\text{best}}$, contraiamo δ , reset $\mathbf{d}_{i-1}$.
4. $\mathbf{w}_{i+1}$ **non finito**: α_i esplosivo. Stessa azione.

Inoltre il *fallback a contatore di iterazione* R_{iter} : su ELM LASSO il contatore r del meccanismo originale non scatta mai (gli step diventano piccolissimi con $\gamma_i \rightarrow 0$). Aggiungiamo: se $\bar{f}$ non migliora per R_{iter} iterazioni consecutive, contraiamo δ e resettiamo $\mathbf{d}_{i-1} \leftarrow \mathbf{0}$ (cosicché $\gamma_{i+1} = 1$ e $\mathbf{d}_{i+1} = \mathbf{g}_{i+1}$).

13 Pseudocodice completo

Algoritmo SGPTL

Input: $\mathbf{X}, \mathbf{y}, \lambda, i_{\max}, \beta = 1, \delta_0, R, \rho \in (0, 1), \gamma_{\min} > 0, R_{\text{iter}}$, warm start $\mathbf{w}_0$.
Init: $\mathbf{w} \leftarrow \mathbf{w}_0$; $f_{\text{curr}} \leftarrow f(\mathbf{w})$; $\delta \leftarrow \delta_0$; $f_{\text{ref}} \leftarrow f_{\text{curr}}$; $\bar{f} \leftarrow f_{\text{curr}}$; $\mathbf{w}_{\text{best}} \leftarrow \mathbf{w}$; $\mathbf{d}_{-1} \leftarrow \mathbf{0}$; $r \leftarrow 0$; *stalled* $\leftarrow 0$.
For $i = 0, \dots, i_{\max} - 1$:
 1. Fallback iter-count: **if** *stalled* $\geq R_{\text{iter}}$: $\delta \leftarrow \delta\rho$, $\mathbf{d}_{i-1} \leftarrow \mathbf{0}$, *stalled* $\leftarrow 0$.
 2. $\mathbf{g}_i \leftarrow \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \text{sign}(\mathbf{w})$.
 3. $\gamma_i \leftarrow \text{clip}_{[\gamma_{\min}, 1]} ((\|\mathbf{d}_{i-1}\|^2 - \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle) / \|\mathbf{g}_i - \mathbf{d}_{i-1}\|^2)$, oppure 1 al primo step.
 4. $\mathbf{d}_i \leftarrow \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$.
 5. $\beta_i \leftarrow \min(\beta, \gamma_i)$.
 6. $\text{num} \leftarrow \beta_i (f_{\text{curr}} - (f_{\text{ref}} - \delta))$. **If** $\text{num} \leq 0$: $\delta \leftarrow \delta\rho$, continua.
 7. $\alpha_i \leftarrow \text{num} / \|\mathbf{d}_i\|^2$; $\mathbf{w}_{\text{new}} \leftarrow \mathbf{w} - \alpha_i \mathbf{d}_i$; $f_{\text{new}} \leftarrow f(\mathbf{w}_{\text{new}})$.
 8. Overshoot check.
 9. Aggiorna record: **if** $f_{\text{new}} < \bar{f}$: $\bar{f} \leftarrow f_{\text{new}}$, $\mathbf{w}_{\text{best}} \leftarrow \mathbf{w}_{\text{new}}$.
 10. Target-level update:
 - **if** $f_{\text{new}} \leq f_{\text{ref}} - \delta/2$: $f_{\text{ref}} \leftarrow \bar{f}$, $r \leftarrow 0$.
 - **elif** $r > R$: $\delta \leftarrow \delta\rho$, $r \leftarrow 0$.
 - **else**: $r \leftarrow r + \alpha_i \|\mathbf{d}_i\|$.
 11. Aggiorna stato.
Return $\mathbf{w}_{\text{best}}$.

14 Scelta dei parametri

- $\beta = 1$ (slide: $\beta \in (0, 2]$, valore massimo che soddisfa la regola).
- $\delta_0 = 0.1 f(\mathbf{w}_0)$ (scala a-priori, non usa f^*).
- $\rho = 0.7$ (consenso letteratura $[0.5, 0.7]$; smoke test).
- $R = 10\sqrt{i_{\max}}$ (euristica slide).
- $R_{\text{iter}} = \max(i_{\max}/100, 50)$ (nostra augmentation).
- $\gamma_{\min} = 0.05$ (compromesso tra costante del rate e probabilità di collasso).

Part VI

Applicazione a ELM LASSO

15 Calcolo del subgradiente

Da (3):

$$\mathbf{g}(\mathbf{w}) = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \text{sign}(\mathbf{w}),$$

con convenzione $\text{sign}(0) = 0$. Costo: una moltiplicazione $\mathbf{X}\mathbf{w}$ ($O(MH)$), una sottrazione ($O(M)$), una moltiplicazione $\mathbf{X}^\top(\cdot)$ ($O(MH)$), una somma ($O(H)$). Totale $O(MH)$ per iterazione.

16 Verifica delle ipotesi del Teorema 9.1

1. **Convessità di f :** Proposizione 2.2.
2. $\|\mathbf{g}_i\| \leq L$: per coercività di f (Proposizione 2.3), gli iterati restano in S_{c_0} per qualche $c_0 \geq f(\mathbf{w}_0)$. Su questo compatto, $\|\mathbf{g}\| \leq L$ uniformemente (Proposizione 2.5). Il valore esatto di L dipende da $\mathbf{X}, \mathbf{y}, \lambda$ e dal sublivello, ma è finito.
3. $\beta_i \leq \gamma_i, \beta_i \geq \beta_{\min}$: $\beta_i = \min(\beta, \gamma_i)$ con $\beta = 1$ dà la prima. Il clip $\gamma_i \geq \gamma_{\min} = 0.05$ dà $\beta_i \geq \gamma_{\min}$, quindi $\beta_{\min} = \gamma_{\min}$.

Il Teorema 9.1 si applica con $\beta_{\min} = 0.05$, dando rate

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{0.05\sqrt{k}} = \frac{20 L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\sqrt{k}}.$$

17 Il warm-start OLS: costo, alternativa, perché conviene

I due algoritmi del progetto (IRLS e SGPTL) cominciano entrambi da $\mathbf{w}_0 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, l'OLS warm-start. È una scelta che va motivata: bisogna chiedersi *cosa costa calcolarlo*, e *cosa si guadagna* rispetto a una alternativa banale come $\mathbf{w}_0 = \mathbf{0}$ (cold start).

17.1 Costo: contiamo i FLOP

Calcolare $\mathbf{w}_0 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ in modo numericamente sensato significa risolvere il sistema lineare $\mathbf{X}^\top \mathbf{X} \mathbf{w}_0 = \mathbf{X}^\top \mathbf{y}$ via fattorizzazione di Cholesky (perché $\mathbf{X}^\top \mathbf{X}$ è simmetrica definita positiva sotto le nostre ipotesi). I passi e i loro costi:

Operazione	Costo dominante	Nei nostri regimi
formare $= \mathbf{X}^\top \mathbf{X}$	$O(MH^2)$ moltiplicazioni-addizioni	“meglio non fare se evitabile, ma servono”
formare $= \mathbf{X}^\top \mathbf{y}$	$O(MH)$	lineare in MH
Cholesky di $(=^\top)$	$O(H^3/3)$	cubico in H
forward solve $^\top =$	$O(H^2)$	trascurabile
back solve $\mathbf{w}_0 =$	$O(H^2)$	trascurabile
totale warm-start	$O(MH^2 + H^3)$	dominato da $\mathbf{X}^\top \mathbf{X}$ e Cholesky

Cifre concrete sui nostri test:

- Istanza di convergenza ($H = 100, M = 300$): $MH^2 + H^3 = 3 \cdot 10^6 + 10^6 = 4 \cdot 10^6$ FLOP. Sull'hardware moderno, ~ 1 ms.
- Scalability massima ($H = 2000, M = 10000$): $MH^2 + H^3 = 4 \cdot 10^{10} + 8 \cdot 10^9 \approx 5 \cdot 10^{10}$ FLOP. ~ 1 –2 secondi.

17.2 Costo in contesto: confronto con il costo totale degli algoritmi

IRLS: ogni iterazione risolve un sistema simile ($\mathbf{X}^\top \mathbf{X}$ più una correzione diagonale dipendente dall'iterato, ricalcolata ogni volta), con Cholesky a costo $O(H^3)$ per fattorizzazione + $O(MH^2)$ per formare se è cambiata. Su $k_{\max} = 100$ iterazioni:

$$\underbrace{O(MH^2 + H^3)}_{\text{warm-start}} + \underbrace{100 \cdot O(MH^2 + H^3)}_{\text{loop IRLS}} = 101 \cdot O(MH^2 + H^3).$$

Il warm-start vale *un'iterazione su 101*, cioè $\sim 1\%$ del costo totale. **Trascurabile.**

SGPTL: ogni iterazione costa $O(MH)$ (due prodotti matrice-vettore: $\mathbf{X}\mathbf{w}$ e poi $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$). Su $i_{\max} = 8000$:

$$\underbrace{O(MH^2 + H^3)}_{\text{warm-start}} + \underbrace{8000 \cdot O(MH)}_{\text{loop SGPTL}}.$$

Adesso il rapporto è meno favorevole. Esempio numerico sull'istanza di convergenza ($H = 100$, $M = 300$):

- warm-start: $\sim 4 \cdot 10^6$ FLOP.
- loop SGPTL: $8000 \cdot 2MH = 8000 \cdot 6 \cdot 10^4 = 4.8 \cdot 10^8$ FLOP.
- rapporto: warm-start $\approx 1\%$ del loop. Trascurabile anche qui.

Sull'istanza più grande della scalability ($H = 2000$, $M = 10000$, $i_{\max} = 3000$):

- warm-start: $\sim 5 \cdot 10^{10}$ FLOP.
- loop SGPTL: $3000 \cdot 2 \cdot 10000 \cdot 2000 = 1.2 \cdot 10^{11}$ FLOP.
- rapporto: warm-start $\approx 40\%$ del loop. **Significativo, ma non dominante.**

Il warm-start cresce come H^3 (cubico in H), il loop SGPTL come $i_{\max} MH$ (lineare in H a budget fisso). Quindi per H molto grande il warm-start *diventa* più costoso del loop. Sulle nostre dimensioni di test resta sempre minoritario, ma è una conseguenza che vale notare.

Attenzione

Punto importante. Il costo del warm-start è il *punto a iterazione zero* sui grafici tempo-vs-iterazione del report: chiama questo punto $t_0 > 0$. Sui plot log-log il piccolo offset iniziale t_0 è la testimonianza visiva del fatto che “il loop comincia con un po' di lavoro già fatto”. Se nei grafici quel punto è solo apparente perché coperto da overplotting o perché lo asse log lo schiaccia, conviene dirlo esplicitamente nella didascalia (cosa che facciamo nel report).

17.3 Cosa cambierebbe con il cold start $\mathbf{w}_0 = \mathbf{0}$

Alternativa banale: $\mathbf{w}_0 = \mathbf{0}$. Costo zero. *Conviene?* Vediamo qualitativamente e quantitativamente.

Qualitativamente. Da $\mathbf{0}$, $f(\mathbf{0}) = \frac{1}{2} \|\mathbf{y}\|^2$ (il termine $\lambda \|\mathbf{0}\|_1 = 0$). Cioè $f(\mathbf{0})$ = “SSR del predittore costante zero”. È un valore molto alto rispetto a f^* .

Da $\mathbf{w}_{\text{OLS}}$, $f(\mathbf{w}_{\text{OLS}}) = \frac{1}{2} \|\mathbf{X}\mathbf{w}_{\text{OLS}} - \mathbf{y}\|^2 + \lambda \|\mathbf{w}_{\text{OLS}}\|_1$. Il primo termine è il *residuo OLS*, il minimo del problema senza ℓ_1 . Sui nostri test:

- Istanza di convergenza: $f(\mathbf{0}) \approx 76$, $f(\mathbf{w}_{\text{OLS}}) \approx 1.56$, $f^* \approx 1.13$. Cioè $f(\mathbf{w}_{\text{OLS}}) - f^* \approx 0.42$, contro $f(\mathbf{0}) - f^* \approx 75$. Il warm-start parte $\sim 180\times$ più vicino al minimo (in scala f).
- Su diabetes: $f(\mathbf{0}) \approx 177$, $f(\mathbf{w}_{\text{OLS}}) \approx 60$, $f^* \approx 54$. Warm-start parte $\sim 20\times$ più vicino.

Cioè il warm-start salta in avanti un'enorme porzione del gap iniziale, gratis (gratis nel senso: costa il prezzo del Cholesky una volta sola).

Quantitativamente. Quante iterazioni di SGPTL servirebbero da $\mathbf{0}$ per recuperare il livello di $\mathbf{w}_{\text{OLS}}$? Usiamo il rate $\bar{f}^k - f^* \leq L \|\mathbf{w}_0 - \mathbf{w}^*\| / (\beta_{\min} \sqrt{k})$. Sull'istanza di convergenza:

- Per arrivare a gap 0.42 partendo da gap 75 servono $k \approx (L \|\mathbf{0} - \mathbf{w}^*\| / (\beta_{\min} \cdot 0.42))^2$ iterazioni. Anche con stime conservative su L e $\|\mathbf{w}^*\|$, si tratta di centinaia se non migliaia di iterazioni. Tutte “sprecate” a recuperare il livello che il warm-start ci dà gratis.

Empiricamente, con la regola theory-pure ($R = 1$, no iter-fallback) e $i_{\max} = 8000$, SGPTL warm-started e cold-started arrivano *essenzialmente allo stesso gap finale* ($\sim 4 \cdot 10^{-5}$ warm vs $\sim 2 \cdot 10^{-5}$ cold, vedi Figura 4). **Nota storica:** la versione precedente di questo tutorial citava qui un divario di $\sim 10^4$ tra warm e cold a vantaggio di warm. Era un artefatto della precedente combinazione R grande + iter-fallback, non una proprietà dell'algoritmo. Con $R = 1$ il warm-start dà comunque un vantaggio (si parte più vicino a f^* in scala f), ma il guadagno si esaurisce velocemente: la teoria $1/\sqrt{k}$ recupera in ~ 100 iterazioni il gap iniziale che il warm-start fornisce gratis.

17.4 Sintesi

Intuizione

- **Costo warm-start:** $O(MH^2 + H^3)$. Su istanze piccole/medie ($H \leq 1000$): $\leq 1\%$ del costo totale degli algoritmi. Su istanze grandi ($H \sim 2000$, SGPTL): fino al $\sim 40\%$ del loop, ma comunque sub-dominante.
- **Cosa si guadagna:** punto di partenza con f centinaia di volte più vicino a f^* rispetto a $\mathbf{0}$.
- **Conclusione:** il warm-start si paga da solo. Costa una manciata di iterazioni IRLS o una frazione del loop SGPTL; ne risparmia migliaia.
- **Confronto onesto:** dare lo stesso $\mathbf{w}_0$ a IRLS e SGPTL elimina una variabile (effetto warm vs cold) dal confronto tra i due algoritmi. Diversamente, l'uno avrebbe un vantaggio gratuito sull'altro.

18 Esempio numerico (un'iterazione)

Esempio

Prendiamo $\mathbf{X} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$, $\mathbf{y} = (1, 2, 4)^\top$, $\lambda = 0.5$, $\mathbf{w}_0 = (0, 0)^\top$. Allora:

$\mathbf{X}\mathbf{w}_0 - \mathbf{y} = -\mathbf{y} = (-1, -2, -4)^\top$, $\|\mathbf{X}\mathbf{w}_0 - \mathbf{y}\|^2 = 1 + 4 + 16 = 21$, $f(\mathbf{w}_0) = \frac{1}{2} \cdot 21 + 0 = 10.5$.

Gradiente smooth: $\mathbf{q}_0 = \mathbf{X}^\top(\mathbf{X}\mathbf{w}_0 - \mathbf{y}) = (-1 - 4, -2 - 4)^\top = (-5, -6)^\top$.

Sub-grad: $\mathbf{s}_0 = \text{sign}(\mathbf{w}_0) = (0, 0)^\top$. Subgradiente: $\mathbf{g}_0 = \mathbf{q}_0 + \lambda \mathbf{s}_0 = (-5, -6)^\top$, $\|\mathbf{g}_0\|^2 = 61$.

Direzione (primo step, $\gamma_0 = 1$): $\mathbf{d}_0 = \mathbf{g}_0 = (-5, -6)^\top$.

Default: $\delta_0 = 0.1 \cdot 10.5 = 1.05$, $f_{\text{ref}} = 10.5$, target = 9.45. Numerator: $\beta_0(f(\mathbf{w}_0) - \text{target}) = 1 \cdot (10.5 - 9.45) = 1.05$. $\alpha_0 = 1.05/61 \approx 0.0172$.

$\mathbf{w}_1 = \mathbf{w}_0 - \alpha_0 \mathbf{d}_0 = (0, 0) - 0.0172 \cdot (-5, -6) = (0.086, 0.103)$.

$f(\mathbf{w}_1) = \frac{1}{2} \|(0.086, 0.103, 0.189) - (1, 2, 4)\|^2 + 0.5 \cdot (0.086 + 0.103) = \frac{1}{2}(0.835 + 3.601 + 14.524) + 0.094 \approx 9.574$.

Notare: f scese da 10.5 a 9.574, e si è “avvicinata” al target 9.45 ma non l'ha raggiunto.

Buon segno: il passo è andato nella direzione giusta.

Part VII

Comportamento atteso e risultati

19 Convergenza

Cosa aspettarsi. $\bar{f}^i$ scende come $\sim 1/\sqrt{i}$. Su scala log-log, una linea con pendenza $-1/2$. $f(\mathbf{w}_i)$ corrente *non* è monotono: oscilla, sale e scende.




Figure 1: Convergenza di IRLS e SGPTL sull'istanza di convergenza ($H = 100$, $M = 300$, $\lambda = 0.1$). Pannello sinistro: IRLS, semilog. Linea retta = decrescita lineare per iterazione. Pannello destro: SGPTL, log-log. La traccia rossa scura è $\bar{f}^i - f^*$ (record, monotono), la traccia arancione chiara è $f(\mathbf{w}_i) - f^*$ (corrente, oscillante). I salti visibili sul record corrispondono alle contrazioni di δ .

Lettura del grafico.

- IRLS (sinistra, semilog) è una retta $\Rightarrow$ rate *lineare*: ogni iterazione moltiplica il gap per un fattore costante (qui ≈ 0.85). 10^3 a 10^{-6} in ~ 100 iter.
- SGPTL (destra, log-log) è una retta a pendenza $-1/2 \Rightarrow$ rate *sublineare*: ogni decade in più di accuratezza richiede $\sim 100\times$ iterazioni.
- Il gap finale SGPTL ($\sim 6.6 \cdot 10^{-8}$ a $i = 8000$) è ottimo per un metodo sublineare ma comunque lontano da quel che IRLS raggiunge in pochi step.

19.1 Non-monotonicità in f

Perché? Il subgradiente non è una direzione di discesa; quando δ è troppo grande, il passo di Polyak diventa $\alpha_i \gg \alpha_i^{\text{ideale}}$ e $\mathbf{w}_{i+1}$ scavalca $\mathbf{w}^*$. La sicurezza overshoot snappa indietro al miglior iterato per evitare divergenze, ma solo dopo aver osservato il salto.

Conseguenza algoritmica. Si restituisce $\mathbf{w}_{\text{best}}$, non l'ultimo $\mathbf{w}_i$.

20 Sensitività a ρ

Pannello sinistro (δ_0). L'algoritmo è *robusto* a δ_0 : tutti i valori in $\{0.01, 0.05, 0.1, 0.5, 1.0\}$ $f(\mathbf{w}_0)$ raggiungono gap $\in [1.7 \cdot 10^{-8}, 4.6 \cdot 10^{-8}]$. Il meccanismo di contrazione adatta δ alla scala giusta




Figure 2: SGPTL sulle prime 2000 iterazioni, semilog y . Il *current gap* $f(\mathbf{w}_i) - f^*$ (arancione) oscilla bruscamente, ben sopra il *record gap* $\bar{f}^i - f^*$ (nero), monotono per costruzione. L’overshoot più grande è annotato.

in poche cicli di patience.

Pannello destro (ρ). Sensibilità *enorme*: i gap finali vanno da $6.9 \cdot 10^{-9}$ ($\rho = 0.8$) a $2.9 \cdot 10^{-4}$ ($\rho = 0.95$). Spaccatura netta:

- $\rho \geq 0.9$ (slow): δ contrae lentamente, target resta sopra f^* a lungo, miglioramento del check “ $f_{\text{new}} \leq f_{\text{ref}} - \delta/2$ ” non scatta, solo il fallback iter-count guida. Lento.
- $\rho \leq 0.5$ (aggressive): δ contrae troppo velocemente, target oscilla, sicurezze scattano spesso. $\rho = 0.3$ produce 607 contrazioni in 5000 step.
- $\rho \in [0.5, 0.8]$: sweet spot. $\rho = 0.7$ è il default robusto.

21 Warm vs cold start (con regola theory-pure)

Cosa si vede.

- Entrambi gli start convergono con la stessa pendenza qualitativa (rate sublineare $\sim 1/\sqrt{k}$).
- Il cold start finisce leggermente avanti ($\bar{f}^i - f^* \approx 2.4 \cdot 10^{-5}$) rispetto al warm ($4.8 \cdot 10^{-5}$) — factor di 2, dentro la variabilità tra istanze.
- Entrambi triggerano un numero comparabile di contrazioni δ (26 vs 22). Il meccanismo $r > R$ di Lemma 3.8 funziona come la teoria richiede — la chiave era avere $R = 1$ dello stesso ordine del passo tipico, non $R = 10\sqrt{i_{\max}}$ della prima sottomissione.

Conclusione. Il warm-start non è né necessario né dannoso: con R alla scala giusta, entrambi i punti di partenza funzionano. Lo manteniamo come default per consistenza con IRLS (stesso $\mathbf{w}_0$ in entrambi gli algoritmi $\Rightarrow$ confronto apples-to-apples). Il cold start resta un’alternativa valida con impatto pratico ridotto.

Floor $\gamma_{\min}$: ingrediente strutturale separato. Senza floor ($\gamma_{\min} = 0$), il greedy γ_i collassa a 0 su subgradienti quasi allineati, $\beta_i = \min(\beta, \gamma_i) \rightarrow 0$, e (3.5) del paper viene violata. La convergenza del Teorema 3.1 *richiede* $\gamma_{\min} > 0$. Sweep su $\gamma_{\min} \in \{0.05, 0.1, 0.2, 0.5\}$ produce gap consistentemente in $[10^{-7}, 10^{-5}]$, con $\gamma_{\min} = 0.05$ marginalmente migliore.




Figure 3: Sensibilità di SGPTL a δ_0 (sinistra, $\rho = 0.7$ fisso) e a ρ (destra, $\delta_0 = 0.1 f(w_0)$ fisso). $H = 100, M = 400, 5000$ iter.




Figure 4: SGPTL theory-pure (Algoritmo 1 senza iter-fallback, $R = 1, \gamma_{\min} = 0.05, \rho = 0.7$) su $H = 100, M = 300, \lambda = 0.1, i_{\max} = 8000$. Sinistra: record gap $\bar{f}^i - f^*$ in log-log; entrambi i punti di partenza producono discesa sublineare con envelope predetto dal Teorema 3.1. Destra: δ_i in log-lineare; la scala a gradini mostra le contrazioni di δ dal ramo $r > R$ (26 cold, 22 warm).

22 Confronto con IRLS

Numericamente, iterazioni per raggiungere ε :

ε	10^{-1}	10^{-2}	10^{-3}	10^{-4}	10^{-6}
IRLS	1	3	7	19	101
SGPTL	2	351	2571	5069	9711

Leggere il grafico. IRLS si schiaccia contro il pavimento di precisione in ~ 100 iterazioni a ~ 3 ms. SGPTL invece arriva a 10^{-6} ma impiega $\sim 10\,000$ iterazioni e ~ 170 ms. In tempo CPU, sull'istanza moderata, IRLS è due ordini di grandezza più veloce.

23 Scalabilità

Cosa ci si aspetta dalla teoria.

IRLS vs SGPTL ($H = 50, M = 200, \lambda_{\text{LASSO}} = 0.1$)




Figure 5: IRLS vs SGPTL sull'istanza moderata ($H = 50, M = 200, \lambda = 0.1$). Log-log. Pannello sinistro: gap vs iterazione. Pannello destro: gap vs tempo CPU.




Figure 6: Wall-clock time vs H per IRLS e SGPTL, $M = 5H$, $H \in \{50, 100, 500, 1000, 2000\}$, log-log.

- IRLS: $O(H^3)$ per Cholesky a iterazione, costante numero di iterazioni $\Rightarrow$ totale $O(H^3)$. Sul plot log-log, pendenza ≈ 3 .
- SGPTL: $O(MH) = O(H^2)$ a iterazione (perché $M = 5H$), per un numero di iterazioni che dipende dalla precisione voluta ma è $O(1)$ rispetto a H a precisione fissa $\Rightarrow$ totale $O(H^2)$. Pendenza ≈ 2 .

Per H moderato (≤ 2000 sul mio laptop) il costante davanti vince e IRLS è più veloce in assoluto. Per H molto grande, asintoticamente SGPTL diventa competitivo, ma quel regime non è raggiungibile su laptop standard.

24 Validazione su dati reali

Cosa si vede.

- Su entrambi i dataset, IRLS scende al pavimento di precisione in ~ 100 iterazioni.
- SGPTL converge sublinearmente; la differenza tra “submitted” e “fixed” è meno drammatica su diabetes ($\rho=0.9$ vince leggermente, perché il dataset è mal-condizionato e $f(\mathbf{w}_0)$ è già vicino a f^*) e leggermente in favore di “fixed” su California.




Figure 7: Convergenza sui due dataset reali (*diabetes*, *California housing*) trasformati da uno strato ELM di $H = 200$ sigmoidi. Plot di $f - f_{\min}$ con $f_{\min}$ il minimo empirico tra IRLS, SGPTL e sklearn. La curva tratteggiata è la versione “submitted” di SGPTL con $\rho = 0.9$, $\delta_0 = 0.1 f^*$ (impropria); la solida è la versione corretta con $\rho = 0.7$, $\delta_0 = 0.1 f(\mathbf{w}_0)$.

Part VIII

Lettura guidata della proof finale del Teorema 3.1

Questa parte è scritta per uno scopo solo: permetterti di rileggere la proof del Teorema 3.1 nel report (file `chapter3.tex`, sezione §5 del capitolo) e capire, riga per riga, *cosa* si sta facendo, *perché* si sta facendo, e *se è onesta*. Non c’è matematica nuova rispetto al resto del tutorial: solo una spiegazione in italiano corrente di quel che è scritto in inglese e LaTeX nel report.

25 Il quadro generale: cosa stiamo provando e con quale strategia

Il Teorema 3.1 del report afferma due cose:

1. I record values $\bar{f}_i = \min_{h \leq i} f(\mathbf{w}_h)$ generati dal nostro Algoritmo 1 (SGPTL su ELM LASSO) convergono a f^* .
2. Asintoticamente, una volta che il target-level si è raffinato a f^* , vale il bound

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|}{\gamma_{\min} \sqrt{k}},$$

da cui la complessità $O(L^2/(\gamma_{\min}^2 \varepsilon^2))$ per arrivare a precisione ε .

La strategia che usiamo per dimostrarlo è *citazionale*: non rifacciamo a mano i passaggi tecnici. C’è un articolo, d’Antonio–Frangioni 2009 (*Convergence Analysis of Deflected Conditional Approximate Subgradient Methods*), che dimostra un teorema generale di convergenza per una grande famiglia di metodi del subgradiente deflesso, di cui il nostro SGPTL è un caso particolare. Il loro Teorema 3.7 garantisce $\bar{f}_k \rightarrow f^*$ a patto che tre condizioni siano soddisfatte: (2.13), (3.5), (3.26). Quel teorema vive in un setting molto più generale del nostro (vincoli, oracolo inesatto, otto schemi di proiezione), quindi quasi tutto il lavoro tecnico è già svolto da loro.

Intuizione

La nostra proof è **verifica delle ipotesi**, non costruzione di un risultato da zero. Lo schema è:

1. “Il loro teorema dice X se valgono A, B, C”.
2. “Verifico A su ELM LASSO”. (lo facciamo)
3. “Verifico B su ELM LASSO”. (lo facciamo)
4. “Verifico C su ELM LASSO”. (lo facciamo)
5. “Verifico una condizione di regolarità (subgradienti limitati)”. (lo facciamo)
6. “Quindi vale X su ELM LASSO”. (concludiamo)

Per il *rate* aggiungiamo un secondo passo: una volta dimostrata la convergenza, asintoticamente il target-level coincide con f^* , e in quel regime il rate è il classico Polyak con f^* noto, dimostrato da Bertsekas (Thm. 7.17) e nelle slide del corso (slide 13). Il fattore $1/\gamma_{\min}$ è l’unico aggiustamento dovuto alla nostra deflessione con floor.

26 La mappatura di notazione

d’Antonio–Frangioni usa simboli diversi dai nostri. La proof apre con questa traduzione:

Loro	Noi	Cosa è
σ_k	0	errore dell’oracolo (noi abbiamo gradiente esatto)
α_k	γ_i	parametro di deflessione (peso del subgradiente fresco)
β_k	β_i	moltiplicatore della stepsize-restricted rule
ν_k	α_i	stepsize effettiva del passo $x_{k+1} = x_k - \nu_k d_k$
μ	ρ	fattore di contrazione del threshold δ
X	$\mathbb{R}^H$	insieme di vincoli (noi: tutto lo spazio)
λ_k	$f(\mathbf{w}_i) - (f_{\text{ref}}^k - \delta_k)$	numeratore del passo (gap stimato)

Questa tabella è importante perché senza di essa non si capisce *a quale* delle loro variabili stiamo applicando le nostre. Spesso il nome “ α ” di un paper è il “ γ ” di un altro: il significato è quel che conta.

Perché σ_k

Il paper d’Antonio–Frangioni vive nel setting più generale possibile: assume che a ogni iterata tu chiami una *black box* (oracolo) per ottenere $f(x_k)$ e $g_k \in \partial f(x_k)$, e prevede il caso in cui l’oracolo *sbagli leggermente*. Più precisamente, l’oracolo restituisce un σ_k -approximate subgradient: un vettore g_k che soddisfa la disuguaglianza del subgradiente solo a meno di una tolleranza $\sigma_k \geq 0$,

$$f(y) \geq f(x_k) + \langle g_k, y - x_k \rangle - \sigma_k, \quad \forall y.$$

Quando $\sigma_k = 0$ si recupera la classica subgradient inequality. Quando $\sigma_k > 0$ il vettore restituito non è un subgradiente vero ma un suo surrogato con errore controllato; questo ha senso in applicazioni come la *Lagrangian relaxation*, dove ottenere il subgradiente vero richiede risolvere un sotto-problema costoso e si accetta un’approssimazione per risparmiare tempo. Il paper aggiunge σ_k nei loro teoremi proprio per coprire quei casi.

Noi non siamo in quel caso. Su ELM LASSO il subgradiente si scrive analiticamente:

$$\mathbf{g} = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda_{\text{LASSO}} \mathbf{s}, \quad s_i \in \partial |w_i|.$$

Le due componenti si calcolano *esattamente*:

- $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$ è un gradiente *vero* (il pezzo quadratico è differenziabile), costruito con prodotti matrice-vettore standard di **numpy**. Niente approssimazione, niente errore.
- Per la parte ℓ_1 , scegliamo $s_i \in [-1, +1]$ con la regola del segno e $s_i = 0$ quando $w_i = 0$ (capitolo 3 del report). Questa scelta è *un elemento del subdifferenziale vero* $\partial|w_i|$ — non un’approssimazione di un elemento ottimo, è proprio dentro $\partial|w_i|$ per definizione di subdifferenziale del modulo. La subgradient inequality vale quindi *senza alcuna tolleranza*.

Il fatto che $s_i = 0$ non sia il minimo-norma di $\partial f(\mathbf{w})$ in $w_i = 0$ è un’altra cosa: non riguarda l’*esattezza* del subgradiente (che è esatta), ma solo la *costante* L che lo limita (può essere fino a λ_{LASSO} più grande del necessario per componente affetta). σ_k misura “errore dell’oracolo”, non “sub-ottimalità della scelta dentro il subdifferenziale”. Anche con s_i scelto male, $\sigma_k = 0$.

Conseguenza pratica. Quando applichiamo Theorem 3.7 con $\sigma_k = 0$, la sua conclusione $f_{\text{ref}}^\infty \leq f^* + \sigma^*$ si specializza in $f_{\text{ref}}^\infty \leq f^*$, dove $\sigma^* = \limsup_k \sigma_k = 0$. Combinato con $f_{\text{ref}}^\infty \geq f^*$ (banale, perché i valori della funzione non possono scendere sotto il minimo), otteniamo $f_{\text{ref}}^\infty = f^*$, cioè convergenza esatta del record al valore ottimo. È qui che il $\sigma_k = 0$ fa la differenza concreta nella nostra proof: senza esattezza dell’oracolo, il paper garantirebbe solo σ^* -ottimalità asintotica (cf. Observation 2.7 pag. 364), che è strettamente più debole.

Perché X

Il paper d’Antonio–Frangioni studia il problema vincolato

$$f^* = \inf\{f(x) : x \in X\},$$

dove $X \subseteq \mathbb{R}^n$ è un sottoinsieme chiuso e convesso. Il titolo stesso del paper — “Convergence Analysis of Deflected *Conditional* Approximate Subgradient Methods” — ha la parola *conditional* proprio per questo: “conditional subgradient” è il nome standard per i metodi del subgradiente che, oltre a deflettere, *proiettano* la direzione sul tangent cone $T_X(x_k)$ di X al punto corrente, per evitare di uscire dal feasible set. Tutta la complicazione delle “otto varianti” del paper (eqq. (1.5)/(1.6)) viene dal dover decidere, ad ogni iterata, quali oggetti proiettare e quali no.

Quando X entra in gioco davvero? Tipicamente in applicazioni di *Lagrangian relaxation* su programmi di ottimizzazione combinatoria, dove il duale ha vincoli naturali $\lambda \geq 0$ (ortante non negativo) o vincoli di consistenza tra moltiplicatori — X è allora un poliedro semplice tipo $\mathbb{R}_+^n$. Lì la proiezione è banale (componente per componente) ma la presenza di X cambia la convergenza: gli iterati possono finire sulla frontiera, e la direzione di discesa va proiettata sul tangent cone per non sprecare passi che porterebbero fuori da X .

Noi non abbiamo vincoli. Il problema ELM LASSO è

$$\min_{\mathbf{w} \in \mathbb{R}^H} \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \lambda_{\text{LASSO}} \|\mathbf{w}\|_1.$$

Il dominio della minimizzazione è tutto $\mathbb{R}^H$. Non c’è alcun vincolo sul vettore $\mathbf{w}$ che cerchiamo: i pesi del livello di output dell’ELM possono assumere qualsiasi valore reale, sia positivo che negativo, di qualsiasi modulo. Niente $\mathbf{w} \geq 0$, niente $\|\mathbf{w}\| \leq R$, niente piano di simplex — $\mathbf{w}$ è completamente libero.

Conseguenze concrete della scelta $X = \mathbb{R}^H$.

- Il *tangent cone* di $\mathbb{R}^H$ in qualunque punto è $\mathbb{R}^H$ stesso: ti puoi muovere in qualunque direzione senza uscire dal feasible set.
- Il *normal cone* è $\{\mathbf{0}\}$ ovunque: nessuna direzione è “vietata”.

- La proiezione $P_{T_k} = P_{\mathbb{R}^H}$ è l'identità: $-P_{T_k}(-\tilde{d}_k) = \tilde{d}_k$ sempre.
- Quindi $\hat{d}_k = \tilde{d}_k = d_k$ per ogni iterazione: tutte le “otto varianti” del paper collassano in una sola.
- L'update si riduce a $\mathbf{w}_{k+1} = \mathbf{w}_k - \nu_k \mathbf{d}_k$ senza alcuna proiezione esterna — niente $P_X(\hat{\mathbf{w}}_{k+1})$, niente $\hat{\mathbf{x}}_{k+1}$ vs $\mathbf{x}_{k+1}$: i nostri $\mathbf{w}_{k+1}$ coincidono.

Perché questo è rilevante per la verifica delle ipotesi. La condizione (2.13) del paper, $d_k = \tilde{d}_k \Rightarrow v_{k+1} = \tilde{d}_k$, è precisamente la condizione che lega la direzione *proiettata* e quella *non-proiettata* alla memoria di deflessione: nel caso vincolato $X \neq \mathbb{R}^n$ ti devi preoccupare di scegliere fra le due e mantenere coerenza tra direzione corrente e memoria. Con $X = \mathbb{R}^H$ la condizione svanisce perché non c'è scelta da fare. Allo stesso modo, la condizione (3.5) sulla soglia $\beta^* > 0$ si verifica con la sola dinamica del nostro floor $\gamma_{\min}$, senza alcuna interferenza dalla geometria di X ; e la condizione (3.26) si discute interamente in termini di δ_k e $\sum s_k$, dove $s_k = \|\hat{\mathbf{x}}_{k+1} - \mathbf{x}_k\|$ ma con noi $\hat{\mathbf{x}}_{k+1} = \mathbf{w}_{k+1}$ direttamente, quindi $s_k = \nu_k \|\mathbf{d}_k\|$ pulito.

In sintesi. La generalità “ X chiuso convesso qualunque” del paper è gratis per noi: l'algoritmo è scritto e dimostrato in un setting più grande di quel che ci serve, e noi semplicemente ne usiamo lo *slice* unconstrained, in cui tutto si semplifica. Lo stesso paper, peraltro, copre esplicitamente il caso unconstrained come specializzazione: si vede dalle note nel paragrafo §2 (“ $X \subseteq \mathbb{R}^n$ is closed convex. We are specifically interested in the case where $X \neq \mathbb{R}^n$ ”) — gli autori dichiarano di star scrivendo i risultati pensando al caso vincolato perché è il caso difficile, ma i teoremi continuano a valere quando $X = \mathbb{R}^n$.

27 Punto (a): la condizione (2.13)

Cosa dice la (2.13) nel paper

Il paper, nel suo setting generale (con vincoli), considera due forme della direzione: $\tilde{d}_k$ (non proiettata) e $\hat{d}_k = -P_{T_k}(-\tilde{d}_k)$ (proiettata sul tangent cone T_k di X). Inoltre tiene memoria di una “deflection term” v_{k+1} usata al prossimo passo. La condizione (2.13), dal Lemma 2.4, è:

$$d_k = \tilde{d}_k \Rightarrow v_{k+1} = \tilde{d}_k.$$

Tradotto in italiano: “se la direzione effettiva che usi è quella non-proiettata, allora la memoria che porti avanti per il prossimo step deve coincidere con la stessa direzione non-proiettata”.

A cosa serve

Non è una condizione di proiezione. È una condizione di *coerenza interna del meccanismo di deflessione*. Serve perché il paper dimostra (Lemma 2.4) che, sotto (2.13), vale la disuguaglianza “cruciale” (2.12):

$$\langle d_k, x - x_k \rangle \leq \langle v_{k+1}, x - x_k \rangle,$$

che è l'ingrediente tecnico chiave della loro *stepsize-restricted analysis*. Senza (2.12) la dim non funziona.

Perché vale trivialmente per noi

Siamo unconstrained: $X = \mathbb{R}^H$, quindi $T_k = \mathbb{R}^H$, quindi la proiezione P_{T_k} è l'identità, quindi $\hat{d}_k = \tilde{d}_k$. In altre parole: per noi non esistono “due versioni” della direzione — ce n'è una sola, $\mathbf{d}_i$. E il nostro algoritmo, alla iterazione successiva, usa esattamente $\mathbf{d}_i$ come “previous direction”

nel calcolo del γ_{i+1} ottimo. Quindi $v_{k+1} = d_k = \tilde{d}_k$ automaticamente, e (2.13) è verificata senza fare alcuna fatica.

Attenzione

Cosa avevo scritto male nella versione precedente. Avevo chiamato (2.13) “projection condition”. È sbagliato: la (2.13) lega la direzione *non-proiettata* alla memoria di deflessione. La proiezione c’entra perché l’altra forma $\hat{d}_k$ è una proiezione, e (2.13) governa il caso “no, ho usato $\tilde{d}_k$, non $\hat{d}_k$ ”. Per noi non c’è scelta perché le due coincidono, ma chiamarla “projection condition” è un’imprecisione che hai correttamente segnalato.

28 Punto (b): la condizione (3.5)

Cosa dice la (3.5) nel paper

Per il loro corrected Polyak stepsize $\nu_k = \beta_k \lambda_k / \|d_k\|^2$, la (3.5) impone:

$$\begin{cases} \lambda_k \geq 0 \Rightarrow \alpha_k \geq \beta_k \geq \beta^* > 0, \\ \lambda_k < 0 \Rightarrow \alpha_k = 0 \ (\Rightarrow \beta_k = 0). \end{cases}$$

Tradotto: “quando il gap stimato λ_k è positivo, sia il parametro di deflessione α_k (cioè il nostro γ_i) sia il moltiplicatore β_k devono restare sopra una soglia $\beta^* > 0$ uniforme. Quando il gap è negativo (cioè la tua stima ti dice che sei già passato sotto f^* , situazione anomala), butta via il passo”.

A cosa serve

A garantire che, per le iterazioni in cui ha senso muoversi, ti muovi davvero — la stepsize non collassa a zero. Senza una soglia β^* uniforme, β_k potrebbe tendere a zero adiabaticamente e la convergenza svanire.

Perché vale per noi

Due conti:

- Caso $\lambda_k > 0$ (gap stimato positivo, il caso “normale”). Il nostro algoritmo setta $\beta_i = \min(1, \gamma_i)$. Per il floor sulla deflessione, $\gamma_i \geq \gamma_{\min}$. Quindi $\beta_i \geq \min(1, \gamma_{\min}) = \gamma_{\min}$. Possiamo quindi scegliere $\beta^* = \gamma_{\min}$ nella loro notazione, e la prima riga di (3.5) è soddisfatta. La condizione $\alpha_k \geq \beta_k$ in (3.5) corrisponde a $\gamma_i \geq \beta_i$, che è esattamente la nostra stepsize-restricted rule $\beta_i \leq \gamma_i$.
- Caso $\lambda_k \leq 0$ (numeratore del passo non-positivo). Il safeguard del nostro algoritmo (§4.2, punto (ii) della lista dei safeguard nel report) contrae δ e skipa il passo. “Skippare il passo” significa $\alpha_i = 0$, esattamente quel che chiede (3.5).

29 Punto (c): la condizione (3.26)

Questa è la più delicata, perché è una *disgiunzione*.

Cosa dice la (3.26) nel paper

$$(3.26): \quad O \quad f_{\text{ref}}^\infty = f^* = -\infty \quad \text{oppure} \quad \liminf_k \delta_k = 0 \quad e \quad \sum_{k=1}^{\infty} \frac{\lambda_k}{\|d_k\|^2} = \infty.$$

Cosa significa concretamente

C'è un caso degenerare e un caso “normale”.

Caso degenerare. Se $f^* = -\infty$ (cioè f è inferiormente illimitata) e l'algoritmo sta in qualche modo scoprendolo facendo crashare f_{ref}^k a $-\infty$, allora c'è poco da dimostrare: “converge” a $-\infty$ banalmente. Su ELM LASSO non ci interessa: f è coerciva, $f^* > -\infty$, quindi questo ramo è escluso a priori. Lo nominiamo solo per riprodurre fedelmente l'enunciato di (3.26).

Caso normale. Servono *due* condizioni insieme:

- $\liminf \delta_k = 0$: il threshold di tolleranza del target level deve tendere a zero (almeno in limite inferiore). Senza questo, $f_{\text{ref}}^k - \delta_k$ non si avvicina mai a f^* e tu non puoi pretendere accuratezza arbitraria.
- $\sum \lambda_k / \|d_k\|^2 = \infty$: la *serie* dei moduli dei passi che fai deve divergere. Cioè ti devi muovere abbastanza spesso e abbastanza tanto da accumulare distanza infinita. Se ti fermassi dopo un numero finito di passi non-banali, non avresti modo di esplorare e scoprire f^* .

Il paper osserva (pag. 375) che la seconda condizione si può sostituire con la forma equivalente più maneggevole $\sum_k s_k = \infty$, dove $s_k = \|\hat{x}_{k+1} - x_k\|$ è la lunghezza del passo — è la (3.28) del paper. Cambiare $\lambda_k / \|d_k\|^2$ in s_k non altera la sostanza ma rende verificabile la condizione iterazione per iterazione, dato che s_k è una quantità che l'algoritmo conosce e può controllare attivamente.

Come la verifichiamo: il Lemma 3.8

Il Lemma 3.8 del paper costruisce una regola *esplicita* per aggiornare $(f_{\text{ref}}^k, \delta_k)$ e dimostra che con quella regola si ottiene esattamente la disgiunzione (3.26). La regola è:

1. Inizializza $f_{\text{ref}}^1 = f(x_1)$, $\delta_1 \in (0, \infty)$, $r_1 = 0$.
2. Se $f_k \leq f_{\text{ref}}^k - \delta_k/2$ (*sufficient descent*): aggiorna f_{ref}^k al record corrente, azzera r_k .
3. Altrimenti, se $r_k > R$ (*target infeasibility*): contraì $\delta_k \leftarrow \mu \delta_{k-1}$, azzera r_k .
4. Altrimenti: accumula $r_{k+1} = r_k + \|\hat{x}_{k+1} - x_k\|$.

Questa è *letteralmente* la regola che il nostro Algoritmo 1 esegue alle righe 21–27 (il blocco `if/elif/else` dopo l'update di $\mathbf{w}_{i+1}$). Sotto la nostra mappatura $\mu \leftrightarrow \rho$, le tre branche corrispondono una a una. Quindi la (3.26) vale automaticamente, perché abbiamo implementato *quella* regola.

Note storica: dove eravamo finiti, come ci siamo ripuliti

Un draft precedente del progetto aveva, sopra alla regola di Lemma 3.8, due meccanismi aggiuntivi: **(a)** un *iter-fallback* che contraeva δ ogni R_{iter} iterazioni senza miglioramento di $\bar{f}$ e **(b)** un *overshoot rescue* che riportava $\mathbf{w}$ a $\mathbf{w}_{\text{best}}$ quando il passo Polyak esplodeva. Più **(c)** il default $R = 10\sqrt{i_{\text{max}}} \approx 894$ per la soglia travel-distance, che su ELM LASSO era ordini di grandezza più grande di qualsiasi travel accumulato realisticamente (lunghezze tipiche del passo $\sim 10^{-3}$, quindi r non raggiungeva mai R tra un reset e l'altro). Il prof ha segnalato (a) e (b) come incompatibili con la teoria del paper: il loro Lemma 3.8 dimostra $\sum_k s_k = \infty$ *a patto che* ogni contrazione di δ sia preceduta da almeno R di travel via il trigger $r_k > R$, proprietà che l'iter-fallback viola. Il Teorema 3.1 enunciato nella prima sottomissione, che citava Theorem 3.7 del paper applicato a Lemma 3.8 verbatim, non era quindi pienamente applicabile all'algoritmo che effettivamente eseguivamo.

Il fix: era R , non l'iter-fallback

La diagnosi che ne è seguita è stata duplice. Primo: (a) e (b) sono *workaround* che nascondono bug invece di risolverli, e la prova del paper non si estende a essi; vanno tolti. Secondo: il vero motivo per cui senza (a) l'algoritmo sembrava “non funzionare” nella prima sottomissione era (c) — un singolo intero scelto male. Con R alla scala giusta ($R = 1$, dello stesso ordine del passo tipico $\alpha_i \|\mathbf{d}_i\| \sim 10^{-3}$), il ramo $r > R$ di Lemma 3.8 spara come la teoria si aspetta, δ si contrae a una cadenza sostenuta, e l'algoritmo converge dentro l'envelope teorico del Teorema 3.1.

Bottom line: la regola di Algoritmo 1 è ora *letteralmente* quella di Lemma 3.8, senza estensioni. Per la (3.26): le righe 16–21 dell'Algoritmo 1 (sufficient-descent, target-infeasibility $r > R$, accumulate- r) corrispondono una-a-una alla regola di Lemma 3.8, sotto la mappatura $\mu \leftrightarrow \rho$. Il Lemma 3.8 dà $\delta_k \rightarrow 0$ e $\sum_k s_k = \infty$; quindi (3.26) vale.

Conseguenze numeriche del fix

Il costo di togliere i workaround è moderato:

- Sull'istanza di convergenza ($H = 100$, $M = 300$, $i_{\max} = 8000$): gap $\bar{f}^i - f^* \approx 4.8 \cdot 10^{-5}$ con la regola pura, contro $\sim 6.6 \cdot 10^{-8}$ della prima sottomissione (con workaround). Tre ordini di grandezza più alto, ma è il baseline onesto.
- Sui dati reali (**diabetes**, **california**): SGPTL eguaglia la precisione di sklearn su entrambi — stesso esito della prima sottomissione, senza workaround.
- Sul confronto al variare di ε : SGPTL raggiunge $\varepsilon = 10^{-4}$ in ~ 2500 iterazioni e stalla prima di 10^{-6} , coerente con il rate $O(L^2/\varepsilon^2)$. IRLS raggiunge 10^{-6} in 101 iterazioni come prima.

Il gap rispetto a IRLS che la prima sottomissione sembrava colmare era, retrospettivamente, un artefatto numerico del workaround, non una caratteristica dell'algoritmo. Con la regola theory-pure il confronto qualitativo è preservato (IRLS più veloce in accuracy, SGPTL più economico per iterazione), ma senza promesse che il framework non garantisce.

30 Subgradienti uniformemente limitati

Sia il Teorema 3.7 sia il rate Polyak chiedono $\|\mathbf{g}_i\| \leq L$ uniformemente lungo la traiettoria. Per ELM LASSO f non è globalmente Lipschitz su $\mathbb{R}^H$ (la parte quadratica cresce illimitatamente), quindi non c'è un L che vada bene ovunque. Ma:

- f è coerciva: $f(\mathbf{w}) \rightarrow \infty$ per $\|\mathbf{w}\| \rightarrow \infty$. Quindi ogni sublivello $S_c = \{\mathbf{w} : f(\mathbf{w}) \leq c\}$ è compatto.
- Gli iterati $\mathbf{w}_i$ generati dall'algoritmo (in particolare $\mathbf{w}_{\text{best}}$, che è quel che restituiamo) stanno dentro S_{c_0} per qualche c_0 . Su S_{c_0} , che è compatto, ogni funzione convessa è Lipschitz (risultato standard, slide del corso), e quindi il suo subdifferenziale è uniformemente limitato.
- Esiste quindi un L (dipendente dai dati del problema e dal punto iniziale) tale che $\|\mathbf{g}_i\| \leq L$ per tutti gli i .

Cosa significa “coerciva” (per ELM LASSO)

Definizione. Una funzione $f : \mathbb{R}^H \rightarrow \mathbb{R}$ si dice *coerciva* se

$$\lim_{\|\mathbf{w}\| \rightarrow \infty} f(\mathbf{w}) = +\infty.$$

Tradotto in italiano: *man mano che ti allontani dall'origine in qualunque direzione, il valore di f esplode verso $+\infty$, senza eccezioni*. Non basta che cresca lungo qualche direzione: deve crescere lungo *tutte* le direzioni in cui $\|\mathbf{w}\|$ tende all'infinito. Non possono esistere “corridoi” lungo i quali la funzione resta finita.

Intuizione visiva. Immagina il grafico di f in $\mathbb{R}^2$ come un paesaggio. Coercività dice: il paesaggio è una conca che sale ovunque verso l'esterno — non c'è nessuna valle che si estende fino all'orizzonte mantenendosi a quota costante. Esempi:

- $f(\mathbf{w}) = \|\mathbf{w}\|^2$: coerciva (paraboloide).
- $f(\mathbf{w}) = \|\mathbf{w}\|_1$: coerciva.
- $f(w_1, w_2) = w_1^2$: non coerciva, perché lungo l'asse w_2 resta a quota zero pur con $\|\mathbf{w}\| \rightarrow \infty$.
- $f(\mathbf{w}) = e^{-\|\mathbf{w}\|^2}$: non coerciva, va a zero all'infinito.

Perché ELM LASSO è coerciva. Scriviamo

$$f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda_{\text{LASSO}} \|\mathbf{w}\|_1.$$

Il termine ℓ_1 da solo basta: $\|\mathbf{w}\|_1 \geq \|\mathbf{w}\|_2$ vale in $\mathbb{R}^H$ (è una delle disuguaglianze di equivalenza tra norme), quindi $\|\mathbf{w}\|_1 \rightarrow \infty$ quando $\|\mathbf{w}\|_2 \rightarrow \infty$, e questo basta perché $f(\mathbf{w}) \rightarrow \infty$. Il termine quadratico aiuta ancora di più *quando $\mathbf{X}$ ha rango pieno* (cioè quando il kernel di $\mathbf{X}$ è banale): in quel caso $\|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \rightarrow \infty$ quando $\|\mathbf{w}\| \rightarrow \infty$, e f esplode anche senza il ℓ_1 . Se invece $\mathbf{X}$ ha kernel non banale (caso degenero), esistono direzioni $\mathbf{w}$ in cui $\mathbf{X}\mathbf{w} = \mathbf{0}$ e il termine quadratico resta fermo a $\|\mathbf{y}\|^2/2$ — ma il ℓ_1 continua a esplodere, quindi f è comunque coerciva. *Bottom line*: con $\lambda_{\text{LASSO}} > 0$, ELM LASSO è coerciva sempre, indipendentemente da $\mathbf{X}$.

Conseguenze che ci servono nella proof.

1. $f^* > -\infty$: una funzione coerciva e continua su $\mathbb{R}^H$ ha sempre minimo finito — non può scendere a $-\infty$. Per noi questo esclude il ramo degenero “ $f^* = -\infty$ ” della condizione (3.26), come usato sopra.
2. *Sublivelli* $S_c = \{\mathbf{w} : f(\mathbf{w}) \leq c\}$ sono *compatti*: chiusi (per continuità di f) e limitati (per coercività: se fossero illimitati ci sarebbe una successione $\mathbf{w}^{(k)} \in S_c$ con $\|\mathbf{w}^{(k)}\| \rightarrow \infty$ ma $f(\mathbf{w}^{(k)}) \leq c$, contro la definizione di coerciva).
3. *Subgradienti limitati lungo la traiettoria*: gli iterati di SGPTL non escono mai troppo dal sublivello iniziale (la target-level mechanism evita esplosioni controllando il numeratore del passo), quindi vivono dentro un S_{c_0} compatto. Su un compatto, una funzione convessa è automaticamente Lipschitz, e una funzione Lipschitz ha subgradienti limitati. È esattamente l' L che ci serve nel rate.

Perché lo notiamo solo a questo punto della proof. La coercività non è un'ipotesi che il paper d'Antonio–Frangioni ci chiede esplicitamente: il loro Teorema 3.7 si accontenta dell'oracolo che restituisce g_k tale che $\|g_k\|$ sia “not too erratic”. Però *nella loro proof* (pag. 370) gli serve che la successione $\|d_k\|$ sia limitata superiormente, e per ottenerlo invocano la compattezza del sublivello, ottenuta da coercività. Quindi anche se non è scritta come ipotesi, è di fatto necessaria, e va verificata sul nostro problema. Cosa che facciamo.

31 Lettura della conclusione

A questo punto della proof abbiamo verificato:

- (2.13): trivialmente, perché siamo unconstrained.
- (3.5): per via del floor $\gamma_{\min}$ e del safeguard sul numeratore non-positivo.
- (3.26): perché la nostra regola di update implementa Lemma 3.8 del paper.
- Subgradienti limitati: per coercività + Lipschitz convessa su compatti.
- Oracolo esatto: $\sigma_k = 0$ (calcoliamo subgradienti analitici, no rumore).

Sotto queste ipotesi, il **Teorema 3.7 del paper** conclude $f_{\text{ref}}^\infty \leq f^* + \sigma^* = f^*$ (l'oracolo è esatto). E poiché f_{ref}^k è una sottosuccessione dei valori $f(\mathbf{w}_i)$, anche $\bar{f}_i \rightarrow f^*$. Questo dà il primo pezzo della tesi (convergenza).

Per il *rate*, il Teorema 3.7 non dà un bound $O(1/\sqrt{k})$ esplicito — dà solo convergenza. Per ottenere il rate facciamo un secondo argomento, semplice:

- Lemma 3.8 garantisce $\delta_k \rightarrow 0$, e contestualmente $f_{\text{ref}}^k \rightarrow f^*$ (per come è costruita la regola di update).
- Quindi, asintoticamente, il nostro target-level $f_{\text{ref}}^k - \delta_k$ tende a f^* , e il passo Polyak adattivo $\beta_i(f(\mathbf{w}_i) - (f_{\text{ref}}^k - \delta_k)) / \|\mathbf{d}_i\|^2$ tende al passo Polyak “vero” $\beta_i(f(\mathbf{w}_i) - f^*) / \|\mathbf{d}_i\|^2$.
- In quel regime, vale il rate Polyak classico, $L \|\mathbf{w}_0 - \mathbf{w}^*\| / \sqrt{k}$, dimostrato da Bertsekas (Thm. 7.17) e nelle slide del corso (slide 13).
- L'aggiustamento per il nostro caso è il fattore $1/\gamma_{\min}$: ad ogni iterazione il moltiplicatore $\beta_i = \min(1, \gamma_i)$ contrae il passo di un fattore almeno $\gamma_{\min}$ rispetto al Polyak puro, e questo si riflette nella costante del rate (non nell'esponente).
- Risultato: $\bar{f}_k - f^* \leq L \|\mathbf{w}_0 - \mathbf{w}^*\| / (\gamma_{\min} \sqrt{k})$, da cui complessità $O(L^2 / (\gamma_{\min}^2 \varepsilon^2))$.

32 Cosa NON facciamo — e perché va bene

Non rifacciamo la dim del Teorema 3.7

La dim del Teorema 3.7 del paper è lunga e tecnica (passa per Lemma 3.3, Lemma 3.4, Theorem 3.5, e usa più volte argomenti per assurdo). Non la riproduciamo per due ragioni: (i) è già pubblicata in una rivista peer-reviewed (SIAM J. Optim.); (ii) il pubblico del nostro report è un docente del corso che la conosce e in più è coautore del paper. Sarebbe spreco di pagine, non valore aggiunto.

Non costruiamo il rate $1/\sqrt{k}$ a partire da zero

Allo stesso modo, il rate Polyak classico è materiale di prima settimana del corso di ottimizzazione (slide 13). Citiamo Bertsekas e le slide, non rifacciamo la dim. L'unica cosa che dobbiamo argomentare a mano è il fattore $1/\gamma_{\min}$, ed è un argomento di una riga: ogni iterazione ha un fattore $\beta_i \geq \gamma_{\min}$ in più rispetto al Polyak puro.

Non dimostriamo che gli iterati restano in S_{c_0}

Diciamo solo “gli iterati restano in un sublivello S_{c_0} per qualche c_0 ”. Per il record $\bar{f}_i$ è ovvio (è monotono non crescente da $f(\mathbf{w}_0)$). Per la sequenza $\mathbf{w}_i$ corrente è meno ovvio (i passi possono temporaneamente farti uscire dal sublivello iniziale), ma il target-level mechanism lo mantiene de facto bounded: lo discutiamo nella sezione di verifica delle ipotesi, punto 2 (“Bounded subgradients for ELM LASSO”) del report.

33 Sanity check: la proof è onesta?

I criteri che vale la pena verificare prima di considerarla chiusa:

1. **Ogni teorema citato è effettivamente in quella fonte?** Sì: Theorem 3.7 e Lemma 3.8 sono alle pagg. 374 e 375 del paper d’Antonio–Frangioni, le condizioni (2.13), (3.5), (3.26) sono ai punti 362, 365, 374 rispettivamente. Le slide 13 (Polyak rate) e 14 (target-level) sono dal materiale ufficiale del corso.
2. **Le ipotesi che il teorema richiede sono *tutte* verificate?** Sì: (2.13), (3.5), (3.26), oracolo esatto, subgradienti limitati. Niente di lasciato implicito.
3. **La verifica si fa *sul nostro problema specifico*?** Sì: ogni punto della verifica menziona esplicitamente ELM LASSO o l’algoritmo concreto (numero della riga del pseudocodice).
4. **Stiamo nascondendo qualcosa nelle costanti?** Il fattore $1/\gamma_{\min}$ è esplicito; con $\gamma_{\min} = 0.05$ inflaziona di $400\times$ il numero di iterazioni rispetto a Polyak puro, e lo diciamo a chiare lettere. Niente cifre nascoste.
5. **Eviteremmo critiche del tipo “LLM-flavored”?** Le frasi sono concrete, non generiche; ogni claim ha un riferimento; non ci sono “it is well known that” né “one can easily see”. Il rate non è venduto come conseguenza diretta di Thm. 3.7 (che dà solo convergenza), ma come applicazione del classical Polyak rate nel regime asintotico in cui Lemma 3.8 garantisce $\delta_k \rightarrow 0$.

34 Cosa potresti voler controllare ancora

Se vuoi essere paranoid prima della submission, queste sono le cose da rileggere a fonte aperta:

- Apri il paper d’Antonio–Frangioni a pag. 374 (Theorem 3.7) e verifica che l’enunciato dica letteralmente quel che noi facciamo dire (ipotesi: (2.13), (3.5); tesi: $f_{\text{ref}}^\infty \leq f^* + \sigma^*$).
- Apri pag. 375 (Lemma 3.8) e verifica che le quattro branche della regola siano: init, sufficient descent, target infeasibility, accumulate; sotto l’identificazione $\mu \leftrightarrow \rho$, sono le righe 21–27 dell’Algoritmo 1 del report.
- Apri pag. 374 e verifica la formulazione di (3.26): disgiunzione “ $f_{\text{ref}}^\infty = f^* = -\infty$ oppure $\liminf \delta_k = 0$ e (3.25)”.
- Apri le slide del corso n. 13 e verifica l’enunciato del Polyak rate (la formulazione classica $\bar{f}_k - f^* \leq L \|\mathbf{w}_0 - \mathbf{w}^*\|/\sqrt{k}$, con f^* noto). È la forma cui ci agganciamo per il bound asintotico.

Se tutti e quattro tornano, la proof è chiusa e onesta. Niente formulette aggiuntive, niente catene di lemmi nascoste: solo verifica di ipotesi e citazione del risultato.

Part IX

Conclusioni

35 Sintesi finale

1. **Problema:** $\min f = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \lambda \|\mathbf{w}\|_1$, convesso, non differenziabile, coercivo, strongly convex se $\mathbf{X}$ ha rango pieno.
2. **Subgradiente:** $\mathbf{g} = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{s}$, $\mathbf{s} \in \partial \|\mathbf{w}\|_1$. Soddisfa $\langle \mathbf{g}, \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}) - f^*$.
3. **Polyak step:** $\alpha_i^{\text{Polyak}} = (f(\mathbf{w}_i) - f^*) / \|\mathbf{g}_i\|^2$. Rate $O(L^2/\varepsilon^2)$, ottimale per problemi convex nondifferenziabili (lower bound Nemirovski-Yudin).
4. **Deflected method:** $\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$, smorza oscillazioni. Convergenza richiede $\beta_i \leq \gamma_i$ per chiudere un'induzione su $\nu_i = \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$. Stesso rate, costante peggiorata di $1/\beta_{\min}$.
5. **Target level:** sostituisce f^* con $f_{\text{ref}} - \delta$ adattivo. Tre branche di update (good improvement, too many bad steps, accumulate).
6. **Floor** $\gamma_{\min} > 0$: ingrediente strutturale, non fine-tuning. Senza, l'algoritmo si congela.
7. **Su ELM LASSO:** tutte le ipotesi del teorema verificate. Rate teorico $\bar{f}_k - f^* \leq 20L \|\mathbf{w}_0 - \mathbf{w}^*\| / \sqrt{k}$ con $\gamma_{\min} = 0.05$.
8. **In pratica:** $\bar{f}^i$ scende sublineare $\sim 1/\sqrt{i}$, f corrente non-monotono, ritorno $\mathbf{w}_{\text{best}}$. Robusto a δ_0 , molto sensibile a ρ (default 0.7).
9. **Confronto con IRLS:** SGPTL paga $\sim 100\times$ in iterazioni e $\sim 100\times$ in tempo per la stessa precisione su $\varepsilon \leq 10^{-4}$.

35.1 Per capire definitivamente

Le tre cose da ricordare se devi rispiegare a qualcun altro:

- Il subgradiente esiste sempre per funzioni convesse non differenziabili e fornisce la disuguaglianza $\langle \mathbf{g}, \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}) - f^*$ che è il motore di tutto.
- Il passo di Polyak è “perfetto” nel senso che minimizza la distanza da $\mathbf{w}^*$ dopo il passo; il problema è che usa f^* ignoto, da cui il target-level mechanism come surrogato adattivo.
- La deflessione complica la dim di convergenza ($\mathbf{d}_i$ non è un subgradiente), ma la regola $\beta_i \leq \gamma_i$ chiude un'induzione che ricostruisce il bound. Il floor $\gamma_{\min}$ tiene la costante finita.