

IRLS: rate di convergenza, spiegato passo passo

La Jacobiana $\nabla \mathcal{M}(\mathbf{w}^*) = \mathbf{I} - \mathbf{Q}(\mathbf{w}^*)^{-1} \nabla^2 f_{\varepsilon}(\mathbf{w}^*)$ e la dimostrazione di $\rho(\nabla \mathcal{M}(\mathbf{w}^*)) < 1$

Note di studio — progetto CM (ELM + LASSO, algoritmo A1)

6 giugno 2026

Sommario

Documento di supporto allo studio (per me e per Matthew). Ricostruisce, partendo dalle basi, perché IRLS converge *linearmente* sul problema ELM + LASSO e perché il rate è *lento* (fattore di contrazione vicino a 1). Il cuore sono due cose: (i) la forma della Jacobiana della mappa di IRLS nel punto fisso, e (ii) la dimostrazione che il suo raggio spettrale è strettamente minore di 1. Tutto è coerente con il paragrafo *Convergence rate* del capitolo IRLS del report; qui è solo svolto con più dettaglio e senza passaggi impliciti.

Indice

1	Il problema e cosa fa IRLS	1
2	Cosa significa “rate”: lineare vs sublineare	2
3	IRLS come iterazione a punto fisso	2
4	Il problema “vero” che IRLS risolve: la versione smussata	3
5	La Jacobiana della mappa: derivazione da zero	3
6	Dimostrazione che il raggio spettrale e’ minore di 1	4
7	Perché il rate è vicino a 1 (cioè: perché IRLS è lento)	5
8	Perché la figura sembra “non lineare”	5
9	Avvertenze critiche (limiti della dimostrazione)	6
	Riepilogo in cinque frasi	6

1 Il problema e cosa fa IRLS

Il problema che vogliamo risolvere (ELM con regolarizzazione LASSO) è

$$\min_{\mathbf{w} \in \mathbb{R}^H} f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1, \quad (1)$$

con $\mathbf{X} \in \mathbb{R}^{M \times H}$ la matrice delle feature dello strato nascosto (assunta a *rango colonna pieno*, $M \geq H$) e $\lambda > 0$ il peso LASSO. Il termine $\|\mathbf{w}\|_1$ rende f **non differenziabile** dove qualche componente è zero, quindi non si possono usare metodi a gradiente direttamente.

Idea di IRLS. A ogni passo si sostituisce $|w_i|$ con un maggiorante quadratico (liscio) costruito attorno al punto corrente $\mathbf{w}_k$, e si minimizza il modello risultante. Concretamente, usando la

disuguaglianza $(|w_i| - |(w_k)_i|)^2 \geq 0$ si ottiene

$$|w_i| \leq \frac{w_i^2}{2|(w_k)_i|} + \frac{|(w_k)_i|}{2} \quad ((w_k)_i \neq 0),$$

e sommando su i il termine L_1 viene maggiorato da una forma quadratica pesata. Il modello (surrogato) da minimizzare a ogni iterazione è quindi un **minimi quadrati pesati con regolarizzazione** L_2 , che ha soluzione in forma chiusa risolvendo un sistema lineare SPD.

Pesi con soglia. Per evitare la divisione per zero quando una componente si avvicina a 0, i pesi usano una soglia $\varepsilon > 0$:

$$(\mathbf{W}_k)_{ii} = \left(\max(|(w_k)_i|, \varepsilon) \right)^{-1/2}. \quad (2)$$

Questa soglia, come vedremo, è ciò che trasforma il problema risolto da IRLS in una versione *smussata* del LASSO, ed è anche il motivo per cui la teoria diventa pulita.

2 Cosa significa “rate”: lineare vs sublineare

Chiamiamo g_k una misura dell’errore al passo k (per esempio $\|\mathbf{w}_k - \mathbf{w}^*\|$, oppure il gap $f(\mathbf{w}_k) - f^*$).

Definizione 1 (Convergenza lineare). La successione converge *linearmente* con fattore $\rho \in (0, 1)$ se

$$\lim_{k \rightarrow \infty} \frac{g_{k+1}}{g_k} = \rho, \quad 0 < \rho < 1.$$

A ogni passo l’errore viene moltiplicato (asintoticamente) per la stessa costante ρ .

Definizione 2 (Convergenza sublineare). La convergenza è *sublineare* se $g_{k+1}/g_k \rightarrow 1$ (l’errore cala, ma il guadagno per passo svanisce). Esempio tipico: il metodo del subgradiente, con $g_k \sim 1/\sqrt{k}$.

Lettura su grafico semilog (asse $y = \log g_k$, asse $x = k$):

- lineare $\Rightarrow$ *retta* di pendenza $\log \rho$. Se $\rho \approx 0.99$ la retta è quasi orizzontale (lineare ma *lenta*);
- sublineare $\Rightarrow$ curva *concava* che si appiattisce progressivamente.

Una lineare con $\rho \approx 0.99$ su poche iterazioni è facilmente scambiabile a occhio per una sublineare: è esattamente il malinteso da chiarire nella figura del report.

3 IRLS come iterazione a punto fisso

La soluzione del sotto-problema di IRLS (equazione normale pesata) è, a meno della costante,

$$\mathbf{Q}_k \mathbf{w}_{k+1} = \mathbf{b}, \quad \mathbf{Q}_k = \mathbf{A} + \lambda \operatorname{diag} \left(\frac{1}{\max(|(w_k)_i|, \varepsilon)} \right), \quad \mathbf{A} = \mathbf{X}^\top \mathbf{X}, \quad \mathbf{b} = \mathbf{X}^\top \mathbf{y}. \quad (3)$$

(La costante λ qui è il peso LASSO; nel report compare anche $\lambda_{\text{IRLS}} = \frac{1}{2} \lambda_{\text{LASSO}}$ dovuto al fattore $1/2$ del maggiorante, ma nella matrice finale i conti tornano a λ_{LASSO} .)

Poiché $\mathbf{Q}_k$ dipende *solo* da $\mathbf{w}_k$, l’intera iterazione è una funzione del punto corrente:

$$\boxed{\mathbf{w}_{k+1} = \mathcal{M}(\mathbf{w}_k), \quad \mathcal{M}(\mathbf{w}) = \mathbf{Q}(\mathbf{w})^{-1} \mathbf{b}} \quad (4)$$

con $\mathbf{Q}(\mathbf{w}) = \mathbf{A} + \lambda \operatorname{diag}(1/\max(|w_i|, \varepsilon))$. La soluzione $\mathbf{w}^*$ è un **punto fisso**: $\mathcal{M}(\mathbf{w}^*) = \mathbf{w}^*$, cioè $\mathbf{Q}(\mathbf{w}^*)\mathbf{w}^* = \mathbf{b}$.

Principio guida. Studiare la velocità di IRLS = studiare quanto la mappa $\mathcal{M}$ *contrae* le distanze vicino a $\mathbf{w}^*$. Se vicino al punto fisso $\mathcal{M}$ avvicina i punti a $\mathbf{w}^*$ di un fattore $\rho < 1$ a ogni applicazione, allora la convergenza è lineare con rate ρ . Questo fattore è il raggio spettrale della Jacobiana di $\mathcal{M}$ in $\mathbf{w}^*$.

4 Il problema “vero” che IRLS risolve: la versione smussata

La soglia ε in (2) non è solo un trucco numerico: cambia la funzione obiettivo. Cerchiamo la funzione liscia ψ_ε il cui maggiorante quadratico ha esattamente i pesi $1/\max(|w_i|, \varepsilon)$. Imponendo che la derivata di ψ_ε sia $\lambda w_i / \max(|w_i|, \varepsilon)$ si ottiene

$$\psi_\varepsilon(t) = \begin{cases} |t|, & |t| > \varepsilon, \\ \frac{t^2}{2\varepsilon} + \frac{\varepsilon}{2}, & |t| \leq \varepsilon, \end{cases} \quad (5)$$

cioè una smussatura di tipo Huber del valore assoluto (lineare lontano da 0, quadratica in un intorno di 0, raccordata in modo C^1). Il problema effettivamente risolto da IRLS è

$$\min_{\mathbf{w}} f_\varepsilon(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \sum_{i=1}^H \psi_\varepsilon(w_i). \quad (6)$$

Il minimo di f_ε dista dal minimo del LASSO originale di $O(\varepsilon)$ in valore obiettivo, e lo recupera per $\varepsilon \rightarrow 0$. Con $\varepsilon = 10^{-8}$ la differenza è sotto la soglia di rilevanza rispetto a un solver di riferimento.

Proposizione 1 (Forte convessità). *Se $\mathbf{X}$ ha rango colonna pieno, allora $\mathbf{A} = \mathbf{X}^\top \mathbf{X} \succ 0$ e f_ε è fortemente convessa, quindi ha un unico minimizzatore $\mathbf{w}^*$.*

Dimostrazione. Per ogni $\mathbf{v} \neq \mathbf{0}$ si ha $\mathbf{v}^\top \mathbf{A} \mathbf{v} = \|\mathbf{X}\mathbf{v}\|_2^2 > 0$ (rango pieno), dunque $\mathbf{A} \succ 0$. La parte di penalità $\sum_i \psi_\varepsilon(w_i)$ è convessa (ψ_ε è convessa: derivata seconda 0 o $1/\varepsilon$, mai negativa). Somma di una funzione fortemente convessa e di una convessa è fortemente convessa; l'unicità del minimo segue. $\square$

La Hessiana del problema smussato è

$$\nabla^2 f_\varepsilon(\mathbf{w}) = \mathbf{A} + \lambda \operatorname{diag}(\psi_\varepsilon''(w_i)), \quad \psi_\varepsilon''(t) = \begin{cases} 0, & |t| > \varepsilon \quad (\text{tratto lineare}), \\ 1/\varepsilon, & |t| < \varepsilon \quad (\text{tratto quadratico}). \end{cases} \quad (7)$$

È qui che si gioca tutto: **sulle componenti attive** ($|w_i| > \varepsilon$) la funzione vera $|w_i|$ è una retta, curvatura nulla; **sulle componenti schiacciate a zero** ($|w_i| < \varepsilon$, “pinned”) la curvatura è $1/\varepsilon$.

5 La Jacobiana della mappa: derivazione da zero

Vogliamo $\nabla \mathcal{M}(\mathbf{w}^*)$. Partiamo da $\mathcal{M}(\mathbf{w}) = \mathbf{Q}(\mathbf{w})^{-1} \mathbf{b}$ e differenziamo. Usiamo l'identità $d(\mathbf{A}^{-1}) = -\mathbf{A}^{-1}(d\mathbf{A})\mathbf{A}^{-1}$:

$$d\mathcal{M} = -\mathbf{Q}^{-1}(d\mathbf{Q})\mathbf{Q}^{-1}\mathbf{b} = -\mathbf{Q}^{-1}(d\mathbf{Q})\mathbf{w}, \quad (8)$$

dove nell'ultimo passaggio abbiamo usato che nel punto fisso $\mathbf{Q}(\mathbf{w}^*)^{-1}\mathbf{b} = \mathbf{w}^*$.

Calcolo di $d\mathbf{Q}$. La matrice $\mathbf{Q}(\mathbf{w})$ è $\mathbf{A}$ (costante) più la diagonale $\lambda \operatorname{diag}(1/\max(|w_i|, \varepsilon))$. La derivata dell' i -esimo elemento diagonale rispetto a w_i :

$$\frac{d}{dw_i} \frac{1}{\max(|w_i|, \varepsilon)} = \begin{cases} -\frac{\operatorname{sign}(w_i)}{w_i^2}, & |w_i| > \varepsilon, \\ 0, & |w_i| < \varepsilon. \end{cases}$$

Quindi $d\mathbf{Q}$ è diagonale, con entrate non nulle solo sull'insieme attivo.

Il prodotto $(d\mathbf{Q}) \mathbf{w}^*$. Sull'insieme attivo l' i -esima componente è

$$[(d\mathbf{Q}) \mathbf{w}^*]_i = \lambda \left(-\frac{\text{sign}(w_i^*)}{(w_i^*)^2} \right) (w_i^*) dw_i = -\lambda \frac{\text{sign}(w_i^*)}{w_i^*} dw_i = -\frac{\lambda}{|w_i^*|} dw_i,$$

mentre sull'insieme pinned è 0. In forma matriciale

$$(d\mathbf{Q}) \mathbf{w}^* = -\lambda \underbrace{\text{diag}\left(\frac{1}{|w_i^*|} \text{ (attive)}, 0 \text{ (pinned)}\right)}_{=\mathbf{Q}(\mathbf{w}^*) - \nabla^2 f_\varepsilon(\mathbf{w}^*)} d\mathbf{w}. \quad (9)$$

L'uguaglianza con $\mathbf{Q}(\mathbf{w}^*) - \nabla^2 f_\varepsilon(\mathbf{w}^*)$ si verifica confrontando (3) con (7):

$$\mathbf{Q}(\mathbf{w}^*) - \nabla^2 f_\varepsilon(\mathbf{w}^*) = \lambda \text{diag}\left(\frac{1}{\max(|w_i^*|, \varepsilon)} - \psi''_\varepsilon(w_i^*)\right) = \lambda \text{diag}\left(\underbrace{\frac{1}{|w_i^*|}}_{\text{attive}} - 0, \underbrace{\frac{1}{\varepsilon} - \frac{1}{\varepsilon}}_{\text{pinned}}\right).$$

Sostituendo (9) in (8):

$$d\mathcal{M} = -\mathbf{Q}^{-1} \left(-(\mathbf{Q} - \nabla^2 f_\varepsilon) d\mathbf{w} \right) = \mathbf{Q}^{-1} (\mathbf{Q} - \nabla^2 f_\varepsilon) d\mathbf{w} = (\mathbf{I} - \mathbf{Q}^{-1} \nabla^2 f_\varepsilon) d\mathbf{w}.$$

$$\boxed{\nabla \mathcal{M}(\mathbf{w}^*) = \mathbf{I} - \mathbf{Q}(\mathbf{w}^*)^{-1} \nabla^2 f_\varepsilon(\mathbf{w}^*)} \quad (10)$$

È *esattamente* la matrice di contrazione di una iterazione Majorization–Minimization. Non l'abbiamo presa per citazione: l'abbiamo *derivata* differenziando la mappa.

Osservazione 1 (Quando $\mathcal{M}$ è derivabile). Il calcolo sopra usa ψ''_ε , che ha un salto in $|w_i| = \varepsilon$. La derivazione è quindi lecita finché *nessuna* componente di $\mathbf{w}^*$ giace esattamente sul bordo $|w_i^*| = \varepsilon$ (le attive stanno strettamente sopra, le pinned strettamente sotto). In quel caso $\mathcal{M}$ e f_ε sono C^1 in $\mathbf{w}^*$. È un'ipotesi tecnica generica (insieme di misura nulla), ma è un'*assunzione*, non un teorema — vedi la sezione 9.

6 Dimostrazione che il raggio spettrale e' minore di 1

Questo è il risultato centrale. Poniamo per brevità

$$\mathbf{B} := \mathbf{Q}(\mathbf{w}^*), \quad \mathbf{H} := \nabla^2 f_\varepsilon(\mathbf{w}^*), \quad \nabla \mathcal{M}(\mathbf{w}^*) = \mathbf{I} - \mathbf{B}^{-1} \mathbf{H}.$$

Passo 0 — entrambe SPD. $\mathbf{B} = \mathbf{A} + \lambda \text{diag}(1/\max(|w_i^*|, \varepsilon))$: somma di $\mathbf{A} \succ 0$ e di una diagonale strettamente positiva, quindi $\mathbf{B} \succ 0$. $\mathbf{H} = \mathbf{A} + \lambda \text{diag}(\psi''_\varepsilon \geq 0)$: somma di $\mathbf{A} \succ 0$ e di una diagonale $\succeq 0$, quindi $\mathbf{H} \succ 0$. Entrambe sono simmetriche definite positive.

Passo 1 — gli autovalori di $\mathbf{B}^{-1} \mathbf{H}$ sono reali e positivi. $\mathbf{B}^{-1} \mathbf{H}$ in generale non è simmetrica, ma è *simile* a una matrice simmetrica:

$$\mathbf{B}^{-1} \mathbf{H} = \mathbf{B}^{-1/2} (\mathbf{B}^{-1/2} \mathbf{H} \mathbf{B}^{-1/2}) \mathbf{B}^{1/2}, \quad \mathbf{S} := \mathbf{B}^{-1/2} \mathbf{H} \mathbf{B}^{-1/2}.$$

$\mathbf{S}$ è simmetrica e, essendo $\mathbf{H} \succ 0$, è anche definita positiva. Matrici simili hanno gli stessi autovalori, dunque gli autovalori di $\mathbf{B}^{-1} \mathbf{H}$ coincidono con quelli di $\mathbf{S}$: sono **reali e** > 0 . Chiamiamoli $\mu_1 \geq \dots \geq \mu_H > 0$.

Passo 2 — limite superiore: $\mu_i \leq 1$. Vale $\mathbf{S} \preceq \mathbf{I}$ se e solo se $\mathbf{H} \preceq \mathbf{B}$, cioè $\mathbf{B} - \mathbf{H} \succeq 0$. Ma dalla sezione 5,

$$\mathbf{B} - \mathbf{H} = \lambda \operatorname{diag} \left(\underbrace{\frac{1}{|w_i^*|}}_{\text{attive} > 0}, \underbrace{0}_{\text{pinned}} \right) \succeq 0, \quad (11)$$

una matrice diagonale con entrate ≥ 0 , quindi semidefinita positiva. Dunque $\mathbf{H} \preceq \mathbf{B}$, quindi $\mathbf{S} \preceq \mathbf{I}$, quindi $\mu_i \leq 1$ per ogni i .

Passo 3 — conclusione. Combinando i passi 1–2: $\mu_i \in (0, 1]$. Gli autovalori di $\nabla \mathcal{M}(\mathbf{w}^*) = \mathbf{I} - \mathbf{B}^{-1} \mathbf{H}$ sono allora $1 - \mu_i \in [0, 1)$. Il raggio spettrale è il massimo modulo:

$$\rho(\nabla \mathcal{M}(\mathbf{w}^*)) = \max_i |1 - \mu_i| = 1 - \mu_{\min} < 1,$$

dove $\mu_{\min} = \mu_H > 0$ è il più piccolo autovalore di $\mathbf{B}^{-1} \mathbf{H}$. Poiché $\mu_{\min} > 0$ *strettamente*, si ha $\rho < 1$ strettamente. $\square$

Conseguenza (teorema di Ostrowski). Per un’iterazione a punto fisso $\mathbf{w}_{k+1} = \mathcal{M}(\mathbf{w}_k)$ con $\mathcal{M}$ di classe C^1 in $\mathbf{w}^*$ e $\rho(\nabla \mathcal{M}(\mathbf{w}^*)) < 1$, il punto $\mathbf{w}^*$ è un *punto di attrazione*: esiste un intorno da cui IRLS converge a $\mathbf{w}^*$, e la convergenza è **lineare** con rate asintotico esattamente $\rho(\nabla \mathcal{M}(\mathbf{w}^*))$. (Ostrowski, in Ortega–Rheinboldt, *Iterative Solution of Nonlinear Equations*.)

7 Perché il rate è vicino a 1 (cioè: perché IRLS è lento)

Abbiamo $\rho = 1 - \mu_{\min}$, quindi “vicino a 1” equivale a “ $\mu_{\min}$ piccolo”. Il più piccolo autovalore generalizzato è

$$\mu_{\min} = \min_{\mathbf{v} \neq \mathbf{0}} \frac{\mathbf{v}^\top \mathbf{H} \mathbf{v}}{\mathbf{v}^\top \mathbf{B} \mathbf{v}}.$$

Consideriamo una direzione $\mathbf{v}$ concentrata su una componente attiva con $|w_i^*|$ piccolo. Su quella componente $\mathbf{H}$ ha solo il contributo di $\mathbf{A}$ (curvatura 0 dalla penalità, perché $|w_i|$ è affine lì), mentre $\mathbf{B}$ ha in più il termine $\lambda/|w_i^*|$, che è *grande* quando $|w_i^*|$ è piccolo. Quindi

$$\frac{\mathbf{v}^\top \mathbf{H} \mathbf{v}}{\mathbf{v}^\top \mathbf{B} \mathbf{v}} \approx \frac{\mathbf{v}^\top \mathbf{A} \mathbf{v}}{\mathbf{v}^\top \mathbf{A} \mathbf{v} + \lambda \sum_i v_i^2 / |w_i^*|} \xrightarrow{|w_i^*| \rightarrow 0} 0.$$

Meccanismo della lentezza. IRLS modella $|w_i|$ con una parabola. Sulle componenti attive $|w_i|$ è una retta (curvatura nulla), ma il modello quadratico $\mathbf{B}$ ci mette curvatura $\lambda/|w_i^*|$: *tanta* dove la componente è piccola. Questo disallineamento tra modello e funzione vera spinge $\mu_{\min} \rightarrow 0$ e quindi $\rho \rightarrow 1$. In una frase: *IRLS è lento proprio dove il LASSO è lineare*. Empiricamente $\rho \approx 0.99$, e quasi indipendente da ε .

Caso limite opposto, utile per intuizione: se fosse $\mathbf{B} = \mathbf{H}$ avremmo $\nabla \mathcal{M} = \mathbf{I} - \mathbf{I} = \mathbf{0}$, rate 0, convergenza in un passo (è ciò che fa il metodo di Newton). IRLS è lento esattamente nella misura in cui il suo modello $\mathbf{B}$ si discosta dalla vera Hessiana $\mathbf{H}$.

8 Perché la figura sembra “non lineare”

Su un semilog del gap rispetto al LASSO esatto f^* contro k , la curva *non* è una singola retta. Si sovrappongono tre regimi:

1. **Transiente iniziale veloce:** le prime iterazioni chiudono la maggior parte del gap (fase pre-asintotica, tratto ripido).

2. **Coda lineare lenta:** subentra il rate vero $\rho \approx 0.99$, una retta quasi orizzontale; per vederla come retta servono *molte* iterazioni.
3. **Pavimento di smussatura:** il gap rispetto a f^* non scende sotto $O(\varepsilon) \approx 10^{-8}$; con poche iterazioni la curva sbatte sul pavimento *prima* che la coda lineare sia visibile.

Sommati, danno una curva concava che a occhio sembra sublineare. La verifica corretta è misurare il gap rispetto al minimo *smussato* f_ε^* (non f^*), su molte iterazioni: lì il rapporto per-iterazione g_{k+1}/g_k *si stabilizza* attorno a ≈ 0.995 e oscilla senza crescere $\Rightarrow$ lineare, solo lento. Una sublineare avrebbe g_{k+1}/g_k in crescita monotona verso 1.

9 Avvertenze critiche (limiti della dimostrazione)

Da tenere a mente, anche all'orale:

1. **Rate locale, non globale.** Ostrowski garantisce attrazione e rate lineare in un *intorno* di $\mathbf{w}^*$. La convergenza *globale* della successione si argomenta a parte (monotonia MM + forte convessità + coercività $\Rightarrow$ ogni punto di accumulazione è il minimo unico). Sono due affermazioni distinte.
2. **Ipotesi “nessuna componente sul bordo”** $|w_i^*| = \varepsilon$. Necessaria per la C^1 -regolarità di $\mathcal{M}$; è generica ma assunta, non dimostrata sul nostro problema.
3. $\rho \approx 0.99$ **misurato su una sola istanza.** Per robustezza andrebbe confermato su piu' dataset/seed; la (quasi) indipendenza da ε è verificata, la variabilità tra istanze no. Ridurre il claim oppure rieseguire.
4. **Citazione da non usare.** Il rate lineare *non* segue dal Teorema 5.3 di Daubechies et al. (quello assume la *null space property* per sparse recovery *sottodeterminato*): il nostro regime è *sovradeterminato* e fortemente convesso. La giustificazione corretta è quella di questo documento: forte convessità del problema smussato + teoria locale standard MM/Ostrowski.
5. **Gap relativi.** Per i confronti numerici usare gap *relativi* ($|f - f^*|/|f^*|$): un gap assoluto di 10^{-6} è minuscolo se $f^* \sim 10^4$ e enorme se $f^* \sim 10^{-3}$.

Riepilogo in cinque frasi (per l'orale)

1. IRLS è un'iterazione a punto fisso $\mathcal{M}(\mathbf{w}) = \mathbf{Q}(\mathbf{w})^{-1}\mathbf{b}$, MM su un problema smussato f_ε (Huber sul termine L_1), fortemente convesso perché $\mathbf{X}$ ha rango pieno.
2. Differenziando la mappa nel punto fisso si ottiene $\nabla\mathcal{M}(\mathbf{w}^*) = \mathbf{I} - \mathbf{Q}(\mathbf{w}^*)^{-1}\nabla^2 f_\varepsilon(\mathbf{w}^*)$, la matrice di contrazione MM.
3. $\mathbf{Q}(\mathbf{w}^*)$ e $\nabla^2 f_\varepsilon(\mathbf{w}^*)$ sono SPD e la loro differenza è $\lambda \text{diag}(1/|w_i^*|)$ sulle attive, 0 sulle pinned, quindi $\succeq 0$.
4. Ne segue che gli autovalori di $\mathbf{Q}^{-1}\nabla^2 f_\varepsilon$ stanno in $(0, 1]$, quelli di $\nabla\mathcal{M}$ in $[0, 1)$, dunque $\rho(\nabla\mathcal{M}(\mathbf{w}^*)) = 1 - \mu_{\min} < 1$: per Ostrowski, convergenza lineare locale.
5. Il rate è vicino a 1 perché sulle componenti attive $|w_i|$ ha curvatura nulla mentre il modello quadratico no: $\mu_{\min} \rightarrow 0$ quando $|w_i^*| \rightarrow 0$. Quindi IRLS converge linearmente ma lentamente; la figura sembra sublineare per transiente + pavimento di smussatura, non perché lo sia.