

Teorema 3.1 (convergenza di SGPTL), spiegato passo passo

Il deflected subgradient con Polyak step e target level sul problema ELM + LASSO:
statement, dimostrazione, e ogni passaggio ricostruito da zero

Note di studio per l'orale — progetto CM (ELM + LASSO, algoritmo A2)

8 giugno 2026

Sommario

Questo documento ricostruisce, partendo dai fondamenti e senza dare nulla per scontato, il Teorema 3.1 del report (sezione 3.5.2, “Convergence of SGPTL”) e la sua dimostrazione. L’obiettivo non è ripetere il report ma renderne ogni riga *discutibile all’orale*: ogni oggetto che compare nello statement (subgradiente, deflection, Polyak step, target level, valore-record, proprietà di Fejér) è introdotto prima di essere usato, e ogni passaggio della prova è giustificato per intero, incluse le due derivazioni che il report rimanda in appendice. Alla fine c’è una sezione di *domande tipiche del professore* con le risposte, costruite intorno ai punti dove la dimostrazione è davvero delicata — in particolare il punto in cui un argomento “ovvio” (la limitatezza degli iterati) sarebbe *sbagliato* se motivato come si farebbe per un metodo di discesa.

La fonte teorica del teorema è il paper di D’Antonio–Frangioni 2009 (citato come `dantonio2009deflected` nel report); le slide del corso di Frangioni sul nonsmooth sono la fonte secondaria. I numeri di equazione/teorema fra parentesi “(3.17)”, “(2.9)”, “Cor. 3.2”, “Thm 3.5/3.7”, “Lemma 3.8” si riferiscono a quel paper; “eq. (3.7)” e “eq. (3.8)” del report sono il rate e la disuguaglianza per-step.

Indice

1	Mappa: cosa dimostra il teorema e perché conta	2
2	Prerequisiti: tutti gli oggetti che compaiono nel teorema	2
2.1	Il problema: ELM + LASSO	3
2.2	Subgradiente e subdifferenziale	3
2.3	Lipschitzianità locale e limitatezza dei subgradienti	3
2.4	Il Polyak step e la “disuguaglianza fondamentale”	4
2.5	La deflection: memoria nella direzione	4
2.6	Il target level: come aggirare la non-conoscenza di f^*	5
2.7	Valore-record e proprietà di Fejér (il punto delicato)	5
3	Lo statement del Teorema 3.1	6
4	La dimostrazione, passo per passo	6
4.1	(0) Il dizionario di notazione — da leggere prima di tutto	6
4.2	(a) Condizione (2.13): consistenza della deflection	7
4.3	(b) Condizione (3.5): il bound uniforme sullo stepsize	7
4.4	(c) Condizione (3.26): il target-level scende correttamente	8
4.5	(d) Limitatezza dei subgradienti — il cuore della prova	8
4.6	(e) Conclusione di convergenza via Teorema 3.7	11
4.7	(f) La disuguaglianza per-step (eq. 3.8 del report)	11

4.8	(g) Telescoping: da dove nasce il $1/\sqrt{k}$	12
4.9	(h) Conteggio iterazioni e il prezzo $1/\gamma_{\min}^2$	13
5	Le due derivazioni che il report manda in appendice	13
5.1	Appendice D — la per-step (3.8) per intero	13
5.2	Appendice E — la formula chiusa di γ^*	14
6	Verifica delle ipotesi sul problema specifico ELM+LASSO	14
7	Cosa deve combaciare con gli esperimenti	14
8	Domande tipiche del professore, con risposte	14

1 Mappa: cosa dimostra il teorema e perché conta

Il Teorema 3.1 fa due affermazioni *distinte*, e all’orale è bene tenerle separate:

- (I) **Convergenza (qualitativa).** I *valori-record* $\bar{f}_i = \min_{h \leq i} f(\mathbf{w}_h)$ generati dall’algoritmo SGPTL convergono al minimo f^* . Cioè: prima o poi il miglior valore di funzione visto fin lì si avvicina quanto si vuole all’ottimo.
- (II) **Rate (quantitativo).** Sotto il regime asintotico (quando il target-level si è “affilato” su f^*), il gap del record decresce come

$$\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\gamma_{\min} \sqrt{k+1}},$$

cioè un rate *sublineare* $O(1/\sqrt{k})$. Equivalentemente: per ottenere $\bar{f}_k - f^* \leq \varepsilon$ servono $O(L^2/(\gamma_{\min}^2 \varepsilon^2))$ iterazioni.

Perché ci interessa, in una frase. Il problema ELM+LASSO è convesso ma *non liscio* (per via del termine $\lambda_{\text{LASSO}} \|\mathbf{w}\|_1$): il gradiente non esiste ovunque, quindi non possiamo usare metodi del second’ordine o gradiente liscio. La classe giusta di metodi è quella dei *subgradient methods*. Il teorema dice che la nostra variante (deflected + Polyak + target level) converge, e che il suo rate $O(1/\sqrt{k})$ è *ottimale* per metodi del prim’ordine su problemi convessi nonsmooth (il lower bound $\Omega(L^2/\varepsilon^2)$ non è migliorabile). Il prezzo della deflection è il fattore $1/\gamma_{\min}^2$ davanti, non l’ordine.

La dimostrazione **non riparte da zero**: il paper di D’Antonio–Frangioni ha già un teorema generale di convergenza (il loro Teorema 3.7) per una famiglia di metodi. La nostra prova è quindi un lavoro di *verifica delle ipotesi*: si controlla che il nostro Algoritmo soddisfi le tre condizioni del loro teorema (le condizioni (2.13), (3.5), (3.26)), si invoca il loro risultato per la convergenza, e poi si *deriva a parte* il rate ricalcando una disuguaglianza per-step del paper. Questo schema — “verifico le ipotesi di un teorema citato, poi leggo la tesi” — è esattamente quello che il prof vuole vedere fatto con rigore, perché è qui che si nascondono gli errori (usare un teorema le cui ipotesi non valgono sul *nostro* problema).

2 Prerequisiti: tutti gli oggetti che compaiono nel teorema

Questa sezione è lunga ma è il vero investimento: se padroneggi questi otto oggetti, la prova diventa una sequenza di passaggi quasi meccanici.

2.1 Il problema: ELM + LASSO

Stiamo minimizzando, sui pesi del layer di output $\mathbf{w} \in \mathbb{R}^H$ di una Extreme Learning Machine,

$$f(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda_{\text{LASSO}} \|\mathbf{w}\|_1, \quad (1)$$

dove $\mathbf{X} \in \mathbb{R}^{M \times H}$ è la matrice delle feature nascoste (fissa: l'hidden layer della ELM è random e congelato), $\mathbf{y} \in \mathbb{R}^M$ il target, $\lambda_{\text{LASSO}} > 0$ il peso della penalità L_1 .

Due proprietà di f che useremo continuamente:

- **f è convessa.** Somma di un quadratico convesso (la matrice Hessiana del termine liscio è $\mathbf{X}^\top \mathbf{X} \succeq 0$) e di una norma $\|\cdot\|_1$, che è convessa. La somma di funzioni convesse è convessa.
- **f è nonsmooth.** Il termine $\|\mathbf{w}\|_1 = \sum_j |w_j|$ ha uno spigolo in ogni punto dove qualche coordinata $w_j = 0$: lì il gradiente non esiste. È proprio il prezzo della sparsità.
- **f è coerciva** (Proposizione 1.1 del report): $f(\mathbf{w}) \rightarrow +\infty$ quando $\|\mathbf{w}\| \rightarrow \infty$. Questo garantisce che il minimo $f^* = \min f$ esista, sia finito ($> -\infty$) e sia raggiunto in qualche $\mathbf{w}^*$. È la *prima ipotesi* del teorema, e su ELM+LASSO è *verificata*, non assunta.

2.2 Subgradiente e subdifferenziale

Per una funzione liscia, il gradiente $\nabla f(\mathbf{w})$ definisce l'iperpiano tangente che sta sotto il grafico. Quando f non è derivabile in $\mathbf{w}$, di iperpiani-supperto ce n'è tutto un fascio: ognuno è un *subgradiente*.

Definizione 1 (Subgradiente). $\mathbf{g}$ è un subgradiente di f convessa in $\mathbf{w}$ se

$$f(\mathbf{z}) \geq f(\mathbf{w}) + \langle \mathbf{g}, \mathbf{z} - \mathbf{w} \rangle \quad \text{per ogni } \mathbf{z}. \quad (2)$$

L'insieme di tutti i subgradienti in $\mathbf{w}$ è il *subdifferenziale* $\partial f(\mathbf{w})$.

La (2) è la *subgradient inequality* e sarà il motore di tutta la prova: dice che dal punto $\mathbf{w}$, muovendosi verso un qualunque $\mathbf{z}$, la funzione cresce almeno quanto predice il subgradiente. Conseguenza che useremo: ponendo $\mathbf{z} = \mathbf{w}^*$,

$$\langle \mathbf{g}, \mathbf{w} - \mathbf{w}^* \rangle \geq f(\mathbf{w}) - f(\mathbf{w}^*) = f(\mathbf{w}) - f^* \geq 0. \quad (3)$$

Cioè il subgradiente forma un angolo acuto con la direzione $\mathbf{w} - \mathbf{w}^*$ che punta *via* dall'ottimo: $-\mathbf{g}$ è una direzione di discesa “verso” $\mathbf{w}^*$ nel senso della distanza. Questo è il motivo profondo per cui i subgradient methods funzionano.

Subdifferenziale di ELM+LASSO. Per la (1), sommando la parte liscia (gradiente classico) e la parte L_1 (subdifferenziale del valore assoluto),

$$\partial f(\mathbf{w}) = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda_{\text{LASSO}} \partial \|\mathbf{w}\|_1, \quad \partial |w_j| = \begin{cases} \{\text{sign}(w_j)\} & w_j \neq 0, \\ [-1, 1] & w_j = 0. \end{cases} \quad (4)$$

L'algoritmo sceglie *un* rappresentante (non serve tutto l'insieme): il *sign-based*

$$\mathbf{g} = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda_{\text{LASSO}} \mathbf{s}, \quad s_j = \text{sign}(w_j), \quad \text{sign}(0) := 0. \quad (5)$$

La convenzione $\text{sign}(0) = 0$ è lecita perché $0 \in [-1, 1] = \partial|0|$, quindi $\mathbf{g}$ è un subgradiente *ammissibile*. Il teorema chiede solo ammissibilità, non che $\mathbf{g}$ sia l'elemento di norma minima.

2.3 Lipschitzianità locale e limitatezza dei subgradienti

Fatto (slide 9 del corso, parte smooth). Una funzione convessa e *finita su tutto* $\mathbb{R}^H$ è automaticamente *localmente Lipschitz*. Conseguenza operativa: il suo subdifferenziale ∂f manda insiemi limitati in insiemi limitati. In altre parole, se gli iterati $\{\mathbf{w}_i\}$ restano in un insieme limitato, allora $\|\mathbf{g}_i\|_2 \leq L$ per una costante L finita.

Questo è il meccanismo che produce la costante L del teorema. **Attenzione:** la limitatezza dei subgradienti *non è gratis*, dipende dal fatto che gli iterati stiano in un limitato. Provare *quello* è il passaggio più sottile della dimostrazione (Sezione 2.7 e 4.5).

2.4 Il Polyak step e la “disuguaglianza fondamentale”

Partiamo dal subgradient method puro: $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{g}_i$. Quanto vale la distanza dall’ottimo dopo un passo? Espandendo il quadrato e usando la subgradient inequality (3):

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - 2\alpha_i(f(\mathbf{w}_i) - f^*) + \alpha_i^2 \|\mathbf{g}_i\|_2^2. \quad (6)$$

Questa è la *disuguaglianza fondamentale* (slide 10). Il lato destro è una parabola in α_i : per far scendere il più possibile la distanza dall’ottimo si minimizza in α_i , ottenendo lo *stepsize di Polyak*

$$\alpha_i^* = \frac{f(\mathbf{w}_i) - f^*}{\|\mathbf{g}_i\|_2^2}. \quad (7)$$

È “il passo giusto”: grande quando siamo lontani dall’ottimo (gap $f(\mathbf{w}_i) - f^*$ grande), piccolo quando siamo vicini. Il problema pratico: f^* **non lo conosciamo**. Lo risolve il target level (Sezione 2.6).

2.5 La deflection: memoria nella direzione

Il subgradient puro *zig-zaga* su problemi mal condizionati (rimbalza fra le pareti di una “valle” stretta), perché è *senza memoria*: ogni passo dimentica i precedenti. La deflection mescola il subgradiente corrente con la direzione precedente:

$$\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1} \quad (i \geq 1), \quad \mathbf{d}_0 = \mathbf{g}_0, \quad (8)$$

con $\gamma_i \in [\gamma_{\min}, 1]$ il *parametro di deflection*. L’update diventa $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i$. Interpretazione: $\gamma_i = 1$ riproduce il subgradiente puro; $\gamma_i < 1$ tiene memoria di dove stavamo andando e smorza l’oscillazione.

Come si sceglie γ_i . Si prende il γ che *minimizza* $\|\mathbf{d}_i\|_2^2$ su $[\gamma_{\min}, 1]$. Motivo: $\|\mathbf{d}_i\|_2^2$ è il *denominatore* del Polyak step, quindi minimizzarlo *massimizza* la lunghezza del passo. È un problema quadratico in γ con soluzione chiusa (derivata per intero nell’Appendice E del report, ricostruita qui in Sezione 5.2):

$$\gamma^* = \frac{\|\mathbf{d}_{i-1}\|_2^2 - \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle}{\|\mathbf{g}_i - \mathbf{d}_{i-1}\|_2^2}, \quad \gamma_i = \min(1, \max(\gamma_{\min}, \gamma^*)). \quad (9)$$

Il clip a $\gamma_{\min} > 0$ è un’aggiunta nostra, non del paper, ed è cruciale per la prova. Il greedy (9) su $[0, 1]$ può far tendere $\gamma_i \rightarrow 0^+$ quando i subgradienti consecutivi si allineano vicino alla stazionarietà. Ma la condizione (3.5) del paper richiede un bound *uniforme* $\beta_i \geq \beta^* > 0$ sul moltiplicatore di passo. Proiettare su $[\gamma_{\min}, 1]$ fornisce esattamente quel bound con $\beta^* = \gamma_{\min}$. Senza il floor, l’ipotesi del teorema citato non sarebbe verificata. Questo è un punto da saper difendere all’orale (vedi Sezione 8, D4).

Proprietà che riuseremo. Poiché $\gamma_i \in (0, 1]$, ogni $\mathbf{d}_i$ è una *combinazione convessa* di subgradianti calcolati lungo la run (lo si vede per induzione sulla ricorrenza (8)). Conseguenza:

$$\|\mathbf{d}_i\|_2 \leq \max_{h \leq i} \|\mathbf{g}_h\|_2 \leq L. \quad (10)$$

2.6 Il target level: come aggirare la non-conoscenza di f^*

Nel Polyak step (7) sostituiamo f^* con un *target level* $f_{\text{ref}} - \delta$:

- f_{ref} = miglior valore di funzione trovato fin qui (“reference”);
- $\delta > 0$ = stima del gap residuo $f_{\text{ref}} - f^*$ ancora da colmare.

Lo step effettivamente usato (riga 13 dell’algoritmo, stepsize-restricted) è

$$\alpha_i = \frac{\beta_i (f(\mathbf{w}_i) - (f_{\text{ref}} - \delta))}{\|\mathbf{d}_i\|_2^2}, \quad \beta_i = \min(\beta, \gamma_i), \quad \beta = 1. \quad (11)$$

Il rischio e il rimedio. Se il target è troppo aggressivo, $f_{\text{ref}} - \delta < f^*$, il test di sufficiente discesa $f(\mathbf{w}_{i+1}) \leq f_{\text{ref}} - \delta/2$ diventa *insoddisfacibile* (nessun iterato può scendere sotto f^*), f_{ref} non si aggiorna mai e l’algoritmo si blocca in silenzio. Il rimedio è un *contatore di pazienza* $r_i = \sum_j \alpha_j \|\mathbf{d}_j\|$ (lo spostamento accumulato dall’ultimo aggiornamento di f_{ref}): quando r_i supera una soglia R senza che sia scattata la discesa sufficiente, si *contrae* $\delta \mapsto \rho\delta$ con $\rho \in (0, 1)$ e si azzera r . Le contrazioni ripetute mandano $\delta \rightarrow 0$, e prima o poi $f_{\text{ref}} - \delta \geq f^*$ torna feasible.

Lemma 3.8 del paper è proprio il certificato che questa strategia di aggiornamento di (f_{ref}, δ) — test di discesa sufficiente, test di infeasibility su $r > R$, contatore r — garantisce $\liminf_k \delta_k = 0$ e la condizione di serie (3.25). Le righe 16–21 dell’algoritmo *sono* questa strategia, parola per parola. Lo useremo nel punto (c) della prova.

2.7 Valore-record e proprietà di Fejér (il punto delicato)

Definizione 2 (Valore-record). $\bar{f}_i = \min_{h \leq i} f(\mathbf{w}_h)$ è il miglior valore di funzione visto fino all’iterazione i . È *monotono non crescente* per costruzione, anche se $f(\mathbf{w}_i)$ non lo è.

SGPTL non è un metodo di discesa. Per via della deflection e del target level, in generale $f(\mathbf{w}_{i+1}) \not\leq f(\mathbf{w}_i)$: la successione dei valori *oscilla*. Questo ha una conseguenza pesantissima per la prova, ed è l’errore-tipo che il prof cerca: *non si può* dimostrare che gli iterati sono limitati dicendo “stanno in un sublevel set $\{f \leq f(\mathbf{w}_0)\}$ ”. Quel ragionamento vale solo per metodi monotoni ($f(\mathbf{w}_{i+1}) \leq f(\mathbf{w}_i)$), che SGPTL non è.

Lo strumento corretto è la *Fejér monotonicity*: non è f a decrescere, è la *distanza dall’ottimo* $\|\mathbf{w}_i - \mathbf{w}^*\|_2$ a essere (asintoticamente) non crescente.

Definizione 3 (Fejér-monotonia, e la versione asintotica). $\{\mathbf{w}_i\}$ è *Fejér-monotona* rispetto a $\mathbf{w}^*$ se $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2$ per ogni i . In tal caso tutti gli iterati stanno nella palla di centro $\mathbf{w}^*$ e raggio $\|\mathbf{w}_0 - \mathbf{w}^*\|_2$, e la successione è limitata.

SGPTL realizza solo la versione *asintotica*: la monotonia vale da un indice finito $\bar{i}$ in poi, non da $\mathbf{w}_0$. Allora la limitatezza si ottiene in due pezzi: la *coda* $\{\mathbf{w}_i\}_{i \geq \bar{i}}$ sta nella palla di raggio $\|\mathbf{w}_{\bar{i}} - \mathbf{w}^*\|_2$ (Fejér), e il *transiente* $\{\mathbf{w}_0, \dots, \mathbf{w}_{\bar{i}-1}\}$ è un insieme *finito* di punti finiti, quindi limitato. Unione di due limitati $\Rightarrow \{\mathbf{w}_i\}$ limitata. (**La spiegazione elementare** di “insieme finito $\Rightarrow$ limitato”, con il controesempio sul caso infinito, è svolta passo per passo nel Fatto 2 di Sezione 4.5; qui è solo enunciata.)

Perché non da w_0 ? Il colpevole è il target level. La monotonia parte solo da $\bar{v}$ perché all’inizio il target $f_{\text{ref}} - \delta$ può stare *sotto* f^* (“overshooting”): $\delta_0 = c f(w_0)$ è scelto senza conoscere f^* , quindi può sovrastimare il gap. In quel regime il passo di Polyak punta a un valore irraggiungibile ed è troppo lungo, e la distanza all’ottimo *può crescere*. Cosa garantisce il transiente allora? Non la monotonia, ma la sua *finiteness*: la δ -contrazione del Lemma 3.8 manda $\delta \rightarrow 0$; poiché $f_{\text{ref}} \geq f^*$ sempre, appena δ è piccolo si ha $f_{\text{ref}} - \delta \geq f^*$ *stabilmente*, e questo accade dopo un numero finito di contrazioni. Il conto quantitativo del segno è nel Fatto 2 di Sezione 4.5; la domanda d’orale dedicata è D8.

È da qui che esce la limitatezza degli iterati — e quindi, via Sezione 2.3, il bound $\|g_i\|_2 \leq L$. La disuguaglianza per-step (13) che dimostreremo è precisamente l’enunciato “la distanza al quadrato scende a ogni passo attivo *quando il target è feasible*”, cioè la proprietà di Fejér resa quantitativa.

3 Lo statement del Teorema 3.1

Teorema 1 (Convergenza di SGPTL, da dantonio2009deflected). *Sia $f : \mathbb{R}^H \rightarrow \mathbb{R}$ convessa con $f^* = \min_{w} f(w) > -\infty$ raggiunto in qualche w^* , e sia $\{w_i\}$ la successione generata dall’Algoritmo (SGPTL). Si assuma che i subgradienti incontrati lungo la run siano uniformemente limitati, $\|g_i\|_2 \leq L$, e che valga la regola stepsize-restricted $\beta_i \leq \gamma_i$ con $\gamma_i \geq \gamma_{\min} > 0$. Allora i valori-record $\bar{f}_i = \min_{h \leq i} f(w_h)$ convergono a f^* ; e una volta che la stima target-level si è affilata su f^* (cioè $\delta_k \rightarrow 0$ e $f_{\text{ref}}^k \rightarrow f^*$, garantito dal Lemma 3.8 del paper), il rate asintotico, derivato dalla (3.17) nella prova del Teorema 3.5 del paper, è*

$$\bar{f}_k - f^* \leq \frac{L \|w_0 - w^*\|_2}{\gamma_{\min} \sqrt{k+1}}, \quad (12)$$

e dunque la complessità worst-case per ottenere $\bar{f}_k - f^* \leq \varepsilon$ è $O(L^2/(\gamma_{\min}^2 \varepsilon^2))$.

Le tre ipotesi, e dove vengono verificate sul nostro problema.

- (H1) f convessa con minimo finito raggiunto $\Rightarrow$ vera su ELM+LASSO per *coercività* (Prop. 1.1). Vedi Sezione 2.1.
- (H2) subgradienti uniformemente limitati $\|g_i\|_2 \leq L \Rightarrow$ *non* è un’assunzione gratuita: si *dimostra* dentro la prova via Fejér + Lipschitz locale. Vedi Sezione 4.5. Questo è il cuore tecnico.
- (H3) stepsize-restricted $\beta_i \leq \gamma_i$ con $\gamma_i \geq \gamma_{\min} \Rightarrow$ vera per costruzione: $\beta_i = \min(1, \gamma_i)$ e il clip (9) tiene $\gamma_i \geq \gamma_{\min}$.

4 La dimostrazione, passo per passo

La struttura è: **(0)** dizionario di notazione fra paper e report; **(a)–(c)** verifica delle tre condizioni del Teorema 3.7 del paper; **(d)** limitatezza dei subgradienti (il pezzo che chiude il cerchio con (H2)); **(e)** conclusione di convergenza; **(f)** disuguaglianza per-step; **(g)** telescoping e nascita del $1/\sqrt{k}$; **(h)** conteggio iterazioni e fattore $1/\gamma_{\min}^2$.

4.1 (0) Il dizionario di notazione — da leggere prima di tutto

Trappola di notazione (il prof può chiederlo apposta). Nel paper di D’Antonio le

lettere greche *non* hanno lo stesso significato che nel report. La corrispondenza è:

$$\underbrace{\alpha_k^{\text{paper}}}_{\text{loro}} \leftrightarrow \underbrace{\gamma_i}_{\text{nostra deflection}}, \quad \beta_k^{\text{paper}} \leftrightarrow \beta_i, \quad \underbrace{\nu_k^{\text{paper}}}_{\text{loro}} \leftrightarrow \underbrace{\alpha_i}_{\text{nostro stepsize}}, \quad \mu^{\text{paper}} \leftrightarrow \rho,$$

con $X = \mathbb{R}^H$ (nessun vincolo) e $\lambda_k^{\text{paper}} \leftrightarrow f(\mathbf{w}_i) - (f_{\text{ref}}^k - \delta_k)$ (il gap al target, il segno di λ_k dice se il target è già stato raggiunto). Morale: la *loro* α è la *nostra* deflection γ , e il *loro* ν è il *nostro* stepsize α . Se confondi questi due all'orale, la prova diventa incomprensibile.

Inoltre il framework del paper è scritto per subgradienti σ_k -*inesatti* (con un errore d'oracolo $\sigma_k \geq 0$). Noi calcoliamo $\mathbf{g}_i$ *esattamente* via (5), quindi il parametro di inesattezza è $\sigma_k = 0$ (e $\sigma^* = 0$ asintoticamente). Questo semplifica diverse formule: tutti i termini d'errore d'oracolo spariscono.

4.2 (a) Condizione (2.13): consistenza della deflection

Attenzione: (2.13) parla di *direzioni*, non di stepsize. I tre oggetti che vi compaiono sono tutti *vettori* in $\mathbb{R}^H$, non scalari, e lo stepsize di Polyak non c'entra:

- $\mathbf{d}_k$ = la direzione di ricerca *usata* al passo k (la nostra $\mathbf{d}_i$); ci si muove lungo di essa, $\mathbf{x}_{k+1} = \mathbf{x}_k - \nu_k \mathbf{d}_k$;
- $\tilde{\mathbf{d}}_k$ = la direzione deflessa *grezza* $\gamma_k \mathbf{g}_k + (1 - \gamma_k) \mathbf{v}_k$, *prima* di un'eventuale proiezione (nel caso vincolato può puntare fuori dalla regione ammissibile e venire corretta, dando $\mathbf{d}_k \neq \tilde{\mathbf{d}}_k$);
- $\mathbf{v}_{k+1}$ = la *memoria* riciclata nella deflection del passo *successivo*, $\mathbf{d}_{k+1} = \gamma_{k+1} \mathbf{g}_{k+1} + (1 - \gamma_{k+1}) \mathbf{v}_{k+1}$: gioca il ruolo della nostra $\mathbf{d}_{i-1}$.

Lo stepsize è ν_k (il nostro α_i) e governa *quanto* ci si sposta, non *in che direzione*: non appare in (2.13). Nota la trappola di notazione: nel paper α_k è il parametro di *deflection* (la nostra γ), non lo stepsize.

La condizione del Lemma 2.4 del paper chiede $\mathbf{v}_{k+1} = \tilde{\mathbf{d}}_k$ ogni volta che $\mathbf{d}_k = \tilde{\mathbf{d}}_k$: cioè la *memoria* riciclata deve coincidere con la direzione grezza quando non c'è stata proiezione. È una condizione di *coerenza della memoria della deflection* — serve a garantire che la ricorrenza che mescola subgradiente e direzione precedente sia pulita (la memoria è davvero la direzione precedente, non una sua versione alterata dalla proiezione). Da noi il vincolo non c'è ($X = \mathbb{R}^H$), quindi *nessuna proiezione avviene*: $\mathbf{d}_k = \tilde{\mathbf{d}}_k$ a ogni iterazione, e l'algoritmo pone semplicemente $\mathbf{v}_{k+1} = \mathbf{d}_k (= \tilde{\mathbf{d}}_k)$. La (2.13) è quindi verificata *banalmente*: è solo la formalizzazione del fatto che la nostra ricorrenza $\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$ usa davvero $\mathbf{d}_{i-1}$ come memoria, senza alterarla. È il vantaggio di lavorare non vincolati.

4.3 (b) Condizione (3.5): il bound uniforme sullo stepsize

Tradotta nella nostra notazione, la (3.5) ha due clausole:

- se $\lambda_k \geq 0$ (target non ancora raggiunto), allora $\gamma_i \geq \beta_i \geq \beta^* > 0$ per una costante uniforme β^* indipendente da i ;
- se $\lambda_k < 0$ (target già raggiunto in $\mathbf{w}_i$), allora il passo è nullo, $\alpha_i = 0$.

Caso $\lambda_k > 0$. L'algoritmo pone $\beta_i = \min(1, \gamma_i)$ e il clip (9) tiene $\gamma_i \in [\gamma_{\min}, 1]$. Quindi $\beta_i \geq \gamma_{\min}$ per ogni i , e il bound uniforme vale con $\boxed{\beta^* = \gamma_{\min}}$. L'altra disuguaglianza $\gamma_i \geq \beta_i$ è semplicemente $\gamma_i \geq \min(1, \gamma_i)$, vera per definizione di $\min$.

Caso $\lambda_k \leq 0$. La safeguard numerica (punto 2 dei “Numerical safeguards” del report) salta l’iterazione con $\alpha_i = 0$, che è la seconda clausola alla lettera. *Qui si vede perché il clip a $\gamma_{\min}$ è indispensabile*: è ciò che produce il $\beta^* = \gamma_{\min} > 0$ richiesto.

4.4 (c) Condizione (3.26): il target-level scende correttamente

La (3.26) chiede o che $f_{\text{ref}}^\infty = f^* = -\infty$ (caso illimitato inferiormente) oppure che valgano insieme $\liminf_k \delta_k = 0$ e la condizione di serie (3.25), $\sum_k \lambda_k / \|\mathbf{d}_k\|^2 = \infty$.

Su ELM+LASSO $f^* > -\infty$ (coercività), quindi il primo ramo è *escluso* e ci serve il secondo. È esattamente ciò che fornisce il **Lemma 3.8** del paper: la strategia di aggiornamento di $(f_{\text{ref}}^k, \delta_k)$ — test di discesa sufficiente $f_{k+1} \leq f_{\text{ref}}^k - \delta_k/2$, test di infeasibility $r_k > R$, contatore r accumulato — garantisce sia $\liminf_k \delta_k = 0$ sia la (3.25). Le righe 16–21 dell’algoritmo implementano quella strategia *verbatim* (con $\mu \leftrightarrow \rho$), quindi la (3.26) vale.

4.5 (d) Limitatezza dei subgradienti — il cuore della prova

Questo è il passaggio che giustifica l’ipotesi (H2), e dove la *non-monotonicità* di SGPTL rende l’argomento delicato. Si articola in due fatti.

Fatto 1 — Lipschitz locale. f è convessa e finita su tutto $\mathbb{R}^H$, quindi localmente Lipschitz (slide 9, smooth), quindi ∂f manda limitati in limitati (Sezione 2.3). Dunque se $\{\mathbf{w}_i\}$ è limitata, $\|\mathbf{g}_i\|_2 \leq L$ segue. Resta da provare che $\{\mathbf{w}_i\}$ è limitata.

Fatto 2 — limitatezza via Fejér, non via sublevel set. Si parte dalla disuguaglianza per-step (quella che diventerà la (13)): sostituendo il Polyak step nella fondamentale (6) e maggiorando $\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle$ via il Corollario 3.2 del paper si ottiene

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 \leq \frac{\beta_i \lambda_i \eta_i}{\|\mathbf{d}_i\|_2^2},$$

con $\lambda_i = f(\mathbf{w}_i) - (f_{\text{ref}} - \delta) \geq 0$ sui passi attivi. Il prefattore $\beta_i \lambda_i / \|\mathbf{d}_i\|_2^2$ è ≥ 0 , quindi **il segno del passo è il segno di η_i** , e η_i non dipende da $\|\mathbf{d}_i\|_2$ (questo evita una circolarità: non stiamo assumendo $\|\mathbf{d}_i\|$ limitato per dimostrare che lo è).

Da dove viene η_i (derivazione esplicita). Non è una definizione calata dall’alto: esce dai tre passaggi appena citati, fatti per esteso. (i) *Espansione del quadrato* ($\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i$):

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 = -2\alpha_i \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + \alpha_i^2 \|\mathbf{d}_i\|_2^2.$$

(ii) *Corollario 3.2*, $\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq \gamma_i g_i$ con $g_i := f(\mathbf{w}_i) - f^*$; moltiplicando per $-2\alpha_i \leq 0$ il verso si gira:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 \leq -2\alpha_i \gamma_i g_i + \alpha_i^2 \|\mathbf{d}_i\|_2^2.$$

(iii) *Polyak step* $\alpha_i = \beta_i \lambda_i / \|\mathbf{d}_i\|_2^2$ (con $\lambda_i := f(\mathbf{w}_i) - (f_{\text{ref}} - \delta)$ il gap al *target*), sostituito nei due termini: $-2\alpha_i \gamma_i g_i = -2 \frac{\beta_i \lambda_i}{\|\mathbf{d}_i\|_2^2} \gamma_i g_i$ e $\alpha_i^2 \|\mathbf{d}_i\|_2^2 = \frac{\beta_i^2 \lambda_i^2}{\|\mathbf{d}_i\|_2^2}$. Raccogliendo $\beta_i \lambda_i / \|\mathbf{d}_i\|_2^2$:

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 - \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 \leq \frac{\beta_i \lambda_i}{\|\mathbf{d}_i\|_2^2} \underbrace{(-2\gamma_i g_i + \beta_i \lambda_i)}_{=\eta_i}.$$

Quindi per definizione $\eta_i = -2\gamma_i g_i + \beta_i \lambda_i$, ancora in funzione del gap al target λ_i .

Decomposizione di η_i — chi controlla il segno. Il passo che rende leggibile il segno è riscrivere λ_i (gap al target) tramite g_i (gap all’ottimo). Aggiungendo e togliendo f^* , con l’*offset del target* $t_i := (f_{\text{ref}} - \delta) - f^*$:

$$\lambda_i = f(\mathbf{w}_i) - (f_{\text{ref}} - \delta) = \underbrace{[f(\mathbf{w}_i) - f^*]}_{g_i} - \underbrace{[(f_{\text{ref}} - \delta) - f^*]}_{t_i} = g_i - t_i.$$

Sostituendo $\lambda_i = g_i - t_i$ in $\eta_i = -2\gamma_i g_i + \beta_i \lambda_i$ ed espandendo:

$$\eta_i = -2\gamma_i g_i + \beta_i(g_i - t_i) = \underbrace{-(2\gamma_i - \beta_i)g_i}_{\leq 0 \text{ (floor } \gamma_i \geq \gamma_{\min})} - \underbrace{\beta_i t_i}_{\text{segno di } -t_i}.$$

Il primo termine è sempre ≤ 0 (porta il floor $2\gamma_i - \beta_i = \gamma_i \geq \gamma_{\min}$). Il secondo dipende da *dove sta il target rispetto a f^** :

- se $f_{\text{ref}} - \delta \geq f^*$ (target feasible, $t_i \geq 0$): il secondo termine è ≤ 0 e *rinforza* la discesa $\Rightarrow \eta_i < 0$, la distanza scende;
- se $f_{\text{ref}} - \delta < f^*$ (*overshooting*, $t_i < 0$): il secondo termine è $+\beta_i|t_i| > 0$ e *può* far diventare $\eta_i > 0$ se domina il primo (cioè vicino all'ottimo, dove g_i è piccolo). Qui la distanza all'ottimo *può crescere*.

Poiché $f_{\text{ref}} \geq f^*$ sempre, vale $t_i \geq -\delta$, dunque il termine target aggiunge al più $\beta_i \delta$. La δ -contrazione del Lemma 3.8 manda $\delta \rightarrow 0$ (l'errore di deflection svanisce, oracolo esatto $\sigma^* = 0$), quindi da un indice finito $\bar{i}$ in poi $t_i \geq 0$ *stabilmente* e $\eta_i < 0$: $\|\mathbf{w}_i - \mathbf{w}^*\|_2$ è *non crescente sulla coda* $i \geq \bar{i}$.

Il transiente $i < \bar{i}$. Non serve che sia monotono: basta che sia limitato, e lo è per un motivo elementare. Spacchetto in tre passi, perché è il punto che a prima vista sembra “detto troppo in fretta”.

Passo 1 — ricordare cosa significa “limitato”. Un insieme di vettori S è limitato se esiste un raggio $R < \infty$ con $\|\mathbf{w}\|_2 \leq R$ per ogni $\mathbf{w} \in S$: tutti i punti stanno in una palla di raggio R .

Passo 2 — ogni iterato del transiente è un punto finito. Per induzione sull'update: $\mathbf{w}_0 = \mathbf{0}$ è finito; se $\mathbf{w}_i$ è finito allora $\mathbf{w}_{i+1} = \mathbf{w}_i - \alpha_i \mathbf{d}_i$ è finito, perché $\mathbf{d}_i$ è combinazione di subgradienti finiti, e $\alpha_i = \beta_i \lambda_i / \|\mathbf{d}_i\|_2^2$ è un rapporto di quantità finite con *denominatore* > 0 (se $\|\mathbf{d}_i\|_2^2 < 10^{-30}$ la safeguard 1 *termina* l'algoritmo, quindi non si divide mai per ≈ 0). Somma e multiplo di vettori finiti restano finiti, e la safeguard 3 scarta esplicitamente ogni $\mathbf{w}_{i+1}$ con componente non-finita. Dunque $\|\mathbf{w}_i\|_2 < \infty$ per ogni i .

Passo 3 — finiti quanti punti $\Rightarrow$ massimo delle norme. Il numero di iterati del transiente è $\bar{i} < \infty$ ($\bar{i}$ è finito perché $\delta_k = \rho^k \delta_0 \rightarrow 0$ e basta $\delta \leq f_{\text{ref}} - f^*$ per ripristinare la feasibility del target). Le norme $\|\mathbf{w}_0\|_2, \dots, \|\mathbf{w}_{\bar{i}-1}\|_2$ sono allora *finitamente molti numeri finiti*, e tra finitamente molti reali il massimo *esiste sempre*:

$$R_{\text{trans}} := \max_{0 \leq i < \bar{i}} \|\mathbf{w}_i\|_2 < \infty.$$

Per costruzione ogni punto del transiente ha norma $\leq R_{\text{trans}}$, cioè il transiente è limitato.

Perché “finito” è la parola che conta (e perché la coda è diversa). Per un insieme *infinito* di punti il massimo delle norme può non esistere, anche se ogni singolo punto è finito: la successione $(1, 0, \dots), (2, 0, \dots), (3, 0, \dots), \dots$ ha tutti i punti finiti ma norme $1, 2, 3, \dots$ che crescono senza limite, quindi *non* è limitata. Per questo sulla *coda* (infinita) non basta “punti finiti”: serve Fejér, che tiene le norme tutte sotto $\|\mathbf{w}_{\bar{i}} - \mathbf{w}^*\|_2$. Sul *transiente* (solo $\bar{i}$ punti) il massimo esiste gratis e l'argomento di Fejér non serve.

Unione. $\{\mathbf{w}_i\} = \text{transiente} \cup \text{coda}$, entrambi limitati (raggi R_{trans} e $\|\mathbf{w}_{\bar{i}} - \mathbf{w}^*\|_2 + \|\mathbf{w}^*\|_2$); l'unione sta nella palla di raggio il massimo dei due. Quindi $\{\mathbf{w}_i\}$ è limitata.

La condizione di feasibility è davvero verificata? (e il caso al contorno). La monotonia sulla coda richiede che il target diventi feasible, $f_{\text{ref}} - \delta \geq f^*$, e *ci resti*. Due fatti la garantiscono: $f_{\text{ref}} \geq f^*$ sempre (il record non scende sotto il minimo) e $\delta_k \rightarrow 0$ (Lemma 3.8, le cui ipotesi sono i punti (a)(b)(c) appena verificati). Appena $\delta \leq f_{\text{ref}} - f^*$ il target è feasible. C'è però un caso da dichiarare, perché il prof lo cerca:

- se f_{ref} si *assesta sopra* f^* (margine $f_{\text{ref}} - f^* > 0$ fisso), allora $\delta \rightarrow 0$ scende sotto il margine e la feasibility vale *definitivamente*: monotonia esatta sulla coda, come descritto;
- se invece $f_{\text{ref}} \rightarrow f^*$ (il record converge all'ottimo), il margine $f_{\text{ref}} - f^* \rightarrow 0$ *insieme* a $\delta \rightarrow 0$ e la disuguaglianza $\delta \leq f_{\text{ref}} - f^*$ può oscillare: la feasibility non è garantita “una volta per tutte”. Ma in questo caso $f_{\text{ref}} \rightarrow f^*$ è *già* la tesi di convergenza, quindi nulla va perso.

La limitatezza nel caso al contorno si salva senza invocare la monotonia esatta: il termine di disturbo in η_i è limitato da $\sim \beta_i \delta \rightarrow 0$, dunque la per-step ha la forma *quasi-Fejér* $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 + \varepsilon_i$ con perturbazioni ε_i evanescenti/sommabili. Una successione quasi-Fejér è comunque limitata e convergente: è il contenuto effettivo del Teorema 3.5 del paper, di cui la “monotonia da un indice in poi” è solo la versione semplificata. Riassunto: le ipotesi *sono* verificate; la monotonia stretta vale quando il target è feasible, e dove la feasibility oscilla subentra la quasi-Fejér.

Le condizioni esatte, in forma di enunciato (da saper recitare). Raccolgo in una proposizione *cosa* esattamente garantisce la (quasi-)Fejér, usando la decomposizione $\eta_i = -(2\gamma_i - \beta_i)g_i - \beta_i t_i$ già ottenuta sopra ($g_i = f(\mathbf{w}_i) - f^* \geq 0$ il gap vero, $t_i = (f_{\text{ref}} - \delta) - f^*$ l'offset del target).

Proposizione 1 (Condizione per-passo di non-crescita della distanza). *Al passo i vale $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2$ se sono soddisfatte entrambe:*

- (1) **passo attivo:** $\lambda_i = f(\mathbf{w}_i) - (f_{\text{ref}} - \delta) \geq 0$ (se $\lambda_i < 0$ il passo è nullo, $\alpha_i = 0$, e la distanza resta invariata — comunque non cresce);
- (2) **target feasible:** $f_{\text{ref}} - \delta \geq f^*$, cioè $t_i \geq 0$.

Dimostrazione (tre righe). Sui passi attivi il prefattore $\beta_i \lambda_i / \|\mathbf{d}_i\|_2^2 \geq 0$, quindi il segno della variazione è quello di η_i . Sotto (2), entrambi i termini di η_i sono ≤ 0 : il primo perché $2\gamma_i - \beta_i \geq \gamma_i > 0$ e $g_i \geq 0$; il secondo perché $-\beta_i t_i \leq 0$ quando $t_i \geq 0$. Dunque $\eta_i \leq 0$ e la distanza non cresce. $\square$

Perché (1) e (2) valgono sul nostro problema. (1) è una dicotomia interna all'algoritmo: o il passo è attivo, o la safeguard lo annulla (seconda clausola di (3.5), punto (b)) — in entrambi i casi la distanza non aumenta. (2) vale *definitivamente* perché $f_{\text{ref}} \geq f^*$ sempre e $\delta_k \rightarrow 0$ (Lemma 3.8, ipotesi (a)(b)(c) verificate), quindi $\exists \bar{\tau} : \forall i \geq \bar{\tau}, f_{\text{ref}} - \delta \geq f^*$. Nei finitamente molti passi $i < \bar{\tau}$ con target infeasible la crescita per-passo è limitata da $|t_i| \leq \delta \rightarrow 0$: è esattamente l'errore ε_i della quasi-Fejér.

Definizione 4 (Quasi-Fejér-monotonia). $\{\mathbf{w}_i\}$ è quasi-Fejér rispetto a $\mathbf{w}^*$ se esiste $\varepsilon_i \geq 0$ con $\sum_i \varepsilon_i < \infty$ tale che $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 + \varepsilon_i$. Risultato classico (Polyak; Combettes): una successione quasi-Fejér è *limitata* e $\|\mathbf{w}_i - \mathbf{w}^*\|_2$ converge.

La difesa, in una frase. Non assumo la Fejér-monotonia: è la *tesi* del Teorema 3.5 del paper, che mostra $\{\mathbf{w}_i\}$ quasi-Fejér rispetto a $\mathbf{w}^*$. Le *ipotesi* di quel teorema sono le condizioni (2.13),(3.5),(3.26), verificate sul nostro problema in (a),(b),(c). Il meccanismo concreto è la Proposizione 1: dove il target è feasible la distanza non cresce ($\eta_i \leq 0$, entrambi i termini negativi), e il target diventa feasible definitivamente perché $f_{\text{ref}} \geq f^*$ e $\delta \rightarrow 0$; nei finitamente molti passi iniziali l'overshoot $\leq \delta \rightarrow 0$ dà l'errore sommabile della quasi-Fejér. *Quindi non devo “dimostrare che è Fejér”: devo verificare (a)(b)(c), e l'ho fatto.*

Questo è il punto da raccontare bene all'orale. La limitatezza *non* viene da “ f scende quindi sto in un sublevel set” (falso: SGPTL non è descent). Viene dalla proprietà di Fejér: è la *distanza all'ottimo* a non crescere sulla coda, non il valore di f . Confondere le due cose è esattamente l'errore che è già costato una correzione in questo progetto.

Sulla $\{\mathbf{w}_i\}$ limitata, ∂f è limitato: $\|\mathbf{g}_i\|_2 \leq L$ e $\sup_i \|\mathbf{d}_i\|_2 = D < \infty$ lungo la run. (H2) è verificata.

Non è un loop? (verifico (a)(b)(c) usando la Fejér che dipende da (a)(b)(c)?) No, e il motivo è che *nessuno* di (a),(b),(c) usa la Fejér, e la Fejér non usa L . Guarda *come* si verificano:

- (a) (2.13): vale perché $X = \mathbb{R}^H$, niente proiezione $\Rightarrow$ *struttura* dell'algoritmo;
- (b) (3.5): vale per $\beta_i = \min(1, \gamma_i)$ e il clip $\gamma_i \geq \gamma_{\min}$, più la safeguard $\alpha_i = 0$ se $\lambda_i < 0 \Rightarrow$ *meccanismo* di stepsize;
- (c) (3.26): vale per il Lemma 3.8 ($\delta \rightarrow 0$) implementato dalle righe 16–21 $\Rightarrow$ *logica* del target level.

Tutti e tre si leggono dal *codice*, non da proprietà degli iterati. La Fejér entra solo per ottenere $\|\mathbf{g}_i\|_2 \leq L$, e — punto decisivo — *si dimostra senza L* : il segno della per-step è il segno di η_i , che dipende da $\gamma_i, \beta_i, g_i, t_i$ ma *non* da $\|\mathbf{d}_i\|, \|\mathbf{g}_i\|$ (compaiono solo come fattori positivi che non cambiano il segno). L'ordine delle dipendenze è quindi aciclico:

$$\underbrace{(a), (b), (c)}_{\text{struttura, no Fejér, no } L} \longrightarrow \underbrace{\text{segno } \eta_i \leq 0}_{\text{usa (a),(c); no } L} \longrightarrow \text{Fejér} \longrightarrow \{\mathbf{w}_i\} \text{ limitata} \longrightarrow L \longrightarrow \underbrace{\text{Thm 3.7}}_{\text{usa (a)(b)(c)+} L}.$$

Le frecce vanno in una sola direzione: la Fejér *usa* (a),(c) ma (a),(c) *non* usano la Fejér; e L arriva *dopo* la Fejér, come conseguenza, non come prerequisito.

4.6 (e) Conclusione di convergenza via Teorema 3.7

Verificate (2.13), (3.5), (3.26) con $\sigma^* = 0$, il **Teorema 3.7** del paper dà direttamente

$$f_{\text{ref}}^\infty \leq f^* + \sigma^* = f^*,$$

e poiché $f_{\text{ref}}^\infty \geq f^*$ sempre (è il limite di valori di funzione, tutti $\geq f^*$), si ha $f_{\text{ref}}^\infty = f^*$, cioè $\bar{f}_i \rightarrow f^*$. *Prima parte del teorema dimostrata.*

Per attaccare un *rate* a questa convergenza ci mettiamo nel regime asintotico dove il Lemma 3.8 ha già portato il target $f_{\text{ref}}^k - \delta_k$ esattamente a f^* . Lì il Polyak step usa il target vero: $\alpha_i = \beta_i(f(\mathbf{w}_i) - f^*)/\|\mathbf{d}_i\|_2^2$.

4.7 (f) La disuguaglianza per-step (eq. 3.8 del report)

Obiettivo: dimostrare

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - \beta_i(2\gamma_i - \beta_i) \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2}. \quad (13)$$

Questa è la versione deflessa della fondamentale, ed è la (3.17) del paper. La derivazione (la sviluppo per intero, è l'Appendice D del report) ha tre ingredienti.

Ingrediente 1 — identità (2.9): espandere il quadrato. Senza vincoli,

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 = \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - 2\alpha_i \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle + \alpha_i^2 \|\mathbf{d}_i\|_2^2. \quad (14)$$

È solo $\|\mathbf{w}_i - \alpha_i \mathbf{d}_i - \mathbf{w}^*\|_2^2$ sviluppato. Nessuna disuguaglianza ancora.

Ingrediente 2 — Corollario 3.2: il prodotto interno della direzione deflessa. Qui entra la deflection. Per il subgradiente puro la subgradient inequality (3) darebbe $\langle \mathbf{g}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq f(\mathbf{w}_i) - f^*$, con coefficiente 1. Ma $\mathbf{d}_i$ non è un subgradiente: è una combinazione convessa che include subgradienti *passati* (in $\mathbf{w}_{i-1}, \mathbf{w}_{i-2}, \dots$). Solo il peso γ_i sul subgradiente *corrente* $\mathbf{g}_i$ può essere certificato dalla subgradient inequality. Il Corollario 3.2 (specializzato a $\bar{x} = \mathbf{w}^*$, $\sigma_k = 0$) formalizza questo:

$$\langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \geq \gamma_i (f(\mathbf{w}_i) - f^*). \quad (15)$$

Perché compare γ_i e non 1. È la “perdita indotta dalla deflection”: la memoria $\mathbf{d}_{i-1}$ punta verso $\mathbf{w}^*$ rispetto a iterati *passati*, non rispetto a $\mathbf{w}_i$, quindi non possiamo certificarla con la subgradient inequality in $\mathbf{w}_i$. Solo la frazione γ_i della direzione — il pezzo $\mathbf{g}_i$ fresco — separa garantitamente $\mathbf{w}_i$ da $\mathbf{w}^*$. È esattamente da qui che nascerà il fattore γ_i^2 nel descent, e quindi il $1/\gamma_{\min}^2$ nel conteggio iterazioni.

Ingrediente 3 — sostituire il Polyak step. Nel regime target= f^* , $\alpha_i = \beta_i(f(\mathbf{w}_i) - f^*)/\|\mathbf{d}_i\|_2^2$. Sostituiamo nei due termini non costanti della (14), usando (15) nel primo:

$$-2\alpha_i \langle \mathbf{d}_i, \mathbf{w}_i - \mathbf{w}^* \rangle \stackrel{(15)}{\leq} -2\alpha_i \gamma_i (f(\mathbf{w}_i) - f^*) = -2\beta_i \gamma_i \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2}, \quad (16)$$

$$\alpha_i^2 \|\mathbf{d}_i\|_2^2 = \left(\frac{\beta_i(f(\mathbf{w}_i) - f^*)}{\|\mathbf{d}_i\|_2^2} \right)^2 \|\mathbf{d}_i\|_2^2 = \beta_i^2 \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2}. \quad (17)$$

Collezionando. Sommando (16) e (17) nella (14) e raccogliendo β_i :

$$\|\mathbf{w}_{i+1} - \mathbf{w}^*\|_2^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|_2^2 - \underbrace{(2\beta_i \gamma_i - \beta_i^2)}_{=\beta_i(2\gamma_i - \beta_i)} \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2},$$

che è la (13). ✓

Specializzazione al nostro algoritmo. Poiché il clip tiene $\gamma_i \leq 1$, l'algoritmo pone $\beta_i = \min(1, \gamma_i) = \gamma_i$. Allora il fattore di discesa collassa:

$$\beta_i(2\gamma_i - \beta_i) = \gamma_i(2\gamma_i - \gamma_i) = \gamma_i^2 \geq \gamma_{\min}^2. \quad (18)$$

4.8 (g) Telescoping: da dove nasce il $1/\sqrt{k}$

Inserendo $\beta_i(2\gamma_i - \beta_i) = \gamma_i^2 \geq \gamma_{\min}^2$ nella (13) e sommando da $i = 0$ a k . La somma a sinistra *telescopa* (i termini intermedi si cancellano: $\sum_i (\|\mathbf{w}_i - \mathbf{w}^*\|^2 - \|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2) = \|\mathbf{w}_0 - \mathbf{w}^*\|^2 - \|\mathbf{w}_{k+1} - \mathbf{w}^*\|^2$), e buttando via il termine finale non negativo $\|\mathbf{w}_{k+1} - \mathbf{w}^*\|^2 \geq 0$:

$$\gamma_{\min}^2 \sum_{i=0}^k \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|_2^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2.$$

Usando $\|\mathbf{d}_i\|_2 \leq L$ dalla (10) (quindi $1/\|\mathbf{d}_i\|_2^2 \geq 1/L^2$):

$$\sum_{i=0}^k (f(\mathbf{w}_i) - f^*)^2 \leq \frac{L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2}{\gamma_{\min}^2}.$$

Adesso il trucco del record. Per ogni $i \leq k$, $\bar{f}_k - f^* \leq f(\mathbf{w}_i) - f^*$ (il record è il minimo), quindi $(\bar{f}_k - f^*)^2 \leq (f(\mathbf{w}_i) - f^*)^2$ per ogni i , e sommando $k+1$ copie:

$$(k+1)(\bar{f}_k - f^*)^2 \leq \sum_{i=0}^k (f(\mathbf{w}_i) - f^*)^2 \leq \frac{L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2}{\gamma_{\min}^2}.$$

Dividendo per $(k+1)$ e prendendo la radice:

$$\boxed{\bar{f}_k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|_2}{\gamma_{\min} \sqrt{k+1}}}$$

che è la (12). *Seconda parte del teorema dimostrata.*

La logica del $1/\sqrt{k}$ in una frase. Il telescoping limita la *somma* degli $k+1$ gap al quadrato con una costante. Se la somma di $k+1$ numeri positivi è limitata, il più piccolo di essi (il record) è al più costante/ $(k+1)$ al quadrato, cioè $\sim 1/\sqrt{k+1}$ dopo la radice. È lo stesso meccanismo del rate dei subgradient methods classici; la deflection cambia solo la costante (mette $\gamma_{\min}^2$ al denominatore).

4.9 (h) Conteggio iterazioni e il prezzo $1/\gamma_{\min}^2$

Risolvendo la (12) per il numero di iterazioni necessario a $\bar{f}_k - f^* \leq \varepsilon$:

$$k+1 \geq \frac{L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2}{\gamma_{\min}^2 \varepsilon^2}.$$

Il Polyak *non* deflesso, sotto le stesse ipotesi (stesso conto col fattore $\beta_i(2-\beta_i)$ invece di $\beta_i(2\gamma_i - \beta_i)$), dà $k+1 \geq L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|_2^2 / \varepsilon^2$. Quindi:

- il *rate-order* è lo stesso, $O(L^2/\varepsilon^2)$ — ed è *ottimale*: il lower bound per metodi del prim'ordine su convessi nonsmooth è $\Omega(L^2/\varepsilon^2)$;
- la deflection *gonfia la costante* di un fattore $1/\gamma_{\min}^2$. Con $\gamma_{\min} = 0.05$ è un moltiplicatore $1/0.05^2 = 400\times$.

Trade-off da saper difendere. Perché accettare un $400\times$? Perché il $1/\gamma_{\min}^2$ è un bound *worst-case* sulla costante, mentre la deflection *riduce in pratica* l'oscillazione (zig-zag) che fa esplodere il numero di iterazioni reali su problemi mal condizionati. Inoltre $\gamma_{\min}$ entra solo nel *floor*: nella maggior parte delle iterazioni γ_i è ben più grande di $\gamma_{\min}$ (il clip è inattivo), quindi il $400\times$ è un soffitto raramente toccato. La scelta $\gamma_{\min} = 0.05$ bilancia “clip quasi sempre inattivo” (serve $\gamma_{\min}$ piccolo) contro “costante peggiore $1/\gamma_{\min}^2$ ” (serve $\gamma_{\min}$ non troppo piccolo). Vedi §3.4.1 del report.

□

5 Le due derivazioni che il report manda in appendice

Per completezza, ricostruisco i due conti che la prova usa come scatole nere.

5.1 Appendice D — la per-step (3.8) per intero

È esattamente la Sezione 4.7 sopra (l'ho già svolta lì passo per passo: identità (2.9) → Corollario 3.2 → sostituzione Polyak → raccolta). Il punto concettuale da ricordare: *il γ_i in (15) è la sorgente di tutto il peggioramento.*

5.2 Appendice E — la formula chiusa di γ^*

Si minimizza $h(\gamma) = \|\gamma \mathbf{g}_i + (1 - \gamma) \mathbf{d}_{i-1}\|_2^2$. Sviluppando per bilinearità del prodotto interno e raccogliendo le potenze di γ :

$$h(\gamma) = \underbrace{\|\mathbf{g}_i - \mathbf{d}_{i-1}\|_2^2}_{\geq 0} \gamma^2 + 2(\langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle - \|\mathbf{d}_{i-1}\|_2^2) \gamma + \|\mathbf{d}_{i-1}\|_2^2.$$

È una parabola con coefficiente di testa $\|\mathbf{g}_i - \mathbf{d}_{i-1}\|_2^2 \geq 0$, quindi convessa verso l'alto. Annullando $h'(\gamma) = 0$:

$$\gamma^* = \frac{\|\mathbf{d}_{i-1}\|_2^2 - \langle \mathbf{g}_i, \mathbf{d}_{i-1} \rangle}{\|\mathbf{g}_i - \mathbf{d}_{i-1}\|_2^2}.$$

Poiché la parabola apre verso l'alto, il minimo su $[\gamma_{\min}, 1]$ è la proiezione del vertice: $\gamma_i = \min(1, \max(\gamma_{\min}, \gamma^*))$. Casi limite: se $\mathbf{g}_i = \mathbf{d}_{i-1}$ il coefficiente di testa si annulla, h è costante e si pone $\gamma_i = 1$ per convenzione; alla prima iterazione $\mathbf{d}_{-1} = \mathbf{0}$ darebbe $\gamma^* = 0$, ma si forza $\gamma_0 = 1$ così che $\mathbf{d}_0 = \mathbf{g}_0$.

Interpretazione del clip (utile all'orale). I due estremi del clip servono a due cose *diverse*: il clip inferiore $\gamma_{\min}$ fornisce il $\beta^* = \gamma_{\min} > 0$ della condizione (3.5) — è ciò che rende la prova valida; il clip superiore a 1 tiene $\gamma_i \in (0, 1]$ così che $\mathbf{d}_i$ resti combinazione convessa di $\mathbf{g}_i$ e $\mathbf{d}_{i-1}$ — proprietà usata in (10) e nel Corollario 3.2.

6 Verifica delle ipotesi sul problema specifico ELM+LASSO

Il report dedica un paragrafo apposta a questo (è ciò che il prof valuta di più). Riepilogo:

- **(H1) minimo finito raggiunto.** Vera per coercività (Prop. 1.1): f è somma di un quadratico $\succeq 0$ e di $\lambda_{\text{LASSO}} \|\cdot\|_1$ con $\lambda_{\text{LASSO}} > 0$, quindi $f(\mathbf{w}) \rightarrow \infty$ per $\|\mathbf{w}\| \rightarrow \infty$; un livello-insieme è compatto e f continua vi raggiunge il minimo.
- **(H2) $\|\mathbf{g}_i\|_2 \leq L$.** La parte liscia $\mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$ cresce con $\|\mathbf{w}\|$ ma resta limitata su ogni limitato; la parte L_1 ha subgradienti in $[-1, 1]^H$, sempre limitati. Poiché $\{\mathbf{w}_i\}$ è limitata (Fejér, Sezione 4.5), $L < \infty$. *Verificata, non assunta.*
- **(H3) stepsize-restricted.** $\beta_i \leq \gamma_i$ per costruzione ($\beta_i = \min(1, \gamma_i)$) e $\gamma_i \geq \gamma_{\min}$ per il floor del clip.

7 Cosa deve combaciare con gli esperimenti

Il rate (12) predice, su un grafico log-log di $\bar{f}_i - f^*$ contro i , una retta di pendenza $-1/2$ (cioè involuppo $\propto 1/\sqrt{i}$). Punti da tenere a mente per discutere la Figura 5.1/5.12:

- Il teorema limita il *record* $\bar{f}_i$, non il valore corrente $f(\mathbf{w}_i)$. Quindi nel plot la curva-record (rossa) sta sotto l'involuppo $1/\sqrt{i}$, mentre il valore corrente (arancione) *oscilla* sopra: coerente con la non-monotonicità.
- L scala con $\|\mathbf{X}\|_2$ e λ_{LASSO} (più penalità $\Rightarrow$ involuppo più alto).
- $\|\mathbf{w}_0 - \mathbf{w}^*\|_2$ entra moltiplicativamente: separa cold start ($\|\mathbf{w}^*\|$) da warm start OLS ($\|\mathbf{w}_{\text{OLS}} - \mathbf{w}^*\|$). Quale dei due vince dipende dall'istanza.

8 Domande tipiche del professore, con risposte

D1. “Mi dimostri che gli iterati sono limitati.”

Trappola: se rispondi “stanno nel sublevel set $\{f \leq f(\mathbf{w}_0)\}$ ” hai **sbagliato**, perché SGPTL non è un metodo di discesa ($f(\mathbf{w}_i)$ oscilla). *Risposta corretta:* la limitatezza viene dalla proprietà di Fejér. Dalla per-step (13) la distanza al quadrato $\|\mathbf{w}_i - \mathbf{w}^*\|^2$ è non crescente sui passi attivi finché il record sta sopra f^* (il termine sottratto è ≥ 0); quindi gli iterati della coda stanno nella palla di raggio $\|\mathbf{w}_0 - \mathbf{w}^*\|$, e i finitamente molti precedenti formano un insieme limitato. È la *distanza all’ottimo* a non crescere, non il valore di f .

D2. “Perché nel Corollario 3.2 compare γ_i e non 1?”

Perché $\mathbf{d}_i$ non è un subgradiente in $\mathbf{w}_i$: è una combinazione convessa che pesa γ_i sul subgradiente corrente $\mathbf{g}_i$ e $1 - \gamma_i$ su direzioni passate. Solo il pezzo $\gamma_i \mathbf{g}_i$ può essere certificato dalla subgradient inequality in $\mathbf{w}_i$ a separare $\mathbf{w}_i$ da $\mathbf{w}^*$. Le direzioni passate “puntavano a $\mathbf{w}^*$ ” rispetto a iterati precedenti, non a $\mathbf{w}_i$. È la perdita indotta dalla deflection, e si propaga fino al fattore γ_i^2 nel descent.

D3. “Da dove esce il $1/\sqrt{k}$? Perché non lineare come IRLS?”

Dal telescoping: la somma degli $k + 1$ gap al quadrato è limitata da una costante, quindi il minimo (record) è $\leq \text{cost}/(k + 1)$ al quadrato, cioè $\sim 1/\sqrt{k + 1}$. È sublineare, non lineare, perché i subgradient methods sfruttano solo l’informazione del prim’ordine nonsmooth: il lower bound $\Omega(L^2/\varepsilon^2)$ dice che *non si può* fare meglio in $O(\cdot)$. IRLS è lineare perché lavora sulla *riformulazione liscia* (Newton-like, informazione di second’ordine), un regime diverso.

D4. “Il clip a $\gamma_{\min}$ ve lo siete inventato voi: serve davvero?”

Sì, serve per verificare l’ipotesi (3.5) del teorema citato. Il greedy che minimizza $\|\mathbf{d}_i\|^2$ su $[0, 1]$ può mandare $\gamma_i \rightarrow 0^+$ vicino alla stazionarietà; ma (3.5) richiede un bound *uniforme* $\beta_i \geq \beta^* > 0$. Il clip a $\gamma_{\min}$ fornisce $\beta^* = \gamma_{\min}$. Senza, non potremmo invocare il Teorema 3.7. Il costo è il fattore $1/\gamma_{\min}^2$ nella costante, accettabile perché è worst-case e il clip è quasi sempre inattivo.

D5. “Il teorema assume $\|\mathbf{g}_i\| \leq L$. Non è circolare assumerlo e poi usarlo?”

No: nel report l’ipotesi (H2) è *dimostrata sul nostro problema*, non assunta. La catena è: Fejér $\Rightarrow$ iterati limitati $\Rightarrow$ (Lipschitz locale di f finita su $\mathbb{R}^H$) $\Rightarrow$ subgradienti limitati. E non è circolare con la per-step: nel Fatto 2 di Sezione 4.5 il segno del passo dipende da η_i , che è *indipendente* da $\|\mathbf{d}_i\|$, quindi non stiamo assumendo ciò che vogliamo provare.

D6. “Cosa garantisce che il target $f_{\text{ref}} - \delta$ non resti sempre sotto f^* e blocchi tutto?”

Il contatore di pazienza: se per uno spostamento accumulato $r > R$ non scatta la discesa sufficiente, si contrae $\delta \mapsto \rho\delta$. Le contrazioni ripetute danno $\delta \rightarrow 0$ (Lemma 3.8), quindi prima o poi $f_{\text{ref}} - \delta \geq f^*$ e il test torna feasible. Formalmente è la condizione (3.26): $\liminf \delta_k = 0$ più la serie (3.25).

D8. “Dice Fejér-monotona da un certo indice in poi: perché non da $\mathbf{w}_0$? E cosa controlla il comportamento prima di quell’indice?”

Perché non da $\mathbf{w}_0$: il passo di Polyak usa il gap al target $f_{\text{ref}} - \delta$, non a f^* . La variazione della distanza ha segno $\eta_i = -(2\gamma_i - \beta_i)\mathbf{g}_i - \beta_i \mathbf{t}_i$ con $\mathbf{g}_i = f(\mathbf{w}_i) - f^* \geq 0$ e $\mathbf{t}_i = (f_{\text{ref}} - \delta) - f^*$. All’inizio $\delta_0 = c f(\mathbf{w}_0)$ è tarato senza conoscere f^* e può mandare il target *sotto* f^* ($t_i < 0$, overshooting): allora il termine $-\beta_i \mathbf{t}_i = +\beta_i |t_i|$ è positivo e la distanza all’ottimo può *crescere*.

Quindi la monotonia non vale da $\mathbf{w}_0$.

Cosa controlla il transiente: non la monotonia, ma la sua *finitezza*. La δ -contrazione del Lemma 3.8 ($\delta \mapsto \rho\delta$ quando la pazienza $r > R$) manda $\delta \rightarrow 0$; poiché $f_{\text{ref}} \geq f^*$ sempre, appena $\delta \leq f_{\text{ref}} - f^*$ il target torna feasible e ci resta, dopo un numero finito di contrazioni $\Rightarrow$ indice $\bar{i}$ finito. Il transiente $\{\mathbf{w}_0, \dots, \mathbf{w}_{\bar{i}-1}\}$ è un insieme finito di punti finiti, dunque limitato. La limitatezza globale è (transiente limitato) $\cup$ (coda Fejér). *Trabocchetto da evitare:* pretendere “Fejér da subito” è lo stesso tipo di errore del sublevel-set — si assume una monotonia che il metodo non ha. Alla limitatezza dei subgradienti basta la monotonia *sulla coda*.

D9. “Mi enunci esattamente sotto quali condizioni la successione è Fejér-monotona, e perché valgono qui.”

Inquadramento (la mossa che sblocca): la (quasi-)Fejér non è un’ipotesi che assumo, è la *tesi* del Teorema 3.5 del paper; io devo solo verificarne le ipotesi — le condizioni (2.13), (3.5), (3.26) — e l’ho fatto in (a), (b), (c).

Condizione per-passo (Proposizione 1): la distanza $\|\mathbf{w}_i - \mathbf{w}^*\|$ non cresce al passo i se (1) il passo è attivo ($\lambda_i = f(\mathbf{w}_i) - (f_{\text{ref}} - \delta) \geq 0$; altrimenti $\alpha_i = 0$ e la distanza è invariata) e (2) il target è feasible ($f_{\text{ref}} - \delta \geq f^*$). Sotto (1)+(2), nella variazione $\propto \eta_i = -(2\gamma_i - \beta_i)g_i - \beta_i t_i$ entrambi i termini sono ≤ 0 ($2\gamma_i - \beta_i \geq \gamma_i > 0$, $g_i \geq 0$, $t_i \geq 0$), quindi $\eta_i \leq 0$.

Perché valgono: (1) è una dicotomia gestita dall’algoritmo; (2) vale *definitivamente* perché $f_{\text{ref}} \geq f^*$ sempre e $\delta \rightarrow 0$ (Lemma 3.8). Nei finitamente molti passi iniziali in cui il target sovrastima ($f_{\text{ref}} - \delta < f^*$) la distanza può salire, ma di al più $\sim |t_i| \leq \delta \rightarrow 0$: questo è l’errore sommabile ε_i della *quasi-Fejér* (Definizione 4), che basta per limitatezza e convergenza. *Non recito “è Fejér”:* verifico (a)(b)(c) e leggo il segno di η_i .

D10. “Per verificare (a)(b)(c) e applicare il Teorema 3.5/3.7 lei usa la Fejér-monotonia, che però è la tesi di quei teoremi. Non è circolare?”

No, perché *nessuno* di (a), (b), (c) usa la Fejér, e la Fejér non usa L . (a) vale per assenza di proiezione ($X = \mathbb{R}^H$); (b) per il clip $\gamma_i \geq \gamma_{\min}$ e la safeguard; (c) per il Lemma 3.8 ($\delta \rightarrow 0$): tutti e tre si leggono dalla *struttura dell’algoritmo*, non dagli iterati. La Fejér serve solo per $\|\mathbf{g}_i\| \leq L$, e si dimostra *senza* L perché il segno della per-step (η_i) è indipendente da $\|\mathbf{d}_i\|, \|\mathbf{g}_i\|$. L’ordine è aciclico: (a)(b)(c) $\rightarrow$ segno $\eta_i \leq 0 \rightarrow$ Fejér $\rightarrow \{\mathbf{w}_i\}$ limitata $\rightarrow L \rightarrow$ Teorema 3.7. La Fejér *usa* (a), (c), ma (a), (c) non usano la Fejér, e L arriva *dopo* la Fejér come conseguenza. Nessun cerchio si chiude.

D7. “Perché $\beta = 1$?”

Sostituendo il Polyak step nella fondamentale, la riduzione di $\|\mathbf{w}_i - \mathbf{w}^*\|^2$ è proporzionale a $\beta(2 - \beta)$, una parabola verso il basso massimizzata in $\beta = 1$. Quindi $\beta = 1$ è la scelta che dà la massima discesa per-step; con $\beta = 1$, $\beta_i = \min(1, \gamma_i)$ è guidato interamente da γ_i .